

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-1234-98765

Miroslav Hájek

Spracovanie dát generovaných senzorovou IoT sieťou

Bakalárska práca

Vedúci práce: Ing. Marcel Baláž, PhD.

Máj 2022

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-1234-98765

Miroslav Hájek

Spracovanie dát generovaných senzorovou IoT sieťou

Bakalárska práca

Študijný program: Informatika
Študijný odbor: Informatika
Miesto vypracovania: Ústav počítačového inžinierstva a aplikovanej informatiky
Vedúci práce: Ing. Marcel Baláž, PhD.
Pedagogický vedúci: Ing. Jakub Findura

Máj 2022

Bakalársky projekt

Akademický rok:	2021/2022
Vedúci projektu:	Ing. Marcel Baláž, PhD.
Pedagogický vedúci:	Ing. Jakub Findura
Pridelený študentovi:	Miroslav Hájek
Študijný program:	Informatika
Miesto vypracovania:	Ústav počítačového inžinierstva a aplikovanej informatiky, FIIT STU

Spracovanie dát generovaných senzorovou IoT sieťou

Senzorové IoT siete sa stali bežnou súčasťou rôznych priemyselných procesov. Ich primárnou úlohou je zbieranie rôznorodých dát z prostredia, ich ukladanie a vyhodnocovanie v reálnom čase. Analyzovanie a vyhodnocovanie dát pri nepretržitom monitorovaní už len z malého množstva senzorov predstavuje veľkú výzvu. Sensory produkujú veľké množstvo dát a anomálie nemusia byť na prvý pohľad detegovateľné.

Cieľom projektu je analyzovať dáta zachytené senzorovou sieťou. Analyzovať algoritmy na ich ukladanie a spracovanie. Analyzujte jednotlivé úrovne senzorovej siete a identifikujte miesta, kde by sa dali dáta čiastočne spracovať. Na základe analýzy navrhnete spôsob ukladania a spracovania dát, prípadne optimalizáciu toku dát pre existujúcu senzorovú sieť. Vaše riešenie implementujte a otestujte jeho funkčnosť.

Čestné prehlásenie

Čestne vyhlasujem, že som túto prácu vypracoval samostatne, na základe konzultácií a s použitím uvedenej literatúry.

V Bratislave, 1.5.2022

.....

Miroslav Hájek

Pod'akovanie

Text pod'akovania

Anotácia

Slovenská technická univerzita v Bratislave

Fakulta informatiky a informačných technológií

Študijný program: Informatika

Autor: Miroslav Hájek

Bakalárska práca: Spracovanie dát generovaných senzorovou IoT sieťou

Vedúci bakalárskej projektu: Ing. Marcel Baláž, PhD.

Pedagogický vedúci: Ing. Jakub Findura

Máj 2022

Stručná charakteristika zadania bakalárskeho projektu ale predovšetkým výsledkov bakalárskeho projektu v slovenskom a anglickom jazyku každá v rozsahu max. 1 strany A4 (hlavička + cca 150-200 slov).

Annotation

Slovak University of Technology Bratislava

Faculty of Informatics and Information Technologies

Degree course: Informatics

Author: Miroslav Hájek

Bachelor's Thesis: Data Processing for Sensor IoT Network

Supervisor: Dr. Marcel Baláž

Departmental advisor: Jakub Findura

2022, May

Annotation text in English, 150-200 words.

Obsah

1	Úvod	1
2	Analýza	3
2.1	Monitorovanie vibrácií a šoku	3
2.1.1	Meranie fyzikálnej veličiny akcelerácie	4
2.1.2	Odvodzovanie rýchlosti a dráhy zo zrýchlenia	9
2.2	Metódy analýzy signálu v časovej doméne	12
2.2.1	Číselné charakteristiky štatistického rozdelenia	13
2.2.2	Algoritmy na rozpoznávanie špičiek	15
2.2.3	Online detekcia anomálií a odchýliek pozorovaní	21
2.3	Frekvenčná a časovo-frekvenčná analýza signálu	22
2.3.1	Fourierová transformácia	22
2.3.2	Algoritmus FFT pre DFT a DCT	22
2.3.3	Oknové funkcie	23
2.3.4	Filtre s konečnou impulznou odozvou	23
2.4	Senzorová sieť	23
2.4.1	Senzorová jednotka	25
3	Opis riešenia	29
3.1	Hardvér sensorovej jednotky	29
3.2	Vývojové prostredie a knižnice	29
3.3	Koordinácia subsystémov	30
3.4	Konzervácia energie znížením vzorkovania	30
3.5	Pravidlový systém na extrahovanie črt záujmu	30
4	Zhodnotenie	33

A Technická dokumentácia

B Harmonogram práce

C Obsah digitálneho média

1 Úvod

2 Analýza

2.1 Monitorovanie vibrácií a šoku

Vibrácie sú periodickým kmitaním hmoty okolo rovnovážnej polohy vznikajúce excitáciou látky, ktorej je dodaná potenciálna energia, a zo zákona zachovania energie je následne premieňaná na kinetickú energiu. V realite dochádza pôsobením trenia k útlmu voľného oscilačného pohybu s časom a pohybová energia sa uvoľňuje v podobe tepelnej alebo akustickej emisie do okolitého prostredia. Častejšie ako presné harmonické kmity sú pozorované náhodné vibrácie, ktorých vývoj nevieme dopredu predvídať. Naproti tomu šok, alebo aj prechodový jav, je náhle uvoľnenie kinetickej energie krátkeho trvania oproti prirodzenej oscilácii systému.

Význam a dôležitosť sledovania vibrácií spočíva v ich výskyte u každého mechanického zariadenia a je zapríčinená pohybom jednotlivých súčiastok a trením v ložiskách. Ich nadmerná prítomnosť býva spôsobená opotrebením dielov stroja alebo nevyvážením rotačných častí, zakliesňovaním ozubených kolies, ako dôsledkoch iných technických defektov. V prevažnej väčšine prípadov ide o nežiaduci jav nakoľko zakladá zníženiu účinnosti so zvýšením hlučnosti ako vedľajšiemu produktu.

Ďalšou oblasťou hojnej prítomnosti vibrácií je preprava osôb alebo tovaru cestnými a železničnými dopravnými prostriedkami, kde sú zapríčinené nerovnosťami povrchu vozovky alebo koľaje v bode styku s kolesami vozidla. Na zvýšenie ovládateľnosti vozidla a komfortu pasažierov sú kabíny odpružené od kolies tlmičmi. Lietadlá sú zasa pod vplyvom trenia vzduchu s trupom a krídlami konštrukcie, ktoré je ďalej zosilnené vzdušnými prúdmi a turbulenciami.

Druhým významným faktorom podieľajúci sa na tvorbe vibrácii je aparát, ktorý uvádza vozidlo do pohybu alebo zastavuje, čiže hnací najčastejšie spaľovací, dieselový alebo elektrický motor a brzdomý systém. Jedná sa najmä o vplyv pohybu


piestov, alebo rotora u elektrických vozidiel, a prenosu otáčavého pohybu motora cez oje hriadeľa na nápravy. ABS brzdový systém prítomný pri väčšine automobilov zabraňuje šmyku striedavým zomknutím a uvoľňovaním brzdových kotúčov, čo má tiež vplyv na podmienky počas jazdy.

Detekciou nežiaducich vibrácií v preprave sa dokáže zabezpečiť aj bezpečnosť pasažierov včasnou výmenou súčiastky, ktorá by ovplyvnila prevádzkyschopnosť v kritických momentoch. Ich eliminácia dokáže predísť nenávratnému poškodeniu krehkých materiálov alebo znehodnoteniu reaktívnych substancií, či dokonca ich aktivácii v prípade výbušnín a pyrotechniky.

V neposlednom rade sú vibrácie súčasťou potenciálne nebezpečných prírodných úkazov a ich správna identifikácia má za následok varovania pre preventívnu evakuáciu obyvateľstva v oblasti, ktoré bude zasiahnutá zemetrasením, či erupciou sopky vedúcimi k ohrozenia zdravia osôb a poškodenia majetku.

2.1.1 Meranie fyzikálnej veličiny akcelerácie

Pohyb mechanického systému vystaveného vonkajším silám sa nazýva odozva, ktorej správanie opisuje zjednodušený model s jedným stupňom voľnosti (1DOF) kmitajúceho telesa s pružinou a tlmičom [1].



Obr. 2.1: Model oscilujúceho systému s pružinou a tlmičom

Pri pôsobení vonkajšej sily F na hmotu upevnenú na pružine vznikajú nútené vibrácie, ktoré ju vychýľujú z rovnovážnej polohy. Uvedená sila je charakterizovaná druhým Newtonovým zákonom v tvare $F = ma$, kde m je hmotnosť telesa a a predstavuje zrýchlenie. V protismere pôsobí sila vyvolaná pružinou $F_s = -kx$ a

tlmiacim členom $F_d = -cv$, kde k je tuhosť pružiny ovplynená jej konštrukciou, c je tlmiaci koeficient, x je vychýlenie z rovnovážneho stavu, a v rýchlosť vychýlenia. Fyzickým obmedzením telesa, ktorým je viazaný na pevnú podložku dochádza pri zanedbaní deformácie k takmer zaručenému návratu do rovnovážnej polohy a to nám umožňuje merať intenzitu vibrácií cez zrýchlenie ťažidla. Výslednú silu v jednom smere získame sčítaním síl podieľajúcich sa na dynamike telesa.

$$F(t) = ma - cv - kx \quad (2.1)$$

Pri použití trojosového akcelerometra, kedy sú evidované všetky tri priestorové súradnice časovo-premennej akcelerácie dostávame nasledujúcu rovnicu vo vektorovom tvare:

$$\vec{a}(t) = \frac{\vec{F}(t)}{m} \quad (2.2)$$


Magnitúda akcelerácie s tromi súradnicami je daná L_2 normou vektora $\vec{a} = (a_x, a_y, a_z)$:

$$|a| = \sqrt{a_x^2 + a_y^2 + a_z^2} \quad (2.3)$$

MEMS kapacitný akcelerometer

Bežné inerciálne senzory na meranie zrýchlenia priamočiareho, ale aj rotačného pohybu (gyroskop), sa vyrábajú technológiou *MEMS* – *mikromechanický systém*, kedy je celé zariadenie vrátane všetkých mechanických súčastí umiestnené na kremík procesom mikrovýroby vo viacerých vrstvách. Sila spôsobujúca zrýchlenie je potom meraná vychýlením vstavanej odpruženej hmoty vzhľadom na pevné elektródy, ktoré môžu byť usporiadané jednostranne alebo ako diferenčný pár [2].

Pri diferenčnom páre spôsobí pohyb doštičky ťažidla medzi elektródami zmenu kapacít a ich rozdielom je možné zistiť aplikovanú silu a cez uvedený vzťah zrýchlenie. Na zvýšenie celkovej kapacity sa používa viacero párov elektród zapojených paralelne. Pred prevodom na číslicový signál musí napäťová úroveň zo senzora prejsť úpravou zahŕňajúcou nábojovocitlivý predzosilňovač, osovú demoduláciu a anti-aliasingové filtrovanie. Viacosové akcelerometre vyžadujú viaceré opísané štruktúry orientované kolmo na seba podľa počtu vyžadovaných stupňov voľnosti, pričom v



Obr. 2.2: Mikroštruktúra 3DOF MEMS kapacitného akcelerometra

skutočných senzoroch vždy existuje aspoň minimálna závislosť medzi osami rádo-
vo najviac v jednotkách percent. Teplota ovplyvňuje citlivosť MEMS akcelerometrov
len nepatrne v stotinách percenta na stupeň Celzia.

Akcelerometre sa odlišujú v niekoľkých dôležitých vlastnostiach, ktoré zvyknú
byť nastaviteľné vo výrobcom stanovenom rozsahu prípustných hodnôt s prísluš-
nými toleranciami [3]. *Citlivosť* stanovuje najmenšiu rozlíšiteľnú zmenu v odčítanom
napätí ku zmene externého pohybu respektíve zrýchlenia. Uvádza sa v jednotkách
 mV/g (milivolt na tiažové zrýchlenie) pri analógovom výstupe, alebo mg/LSB (mili-
g na najmenej významový bit). pri senzoroch so vstavaným analógovo-digitálnym
prevodníkom. Jednotka mg/LSB vyjadruje o koľko sa zmení zrýchlenie keď zvýšime
alebo ponížime binárne číslo na výstupe o jedna. Niekedy sa namiesto citlivosti uvá-
dza mierka pre presnosť ako prevrátená hodnota citlivosti v LSB/g . Tiažové zrých-
lenie g sa mierne líši podľa zemepisnej šírky, ale stanovený prepočet na jednotky SI
je $1g = 9.80665 m/s^2$ ¹.

Dynamický rozsah sa uvádza v tiažovom zrýchlení g . Hovorí o najmenej a naj-
väčšej rozlíšiteľnej hodnote zrýchlenia nad úrovňou ktorej už dochádza k skresleniu
signálu orezaním špičiek. S nevyhnutnými drobnými nepresnosťami výroby mik-
romechaniky je tzv. *zero-g napätie* popisujúce odchýlku skutočného od ideálneho
výstupu, keď na sústavu nepôsobí žiadne zrýchlenie. Za ideálnych okolností bez po-

¹https://physics.nist.gov/cgi-bin/cuu/Value?gn|search_for=acceleration

hybu na vodorovnom povrchu namerajú osi x a y zrýchlenie $0g$, zatiaľčo na z pôsobí $1g$. Očakávaním je nulová hodnota výstupného napätia a tým aj výstupného registra.

Šírka pásma senzora v Hz predurčuje rozsah frekvencie vibrácií, ktoré je možné zachytiť. Podmienená je zvolenou početnosťou čítania akcelerácie za sekundu, čiže vzorkovacou frekvenciou. Stanovuje sa tiež nastaviteľným parameterom *ODR* (Output Data Rate) - výstupný dátový tok, pričom šírka pásma je spravidla polovicou ODR. Menej uvádzanou vlastnosťou býva *frekvenčná odozva* senzora, ktorá určuje o koľko sa v rámci tolerancie odlišuje skutočná citlivosť od referenčnej pre zodpovedajúcu frekvenciu vibrácií. Na meranie zrýchlenia má nevyhnutný vplyv šum zapríčinený Brownovým pohybom a nedokonalosťou skutočných materiálov v štruktúre akcelerometra. Intenzita šumu rastie inverznou odmocninou so šírkou pásma, čiže s častejším meraním získavame menšiu presnosť. Pri dostatočnom odstupe signálu od šumu, $SNR = P_{signal}/P_{um}$, umožňuje hardvér akcelerometra vzorkovať amplitúdy až nad stanovený prah generovaním prerušenia, čím sa dokáže efektívne zbaviť nevýznamných fluktuácií.


Analógovo-digitálny prevodník

Spojité napäťová úroveň transformuje analógovo-digitálny (A/D) prevodník pre spracovanie digitálnym systémom do množiny diskretných hodnôt. Vstupný signál najprv prechádza fázou vzorkovania, kedy sa vzorky zaznamenávajú v pravidelných intervaloch. Počet vzoriek odčítaných za sekundu je vyjadrený vzorkovacou frekvenciou f_s v Hz . Časový rozdiel medzi vzorkami, nazývaný perióda vzorkovania, je prevrátenou hodnotou vzorkovacej frekvencie $T_s = \frac{1}{f_s}$. Pre presnú rekonštrukciu pásmovo obmedzeného signálu v hraniciach $[-f_{max}; f_{max}]$ je nevyhnuté podľa Nyquist-Shannonovej vety o vzorkovaní, aby vzorkovacia frekvencia bola najmenej dvojnásobkom maximálnej frekvencie snímaného signálu.

$$f_s \geq 2 \cdot f_{max} \quad (2.4)$$

Každej vzorke je následne v procese kvantovania priradená diskretná hodnota s konečným počtom n bitov, ktorá je najbližšia možná ku skutočnej hladine analógového vstupu. Dochádza pritom k istému zaokrúhľovaniu z dôvodu nepresnosti vyjadrenia spojitkej domény amplitúd diskretným číslom. Tento jav označujeme ako

kvantizačný šum, ktorý je najviac polovicou z maximálnej rozlíšiteľnej zmeny signálu a trpia nim všetky existujúce A/D prevodníky. Rovnako tak sa u všetkých prevodníkov prejavuje aspoň nepatrná miera nelinearity výstupného kódu, chýbajúce kódy alebo ich nemonotónnosť.



Obr. 2.3: Digitalizácia signálu v analógovo-digitálnom prevodníku

Prevodníky integrované priamo s inerciálnymi jednotkami sa vyhotovujú v rozlíšeníach 12, 16 alebo 20 bitov. Umožňujú tak pripojiť akcelerometer rovno na sérové zbernice *SPI* alebo *I2C*. Všeobecne platí, že pri n bitoch je k dispozícii 2^n rozličných čísel. Kódovaním v dvojkovom doplnku pre zachytenie záporných hodnôt sa uvažuje s intervalom $[-2^{\frac{n}{2}}; 2^{\frac{n}{2}} - 1]$. Napríklad pri 12-bitovom A/D prevodníku s referenčným napätím $3.3V$ je teoreticky najmenšia rozlíšiteľná zmena na najmenej významový bit $3.3V/2^{12} = 0.81mV$. Ak je rozhranie senzora priamo vybavené analógovým výstupom nič nebráni v použití presnejšieho prevodníka, napriek tomu najmenší merateľný dielik je zdola stále ohraničený citlivosťou akcelerometra.

Číslcovú hodnotu v dvojkovom doplnku získanú konverziou \hat{x} je z dôvodu širšej zrozumiteľnosti žiaduce prepočítať na štandardné fyzikálne jednotky pre zrýchlenie, a v m/s^2). R predstavuje nastavený dynamický rozsah v jednotkách g a n je počet bitov A/D prevodníka.

$$a = \hat{x} \cdot \frac{R \cdot g}{2^{\frac{n}{2}}} \quad (2.5)$$

Ako bolo spomenuté ohľadom vlastností MEMS akcelerometrov, presnejší prevod

dosiahneme zužitkovaním deklarovanej citlivosti senzora pri danom dynamickom rozsahu S_R udávaného v mg/LSB .

$$a = \hat{x} \cdot \frac{S_R \cdot g}{1000} \quad (2.6)$$

Vlastnosti bežných akcelerometrov

Na ilustráciu uvádzame parametre zvolených najrozšírenejších typov akcelerometrov. Akcelerometer LSM9DS1 [4] umožňuje cez zbernicu SPI alebo I2C zvoliť zo štyroch dynamických rozsahov, pričom každé rozpätie sa vyznačuje svojou citlivosťou. Zvolením menšieho dynamického rozsahu zvýšime citlivosť. LSM9DS1 funguje pri rozsahoch $\pm 2g$, $\pm 4g$ a $\pm 8g$ a $\pm 16g$, postupne s citlivosťami 0.061 mg/LSB , 0.122 mg/LSB , 0.244 mg/LSB , 0.732 mg/LSB . Výstupný dátový tok (ODR) je možné nastaviť na 10Hz , 50Hz , 119Hz , 238Hz , 476Hz a najvyššie na 952 Hz . Navzorkované hodnoty sú ukladané do 16-bitového výstupného registra v dvojkovom doplnku.

Nízkoenergetický 3DOF MEMS akcelerometer ADXL362 [5] so spotrebou $2 \mu A$ pri 100Hz disponuje rozsahmi $\pm 2g$, $\pm 4g$ a $\pm 8g$ s citlivosťami 1 , 2 a 4 mg/LSB . Dostupné vzorkovacie frekvencie 12-bitového A/D prevodníka sú $12.5 - 400\text{Hz}$ v 8 krokoch vždy po násobkoch predošlého kroku. Pre rýchlejšie čítanie pri nižšom rozlíšení dokáže senzor zakódovať dáta do 8-bitového registra.

Vyrábajú sa tiež akcelerometre s väčšími dynamickými rozsahmi a nízkym šumom, ide napríklad o ADXL356 a ADXL357 [6] so škálami $\pm 10g$, $\pm 20g$ a $\pm 40g$ s citlivosťou $0,019 \text{ mg/LSB}$ po $0,078 \text{ mg/LSB}$ a rozlíšením A/D prevodníka 20 bitov pri ODR $4 - 4000\text{Hz}$. ADXL357 ponúka priamo analógové výstupy s citlivosťou $20 - 80 \text{ mV/g}$ pri napájaní 3.3 V .

2.1.2 Odvodzovanie rýchlosti a dráhy zo zrýchlenia

Meranie akcelerácie umožňuje zároveň nepriamo získať ďalšie údaje o pohybe celkovom v priestore ako aj spôsobenom vibráciami. Zrýchlenie \vec{a} je definované ako časová zmena rýchlosti \vec{v} , zatiaľčo rýchlosť je časovou zmenou polohy \vec{r} . Na pozorovanie prechodových javov alebo na vyjadrenie miery plynulosti pohybu slúži ryv \vec{j} , ktorý je časovou zmenou akcelerácie. Pokiaľ nie sú známe počiatkové podmienky v okamihu začiatku snímania akcelerácie, budú hodnoty veličín relatívne vzhľadom na štart

záznamu. Kinematika v diskretnom čase je potom opísaná nasledujúci rovnicami, kde Δ je operátor diferencie $\Delta t = t(i) - t(i-1)$

$$\vec{v} = \frac{\Delta \vec{r}}{\Delta t}; \quad \vec{a} = \frac{\Delta \vec{v}}{\Delta t}; \quad \vec{j} = \frac{\Delta \vec{a}}{\Delta t} \quad (2.7)$$

Vyjadrenie neznámych premenných vzhľadom na akceleráciu spočíva v prenásobení rovníc členom Δt , čím sa získajú vzťahy pre okamžitú dráhu a okamžitú rýchlosť. Spočítaním čiastkových okamžitých rýchlostí na intervale dostaneme celkovú rýchlosť a rovnaký úsudok platí pre polohu. V spojitom čase, keď by vzorkovacia perióda bola nekonečne krátka, dochádza naproti tomu k integrovaniu funkcie akcelerácie. Dostávame, že rýchlosť je integrálom zrýchlenia a poloha je dvojným integrálom zrýchlenia:

$$\vec{v}(t) = \vec{a}_0 + \int \vec{a}(t) dt \quad (2.8)$$

$$\vec{r}(t) = \vec{r}_0 + \vec{v}_0 t + \iint \vec{a}(t) dt \quad (2.9)$$

Približný výpočet určitého integrálu funkcie akcelerácie je založený na geometrickej interpretácii integrálu ako plochy pod krivkou. Hovoríme vtedy o probléme numerickej kvadratúry, ktorý navrhuje nahradiť pôvodný integrand Lagrangovým interpolačným polynómom l_i [7]. Rád polynómu n implicitne stanoví priebeh funkcie medzi ekvidistantnými vzorkami a má dopad na presnosť aproximácie. Najčastejšie sa používajú konštantný $n = 0$, lineárny $n = 1$ alebo kvadratický $n = 2$ polynóm. Použitie vyššieho rádu však vo všeobecnosti nezaručuje podľa *Rungeho javu* menšiu chybu a môže viesť k nezmyselným výsledkom kvôli výskytu oscilácií polynómu na okrajoch intervalu. Predpis pre odhad akcelerácie o n vzorkách so vzorkovacou periódou T_s polynómom stupňa l_i vychádza zo zložených *Newton-Cortesových vzorcov*.


$$\int_a^b a(t) dt \approx T_s \cdot \sum_{i=0}^n a(t_i) \cdot \int_a^b l_i(t) dt \quad (2.10)$$

Pri *obdĺžnikovom pravidle* nepripúšťame zmenu hodnoty zrýchlenia medzi vzorkami a okamžitú rýchlosť, čiže plochu, odhadneme ako dĺžku intervalu vzorkovania vynásobenú priemerom výšok dvoch následných pozorovaní. Interpolačný polynóm je konštantná funkcia. *Lichobežníkové pravidlo* uvažuje s lineárnou zmenou veli-

činy medzi meraniami, preto interpoluje priamkou. *Simpsonovo pravidlo* sa snaží o ešte tesnejší odhad s využitím kvadratickej funkcie. Každé kvadrátúrne pravidlo sa síce vyznačuje presne vyčísliteľnou chybovosťou, ale k tomu je nevyhnutné poznať analytické vyjadrenie vibrácií, čo dáva realistický odhad len pri čisto periodických kmitoch.

Pravidlo	Vzorec
Obdĺžnikové	$T_s \cdot a\left(\frac{t_i+t_{i-1}}{2}\right)$
Lichobežníkové	$\frac{T_s}{2} \cdot [a(t_i) + a(t_{i-1})]$
Simpsonovo	$\frac{T_s}{3} \cdot [a(t_{2i}) + 4a(t_{2i-1}) + a(t_{2i-2})]$

Tabuľka 2.1: Odhad rýchlosti zo vzorkovaného zrýchlenia cez kvadrátúrne pravidlá



Obr. 2.4: Porovnanie pravidiel numerickej integrácie

Priama integrácia zašumeného signálu zrýchlenia vedie k neskutočnému driftu, ktorý je ešte zvýraznený dvojistou integráciou pri odvodzovaní relatívneho posunutia. Dochádza k zosilneniu nízkych a potlačeniu vyšších frekvencií, čím sa začne dominovať neexistujúci trend vo výstupných dátach. Očakávané oscilujúce správanie vychýlenia u vibrácií so zväčšujúcim sa počtom sčítancov pri rekurentnom výpočte zaniká. Na zlepšenie stability integrátora sa uplatňuje korekcia cez obálky [8].

Najprv je na vstupnom signále vykonaná zvoleným pravidlom numerická kvadratura, ktorá môže byť realizovaná na krátkych úsekoch funkcie, aby sa predišlo pretečeniu pri výraznej akumulácii odklonu. Prichádza k identifikácii lokálnych extrémov, či už maxím, respektíve miním (pozri 2.2.2) a ich interpoláciou s kubickou B-spline sa sformuje horná $e_u(t)$, respektíve dolná obálka signálu $e_d(t)$. Obálky sú spriemerované $\bar{e}(t)$, čím vznikne odhad trendovej krivky, ktorá je od už integrovaného

signálu odčítaná $g(t) = f(t) - \bar{e}(t)$. V prípade výpočtu polohy je možné aplikovať uvedený postup kaskádovito, čiže rovnako ako akcelerácia je aj signál rýchlosti opäť integrovaný a korigovaný obálkami. Trend je rovnako tak odstrániteľný filtrom na potlačenie prítomnosti jednosmernej zložky v podobe hornej priepuste (pozri 2.3.4).

2.2 Metódy analýzy signálu v časovej doméne

Pozorovania veličiny predstavujú udalosti merané sekvenčne v čase, kde je s každou obdržanou hodnotou x_i viazaná unikátna časová značka t_i . Postupnosť jednotlivých čítaní je jednorozmerný časový rad znázoriteľný ako usporiadaná množina dvojíc pečiatky rastúcej v čase a nasnímanej úrovne: $T = \{(t_1, x_1), (t_2, x_2), \dots, (t_n, x_n)\}$. Vzorkovaním v pravidelných intervaloch stačí uvažovať namiesto časových značiek o celočíselných indexoch, ktoré určujú pozíciu prvkov vo vektore pozorovaní: $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$. Keď sú súčasne zaznamenávané viaceré dátové body hovoríme o matici pozorovaní $X_{n,m}$, či o viacrozmernom časovom rade.

Pri veľkom objeme prichádzajúcich vzoriek produkované senzormi, nie je uskutočniteľné ich úplné uchovanie ani spracovanie celkého dátového toku naraz. Často-krát by stratégia neuváženeho odkladania viedla k plýtvaniu zdrojov a zbytočnému archivovaniu údajov s nízkou informačnou hodnotou. Vhodnejšie je agregovanie toku údajov podľa preddefinovaného zmysluplného kritéria, ktoré by umožňovalo zachytiť významné rysy a prompte zodpovedať na vyžadované dopyty. Napríklad zrýchlenie vozidla v konkrétnom okamihu nebude až tak podstatné v porovnaní so znalosťou trvania úsekov pridávania alebo brzdenia, či priemernej prudkosti s akou tieto aktivity boli činené.

Prúdové algoritmy

Priamočiarou realizáciou agregácie je nahliadať na prvky časového radu postupne ako prichádzajú. Prúdové algoritmy pôsobiace v reálnom čase, a teda neschopné vidieť finálny vektor vzoriek vstupu sa vyznačujú vlastnosťou, že vyprodukujú len na základe takého čiastkového vstupu parciálny výsledok platný pre dosiaľ sa vyskytnutú podmnožinu. Online algoritmus spracúvajúci neprestajný potenciálne nekonečne sa rozširujúcu vstupnú sadu sa ideálne vyznačuje sublineárnou alebo po-

lylogaritmickeou časovou zložitostou spracovanie jednotlivých prvkov, celkové spracovanie, a sú žiaduce sublineárne pamäťové nároky [9]. Nie za každej situácie sú však dané nároky z praktických dôvodov naplniteľné, snaha je sa k nim aspoň čo najlepšie priblížiť.

Bod x_i , ktorý je súčasťou prúdu sa pri online agregácii zaráta do každého relevantného počítadla, a môže byť ihneď zabudnutý, čo sa označuje ako turniketový, prípadne pokladňový, model. Turniket je všeobecnejší formalizmus ako pokladňa, pretože umožňuje prvky z počítadla aj odrátavať [9]. Tak namiesto nevýznačného poznatku, že aktuálne vstúpil nový zákazník bude rovno známe, koľko je vnútri zákazníkov dohromady. Z ilustrácie nevyplýva, ktorý fakt je za daných okolností podstatnejší, ale individuálny alarm pri vstupe je hneď vykonaný a nepotrebuje byť spočítaný.

Posuvné a rozširujúce sa okná

Časový rad $(x_i)_{i=0}^n$ s dĺžkou n môže byť pre účely výpočtu sumárnych štatistík rozdelený oknovou funkciou $\mathcal{W}_{l,d}$ na podpostupnosti nazývané okná. Posuvné okná („rolling window“) majú spravidla konštantnú dĺžku l menšiu ako celkovú veľkosť radu a sú aplikované s krokom odstupe d pozorovaní. Rad potom pozostáva z $(n-(l-1))/d$ okien [10]. Prirodzene sa posuvné okná objavujú pri manipulácii s vyrovnávacou pamäťou, ktoré sa využívajú pri blokovom prenose z adaptéra senzora do hlavnej pamäte. Vtedy sa veľkosť bloku rovná kroku posunu $l = d$.

Rozširujúce sa okná („expanding window“) nachádzajú uplatnenie v menej prípadoch, spravidla sa jedná o inkrementálny odhad globálnej štatistiky, ktorá má zmysel prevažne pri sledovaní stabilného javu. [11]. Okno začína na stanovenej minimálnej veľkosti a s pribúdajúcim počtom bodov ich zahŕňa, čím sa zväčšuje. Dostavuje sa rovnaký výsledok ako v turniketovom modeli, ale navyše neplatí obmedzenie zahadzovania už započítaných údajov, ale dokážeme teoreticky operovať so všetkými vzorkami vrámci okna.

2.2.1 Číselné charakteristiky štatistického rozdelenia

Náhodné vibrácie vyskytujúce sa pri skutočných materiáloch sú stochastický proces, ktorý tvorí sekvencia časovo indexovaných náhodných premenných. Časový rad

predstavuje realizáciu tohto stochastického procesu $\mathbf{Y} = (X_1, X_2, \dots, X_n)^T$, kde X_t je náhodná premenná so svojím rozdelením pravdepodobnosti. Všeobecne zvykneme predpokladať pri ideálnych stacionárnych otrasoch, teda oscilujúcich okolo nemalej strednej hodnoty, že premenné pochádzajú z unimodálnej Gaussovej distribúcie $N(\mu, \sigma^2)$ [1].

Sumárna deskripcia senzorom meraného deja pre extrakciu typických črt konkrétnych situácií sa uskutočňuje viacerými štatistikami $h_n(X_1, X_2, \dots, X_n)$ odhadujúcimi funkciu hustoty štatistického rozdelenia. Rozlišujeme momentové a kvantilové charakteristiky.

bodové odhady momentov, priemer, medián, modus

Peak-to-peak

$$x_{PK} = \max_{x \in T} \{x_1, \dots, x_n\} - \min_{x \in T} \{x_1, \dots, x_n\}$$

kvadratický priemer - RMS (efektívna hodnota)

$$x_{RMS} = \sqrt{\frac{1}{n} \sum_{i=0}^n x_i^2}$$

výberový priemer = stredná hodnota = jednosmerná zložka

$$\bar{x} = \frac{1}{n} \sum_{t=0}^n x_t$$

výberový rozptyl, smerodajná odchýlka

$$\sigma^2 = \frac{1}{n-1} \sum_{t=0}^n (x_t - \bar{x})^2$$

$$\sigma = \sqrt{x_{RMS}^2 - \bar{x}^2}$$

(numerická nestabilita) Welfordov online algoritmus [12]:

$$M_1 = x_1; M_k = M_{k-1} + \frac{(x_k - M_{k-1})}{k} \quad (2.11)$$

$$S_1 = 0; S_k = S_{k-1} + (x_k - M_{k-1})(x_k - M_k) \quad (2.12)$$

$$\sigma = \sqrt{S_n / (n-1)} \quad (2.13)$$

šikmost' - záporné skosenie ľavý chvost distribúcie je dlhší a vrchol napravo m^3/s^3
 špicatost' - štvrtý moment m^4/s^4
 kvantily - kumulatívna distribučná funkcia

$$P(X \leq Q_p) = p; F(Q_p) = p$$

medzikvartilové rozpätie

$$IQR = F(0.75) - F(0.25)$$

korelácia medzi osami - všetky kombinácie osí - pohyb sa prejavuje v diagonálnom smere $3C^2 = 3XY, XZ, YZ$ kovariančná / korelačná matica

$$cov(x, y) = \frac{1}{n} \sum_{i=0}^n (x_i - \bar{x})(y_i - \bar{y})$$

$$\rho(x, y) = \frac{cov(x, y)}{s_x s_y}$$

vierohodnosť - odhad parametrov rozdelenia, ktorá je najpravdepodobnejšia na základe (nadobúda) na základe experimentálnych dát Median Absolute Deviate (robustná štatistika na určenie vychýlenosti od normálu) - triedenie vs quickselect + median-of-medians v $O(n)$

$$MAD = \text{median}(|X_i - \bar{X}|) \quad (2.14)$$

2.2.2 Algoritmy na rozpoznávanie špičiek

lokálne minimá a maximá extrémny - cez prvú a druhú deriváciu, [13] $x_0 \in I$ lokálne maximum $f(x_0) \geq f(x), \forall x \in I$ lokálne minimum $f(x_0) \leq f(x), \forall x \in I$ globálne ak interval predstavuje celý definičný obor funkcie

topografická prominencia a izolácia - relatívna výška vrchola / extrém

vyhladzovanie: mean filter, derivative filter (diskrétny derivačný operátor) - sobel filter, Savitzky-Golay filter [14]

Vzájomná korelácia - jadra vrchola a signálu detect peaks in a signal and to measure their positions, heights, widths, and/or areas

Detekcia prahom pri periodických javoch

Nad + pod konštantný prah $y < t$, $y > t$

$$y = \max x_0, x_1, x_2, x_3$$

$$x > \hat{x}$$

má väčšiu šancu byť maximom ako pod priemerom Napr. 75% rozsahu: $t = \frac{\frac{u+d}{2}+u}{2}$

Význačnosť vrchola spomedzi susedov

Preskočí špičky s absolútnou magnitúdou menšou ako `height`. Vo vnútornom cykle zisťuje či je bod vyššie ako všetkých ‘k’ susedov doprava a doľava s toleranciou `epsilon`.

$$\forall c \in \{y_{i-k}, \dots, y_{i+k}\} - \{y_i\}; y_i - c \geq -\epsilon \quad (2.15)$$

[13] $x_{i-1} < x_i > x_{i+1}, \forall i = 2, 3, \dots, n-1$ $x_1 > x_2, x_n > x_{n-1}$

<https://terpconnect.umd.edu/~toh/spectrum/PeakFindingandMeasurement.htm>

Algoritmus 1 Najvyšší spomedzi susedov

```
1: function FIND_PEAKE( $\vec{y}$ ,  $k$ ,  $\epsilon$ ,  $h$ )
2:    $peaks \leftarrow \{\}$  ▷ Množina indexov nájdených špičiek v signále  $y$ 
3:   for  $i \leftarrow k$  to  $length(y) - k$  do
4:     if  $h \neq null$  and  $|y[i]| < h$  then ▷ Ignoruj príliš nízke magnitúdy
5:       continue
6:     end if
7:      $possible\_peak \leftarrow true$ 
8:     for  $j \leftarrow -k$  to  $k$  do
9:       if  $b \neq 0$  and  $y[i+j] - y[i] > \epsilon$  then
10:         $possible\_peak \leftarrow false$  ▷ Vrchol nemá postačujúcu prominenciu
11:      end if
12:    end for
13:    if  $possible\_peak = true$  then
14:       $peaks \leftarrow peaks \cup j$ 
15:    end if
16:  end for
17:  return  $peaks$ 
18: end function
```

Algoritmus prechodu nulou do záporu

Nájdí vo n -krát vyhladenom signále body, že platí: $f'(x) = 0$, kde $f''(x) < 0$ a $|f''(x)| > \theta$. Pre odstránenie hraničných efektov použiť mód 'valid' s príslušným posunom hraníc polí.

Diskrétna verzia:

$$f'(x) = 0 \text{ (Dotynica)} \implies |y_{i+k} - y_{i-k}| \leq \epsilon \text{ (Senica)}$$

$$f''(x) < 0 \implies (y_{i+k} - y_i) - (y_i - y_{i-k}) < 0$$

$$|f''(x)| > \theta \implies |(y_{i+k} - y_i) - (y_i - y_{i-k})| > \theta$$

Parametre:

- ϵ : tolerancia pre nulovú deriváciu
- θ : strmosť druhej derivácie, čiže špicatosť vrchola
- k : polovica dĺžka sečnice pre výpočet prvej derivácie
- n : veľkosť konvolučného jadra
- *smooth*: počet vyhladzovaní

Algoritmus 2 Prechod druhej derivácie nulou do záporu

```
1: function FIND_PEAKS_ZERO_CROSSING( $\vec{y}$ ,  $k$ ,  $\epsilon$ ,  $slope$ )
2:    $peaks \leftarrow \{\}$ 
3:   for  $i \leftarrow k$  to  $length(y) - k$  do
4:     if  $(|y[i+k] - y[i-k]| \leq \epsilon)$  and
5:        $(y[i+k] - y[i]) - (y[i] - y[i-k]) < 0$  and
6:        $|(y[i+k] - y[i]) - (y[i] - y[i-k])| > slope$  then
7:          $peaks \leftarrow peaks \cup i$ 
8:       end if
9:   end for
10:  return  $peaks$ 
11: end function
```

Algoritmus horského turistu

Obsahuje pamäťový efekt pre dočasné zmeny a berie ich do úvahy ak lokálne záchvevy prekročia tolerovanú úroveň. Ak sa zmení 'slope' oproti predošlému kroku Del-

taY, tak hneď neoznačí za zmenu medzi dolinou a vrcholom, ale až po prekročení nastavených prahov. Skutočnosť z reality: jama != údolie [15]

Automatický viacúrovňový detektor špičiek v kvázi-periodickom signále

[16] Uniformne vzorkovaný signál pozostávajúci z komponentu periodických a kvázi-periodických špičiek 1.krok: zo vstupu $x = [x_1, \dots, x_N]$ odstrániť trend a vypočítať local maxima scalogram (LMS). Lokálne maximá signálu sú určené posuvnými oknami s premenlivou veľkosťou okna k $w_k = 2k | k = 1, 2, \dots, \lceil N/2 \rceil - 1$ 2. krok riadkový súčet LMS matice 3. krok preškálovanie matice 4.krok stĺpcová smerodajná odchýlka upravenej matice, špička je pri nulovej sigme.

Algoritmus 3 Horský turista

```
1: function FIND_PEAKS_MOUNTAINEER( $\vec{y}$ )
2:    $peaks \leftarrow \{\}$  ▷ Množina nájdených vrcholov v signále  $y$ 
3:    $valleys \leftarrow \{\}$  ▷ Množina nájdených údolí v signále  $y$ 
4:    $num\_steps \leftarrow 0$ 
5:    $threshold \leftarrow 6$ 
6:    $possible\_peak \leftarrow false$ 
7:    $possible\_valley \leftarrow false$ 
8:   for  $i \leftarrow 1$  to  $length(y)$  do
9:     if  $y[i] > y[i - 1]$  then
10:       $num\_upsteps \leftarrow num\_upsteps + 1$ 
11:      if  $possible\_valley = false$  then
12:         $possible\_valley \leftarrow true$  ▷ Objavenie možného údolia
13:         $y\_valley \leftarrow (i - 1, y[i - 1])$ 
14:      end if
15:    else
16:      if  $num\_upsteps \geq threshold$  then
17:         $possible\_peak \leftarrow true$  ▷ Objavenie možného vrchola
18:         $y\_peak \leftarrow (i - 1, y[i - 1])$ 
19:      else
20:        if  $possible\_valley = true$  and  $y[i] \leq y\_valley$  then
21:           $y\_valley \leftarrow (i, y[i])$ 
22:        end if
23:        if  $possible\_peak = true$  then
24:          if  $y[i - 1] > y\_peak$  then
25:             $y\_peak \leftarrow (i - 1, y[i - 1])$ 
26:          else
27:             $peaks \leftarrow peaks \cup y\_peak$ 
28:          end if
29:          if  $possible\_valley = true$  then
30:             $valleys \leftarrow valleys \cup y\_valley$ 
31:          end if
32:           $threshold \leftarrow 0.6 \cdot threshold$ 
33:           $possible\_peak \leftarrow false$ 
34:        end if
35:      end if
36:       $num\_upsteps \leftarrow 0$ 
37:    end if
38:  end for
39:  return  $peaks$ 
40: end function
```

Algoritmus 4 Zjednodušený algoritmus horského turistu so zavedením tolerancií

```
1: function FIND_PEAKS_HILL_WALKER( $\vec{y}$ , tolerance, hole, prominence)
2:   peaks  $\leftarrow \{\}$ 
3:   i_change  $\leftarrow 0$ 
4:   y_valley  $\leftarrow 0$ 
5:   possible_change  $\leftarrow \text{false}$ 
6:   uphill  $\leftarrow (y[1] - y[0]) \geq 0$ 
7:   for i  $\leftarrow 1$  to length(y) do
8:     y_step  $\leftarrow y[i] - y[i - 1]$ 
9:     slope  $\leftarrow y\_step \geq 0$ 
10:    if possible_change = false and uphill  $\neq$  slope then
11:      possible_change  $\leftarrow \text{true}$   $\triangleright$  Označenie potenciálneho extrému
12:      i_change  $\leftarrow i - 1$ 
13:    else if possible_change = true and uphill = slope then
14:      possible_change  $\leftarrow \text{false}$   $\triangleright$  Potenciálny extrém bol zachvením
15:    end if
16:    if (possible_change = true
17:      and uphill  $\neq$  slope
18:      and  $|i - i\_change| > \text{hole}$ 
19:      and  $|y[i] - y[i\_change]| > \text{tolerance}$ ) then
20:      possible_change  $\leftarrow \text{False}$ 
21:      prev_uphill  $\leftarrow \text{uphill}$ 
22:      uphill  $\leftarrow \text{slope}$   $\triangleright$  Významný lokálny extrém potvrdený
23:      if prev_uphill = false and uphill = true then
24:        y_valley  $\leftarrow y[i\_change]$   $\triangleright$  Nájdené údolie
25:      else if (prev_uphill = true
26:        and uphill = false
27:        and  $|y[i - \text{hole}] - y\_valley| > \text{prominence}$ ) then
28:        y_peak  $\leftarrow y[i\_change]$   $\triangleright$  Skutočný vrchol identifikovaný
29:        peaks  $\leftarrow \text{peaks} \cup i\_change$ 
30:      end if
31:    end if
32:  end for
33:  return peaks
34: end function
```

2.2.3 Online detekcia anomálií a odchýliek pozorovaní

[17] [18], Outlier je pozorovanie, ktoré sa odchyľuje, tak významne od ostatných pozorovaní, že vzbudzuje podozrenie, že bolo vytvorené odlišným mechanizmom. Normálne dáta, Šum, Anomálie (slabé a silné odchýlky) Výstupy algoritmov na detekciu výchyliiek:

- Outlier skóre - miera vychýlenosti bodu
- Binárne štítky - binárne štítky, označenie, či je bod anomália alebo nie.

Algoritmy na anomálie vytvárajú model normálnych vzorov v dátach a skóre vychýlenosti je dané deviáciou od týchto vzorov. [19] Hampel filter

[20] Množstvo prenášaných a spracovaných dát prevyšuje ľudskú schopnosť manuálneho prieskumu. Anomália je pozorovanie alebo postupnosť pozorovaní, ktoré sa významne odchyľuje od distribúcie zvyšku dát.

- Bodové anomálie - x_t je bodová anomália ak sa jeho hodnota významne odlišuje od všetkých bodov v intervale $[x_{t-k}; x_{t+k}]$
- Kolektívne (disonanancie) - jednotlivé body nepredstavujú anomálne správanie, až ak vezmeme dlhšiu postupnosť môže byť označená za anomáliu.
- Kontextové výchyľky / anomálie - body sú normálne v určitom kontexte, ale v inom anomálne.

[21] [22]

$$|x - \hat{x}| \geq \theta \tag{2.16}$$

Bežiaci filter [23]

Metriky pre binárny klasifikátor

Skóre anomálnosti, binárny klasifikátor, Falošne pozívny - proces je normálny, ale registrujeme neočakávané správanie, Falošne negatívny - proces je abnormálny, ale správanie prechádza bez povšimnutia Matica zámen, Precision, Recall, ROC - kvalita binárneho klasifikátora v závislosti od prahu, AUC [24]

Z-score a Z-test:

$$z = \frac{|x - \mu|}{\sigma} \approx \frac{|x - \bar{x}|}{S} \quad (2.17)$$

Bežiaci priemerovací filter [23]

Zisťovanie výchyliiek testovaním štatistických hypotéz: generalized extreme Studentized deviate test [17]

2.3 Frekvenčná a časovo-frekvenčná analýza signálu

[25] vlastnosti frekvenčného spektra, decibele, spektrogram, odstup od šumu (SNR), power spectrum density (dbFS), spektrálny analyzátor

2.3.1 Fourierová transformácia

Diskrétna fourierová transformácia mapuje signál dĺžky N do množiny N diskretných frekvenčných komponentov. [26]

$$X = \mathbf{W}x; W_{nk} = e^{-i\frac{2\pi}{N}nk} = W_N^{nk} \quad (2.18)$$

Inverzná transformácia

$$x = \frac{1}{N} \mathbf{W}^H X \quad (2.19)$$

Integrálne transformácie: Fourierová transformácia (CFT, DFT), Kosínusová transformácia (MDCT), Vlnková transformácia (CWT) [27] [28]

$$T(n) = \int f(t)K(t, x)dt \quad (2.20)$$

$$\mathcal{F} : X(\omega) = \int_{-\infty}^{+\infty} x(t) \cdot e^{-i\omega t} dt \quad (2.21)$$

2.3.2 Algoritmus FFT pre DFT a DCT

Opis DIT radix-2 FFT algoritmus komplexných, reálny, pre MDCT [29]

$$X(m) = \sum_{n=0}^{N-1} x(n) \cdot e^{-i2\pi nm/N} \quad (2.22)$$

Frekvenčné rozlíšenie

$$\Delta f = \frac{f_s}{N} \quad (2.23)$$

2.3.3 Oknové funkcie

Gaborová transformácia, Prehľad okien a ich transformácií (sinc), Efekt oknových funkcií na spectral leakage, výhodné percentá prekryvu FT [30] [31] Priemerovanie a prekryv - Amplitude Flatness (AF), Power Flatness (PF), Overlap Correlation (OC)

2.3.4 Filtre s konečnou impulznou odozvou

Roziel medzi FIR a IIR, Dolná pripusť, pásmová priepusť, horná pripusť, Konvolúcia a konvolučné jadro, konvolučná veta, účel: identifikácia prítomnosti známej frekvencie v signále akcelerácie

$$y(n) = \sum_{k=0}^{D_y} x(k) \cdot h(n-k) = x(n) * h(n) \quad (2.24)$$

Prenosová funkcia

$$H(\Omega) = \frac{Y(\Omega)}{X(\Omega)} \quad (2.25)$$

Detektor obálok

2 3

2.4 Senzorová sieť

Nízko-energetické zariadenia komunikujúce cez odľahčené sieťové protokoly so snahou spracovania v reálnom čase a ponechaním najdôležitejších informácií dolovaním

²<https://www.mathworks.com/help/dsp/ug/envelope-detection.html>

³<https://www.dsprelated.com/showarticle/938.php>

z veľkého množstva zdrojových dát. Cloud / Fog computing. Sink a Edge nodes

Vlastnosti senzorovej siete

- Autokonfigurácia senzora - reakcia na zmeny v sieti a prostredia pôsobenia
- Škálovateľnosť - veľké množstvo senzorov so spoločným účelom a schopnosťou vzájomnej kooperácie a interoperability.
- Odolnosť voči chybám - v prípade pridania alebo odobratia uzla budú spojenia bez prerušenia.
- Energeticky efektívna komunikácia uzlov - s upravenými protokolmi štandardného sieťového zásobníka
 - Event-driven - stály zber dát a reakcia na náhle zmeny. posielajú údaje až po prekročení kritického prahu
 - Query-driven - zbierajú údaje iba po prijatí dopytu od používateľa
 - Time-driven - pravidelne odosielať údaje sinku. vzorkovaciu frekvenciu volí sink

[32]

Spracovanie toku informácií (IFP - Information flow processing) - nástroj na včasné spracovanie dát ako tečie z periférií do centra systému. Snahou je ukladanie agregovaných štatistík, napr. detektor požiaru za použitia čidiel teploty a dymu nepotrebuje ukladať jednotlivé merania, lebo sú samo o sebe nepodstatné. Keď nastane varovná situácia, je potrebné aby tá obsahoval všetky údaje na lokalizáciu ohniska.

CEP - Complex event processing - spracúva toky udalosti zo zdrojov reálneho sveta na základe aplikovania aktívnych pravidiel stanovených správcami systému a poupraví toky do komplexnejšieho výstupu. Pravidlá sú v tvare Event-Condition-Action (ECA).

- Udalosť - definuje zdroje ako generátory udalostí
- Podmienka - uvažuje ktorá časť udalosti bude braná do úvahy pri spracovaní, napr. môže ísť o prekročenie prahu
- Akcia - aká sada úloh má byť vykonaná pri detekcii udalosti

Behové pravidlá sú spracúvané vo viacerých fázach

- Signalizácia - detekcia udalosti
- Spustenie - asociácia udalosti so sadou pravidiel
- Vyhodnotenie - vyhodnotenie podmienky
- Plánovanie - stanovenie poradia vykonania
- Vykonanie - vykonanie pravidiel

[33]

2.4.1 Senzorová jednotka

Súčasti sensorovej jednotky:

- Zberná jednotka
- Výpočtová jednotka
- Komunikačná jednotka
- Napájacia jednotka

Obmedzenia na sensorové uzly

- Spotreba energie - energetická autonómia uzlov vo WSN umožňuje nasadzovanie zariadení do odľahlých miest pre využitie v inteligentných mestách alebo na účely ochrany prírody. životnosť sensorovej jednotky je ohraničená kapacitou batérie.
- Dosah komunikácie - Sensory disponujú obmedzenou energiou na vysielanie a dosah je negatívne ovplyvnený silou signálu na anténe. Z toho vyplývajú aj nižšie prenosové rýchlosti.
- Výpočtový výkon a úložisko - Nízka taktovacia frekvencia procesora v megahercoch a veľkosti pracovných pamätí v stovkách kilobajoch alebo megabajtoch.

[34]

Za ideálnych okolností by sa mal online algoritmus učiť kontinuálne bez uklada-
nia predošlých bodov a detekcií. V rozhodnutiach algoritmu sú zahrnuté informácie
o všetkých predošlých bodoch do terajšieho rozhodnutia. Mal by mať schopnosť sa
adaptovať dynamickému prostrediu, v ktorom pôsobí. Bez nutnosti manuálnych úp-
rav parametrov modelu. Zároveň je žiaduce minimalizovať falošné pozitíva a negatíva
pri detekcii udalostí.

3 Opis riešenia

Požiadavky

- Najvhodnejší spôsob identifikácie lokálnych extrémov - špičiek
- Možnosti redukcie zberu dát za cenu redukcie energetické nároky a prenosu významných črt signálu
- Pravidlový systém na definíciu udalostí záujmu operátorov a ich spoľahlivá identifikácia
- Upozornenie na nezvyčajnosti pri prevoze (detekciou anomálií) - veľká nerovnosť, neočakávaný pohyb

Senzorová jednotka s akcelerometrom na meranie vibrácií a nárazov pri prevoze krehkých látok/materiálov upozorňujúca na základe konfigurovateľných pravidiel alebo nezvyčajných vzorov (pozn.:lepšie dodefinovať). Preskúmanie možností redukcie zberu alebo nasnímaných údajov - nastavenie vzorkovacej frekvencie / akceptovanie nad stanovenú amplitúdu / kompresia. Rozšírenie: /distribuovaná/ korelácia údajov z viacerých akcelometrov z jedného balíka / vozidla.

3.1 Hardvér senzorovej jednotky

3.2 Vývojové prostredie a knižnice

CMSIS, MDK5, OPENOCD, GCC

3.3 Koordinácia subsystémov

3.4 Konzervácia energie znížením vzorkovania

3.5 Pravidlový systém na extrahovanie črt záujmu

Táto časť bakalárskeho projektu obsahuje opis výsledkov riešenia jednotlivých etáp projektu. V prípade, že záverečný projekt nerieši všetky etapy, malo by byť v príslušnej časti uvedené kto, resp. kde sa príslušná etapa rieši/riešila/bude riešiť.

Typické etapy riešenia pri tvorbe softvérového systému:

- špecifikácia požiadaviek
- návrh
- implementácia (ak to zadanie požaduje)
- overenie riešenia

Podľa možnosti treba vychádzať zo známych prístupov (napr. pri softvérových projektoch štruktúrovaný alebo objektovo orientovaný prístup) a techník (napr. blokové schémy, vývojové diagramy, UML, entito-relačné diagramy atď.). Táto časť práce závisí od konkrétneho zadania. Je dôležité prezentovať návrhové rozhodnutia, alternatívy, ktoré sa zvažovali pri riešení a samotný návrh riešenia zadaného problému. Štruktúrovanie textu tejto časti BP by malo vychádzať zo zadanej úlohy, ktorá sa rieši. Najmä v tejto časti študent preukazuje tvorivý prístup k riešeniu problémov a kritické myslenie.

4 Zhodnotenie

Hlavné výsledky práce, prípadne porovnanie s inými prístupmi, možné smery ďalšieho rozvíjania. Tu sa musí presne špecifikovať, čo je pôvodné a čo riešiteľ prebral.

Literatúra

1. BROCH, Jens Trampe. *Mechanical Vibration and Shock Measurements*. 2. vyd. Brüel & Kjær, 1984. ISBN 87-87355-3-4-5.
2. MOHAMMED, Zakriya; ELFADEL, Ibrahim (Abe) M.; RASRAS, Mahmoud. Monolithic Multi Degree of Freedom (MDoF) Capacitive MEMS Accelerometers. *Micromachines*. 2018, roč. 9, č. 11. ISSN 2072-666X. Dostupné z DOI: 10.3390/mi9110602.
3. DADAFSHAR, Majid. *Accelerometer and Gyroscopes Sensors: Operation, Sensing, and Applications*. 2014.
4. *iNEMO inertial module: 3D accelerometer, 3D gyroscope, 3D magnetometer*. 2015. Č. LSM9DS1. Rev. 3.
5. *Micropower, 3-Axis, $\pm 2\text{ g}/\pm 4\text{ g}/\pm 8\text{ g}$ Digital Output MEMS Accelerometer*. 2019. Č. ADXL362. Rev. F.
6. *Low Noise, Low Drift, Low Power, 3-Axis MEMS Accelerometers*. 2020. Č. ADXL356. Rev. A.
7. QUARTERONI, Alfio; SACCO, Riccardo; SALERI, Fausto. Numerical Mathematics. In: Springer Inc., 2000, kap. 9. Numerical Integration, s. 371–398. ISBN 0-387-98959-5.
8. YANG, Yanli; ZHAO, Yanfei; KANG, Dali. Integration on acceleration signals by adjusting with envelopes. *Journal of Measurements in Engineering*, 2016, roč. 4, s. 117–121.
9. MUTHUKRISHNAN, S. Data Streams: Algorithms and Applications. *Foundations and Trends in Theoretical Computer Science*. 2005, roč. 1, č. 2, s. 117–236. ISSN 1551-305X. Dostupné z DOI: 10.1561/04000000002.

10. PAJUREK, Tomáš. *Online Anomaly Detection in Time-Series*. Fakulta informačních technologií, České vysoké učení technické v Praze, 2018. Dostupné též z: <https://dspace.cvut.cz/bitstream/handle/10467/76417/F8-DP-2018-Pajurek-Tomas-thesis.pdf>. Dipl. pr.
11. NIELSEN, Aileen. *Practical Time Series Analysis: Prediction with Statistics and Machine Learning*. O'Reilly Media, 2019. ISBN 978-1-492-04165-8.
12. KNUTH, Donald E. The Art of Computer Programming. In: 2. vyd. Addison-Wesley, 1981, zv. 2, kap. 4.2.2, s. 216. ISBN 0-201-03822-6.
13. SCHNEIDER, Roger. Survey of Peaks/Valleys identification in Time Series. 2011. Department of Informatics, University of Zürich.
14. YANG, Chao; HE, Zengyou; YU, Weichuan. Comparison of public peak detection algorithms for MALDI mass spectrometry data analysis. *BMC bioinformatics*. 2009, roč. 10, s. 4. Dostupné z DOI: 10.1186/1471-2105-10-4.
15. ARGÜELLO-PRADA, Erick Javier. The mountaineer's method for peak detection in photoplethysmographic signals. *Revista Facultad de Ingeniería Universidad de Antioquia*. 2019, č. 90, s. 42–50. Dostupné z DOI: 10.17533/udea.redin.n90a06.
16. SCHOLKMANN, Felix; BOSS, Jens; WOLF, Martin. An Efficient Algorithm for Automatic Peak Detection in Noisy Periodic and Quasi-Periodic Signals. *Algorithms*. 2012, roč. 5, č. 4, s. 588–603. ISSN 1999-4893. Dostupné z DOI: 10.3390/a5040588.
17. NIST/SEMATECH. *e-Handbook of Statistical Methods: Generalized ESD Test for Outliers*. 2012. Dostupné z DOI: <https://doi.org/10.18434/M32189>.
18. HOCHENBAUM, Jordan; VALLIS, Owen S.; KEJARIWAL, Arun. Automatic Anomaly Detection in the Cloud Via Statistical Learning. *CoRR*. 2017, roč. abs/1704.07706.
19. AGGARWAL, Charu C. *Outlier Analysis*. 2. vyd. Springer Publishing Company, Inc., 2016. ISBN 978-3-319-47578-3.

20. BRAEI, Mohammad; WAGNER, Sebastian. Anomaly Detection in Univariate Time-series: A Survey on the State-of-the-Art. *CoRR*. 2020, roč. abs/2004.00433. Dostupné tiež z: <https://arxiv.org/abs/2004.00433>.
21. BLÁZQUEZ-GARCÍA, Ane; CONDE, Angel; MORI, Usue; LOZANO, Jose Antonio. A review on outlier/anomaly detection in time series data. *CoRR*. 2020, roč. abs/2002.04236. Dostupné tiež z: <https://arxiv.org/abs/2002.04236>.
22. MEHROTRA, Kishan G.; MOHAN, Chilukuri K.; HUANG, HuaMing. *Anomaly Detection Principles and Algorithms*. Springer Publishing Company, Inc., 2017. ISBN 978-3-319-67524-4.
23. GIANNONI, Federico; MANCINI, M.; MARINELLI, Federico. Anomaly Detection Models for IoT Time Series Data. *ArXiv*. 2018, roč. abs/1812.00890. Dostupné tiež z: <https://arxiv.org/pdf/1812.00890.pdf>.
24. ZHANG, Yang; MERATNIA, Nirvana; HAVINGA, Paul. Outlier Detection Techniques for Wireless Sensor Networks: A Survey. *IEEE Communications Surveys Tutorials*. 2010, roč. 12, č. 2, s. 159–170. Dostupné z DOI: 10.1109/SURV.2010.021510.00088.
25. WEI, William W.S. Time Series Analysis: Univariate and Multivariate Methods. In: 2. vyd. Pearson Education, Inc., 2006, kap. 13, s. 289–318. ISBN 0-321-32216-9.
26. PRANDONI, Paolo; VETTERLI, Martin. *Signal Processing for Communications*. EPFL Press, 2008. ISBN 978-2-940222-20-9.
27. AHMED, Nasir; NATARAJAN, T; RAO, Kamisetty R. Discrete cosine transform. *IEEE transactions on Computers*. 1974, roč. 100, č. 1, s. 90–93.
28. KOVAČEV, Radovan. *Časově-frekvenční analýza signálu*. Fakulta informačních technologií, Vysoké učení technické v Brně, 2012. Dipl. pr.
29. CHU, Eleanor; GEORGE, Alan. *Inside the FFT Blackbox: Serial and Parallel Fast Fourier Transform Algorithms*. CRC Press LLC, 2000. Computational Mathematics. ISBN 0-8493-0270-6.

30. LYONS, Richard G. *Understanding Digital Signal Processing*. 3. vyd. Pearson Education, Inc., 2011. ISBN 978-0-13-702741-5.
31. HEINZEL, G.; RÜDIGER, A.; SCHILLING, R. Spectrum and spectral density estimation by the Discrete Fourier transform (DFT), including a comprehensive list of window functions and some new at-top windows. In: 2002.
32. MATIN, M.A.; ISLAM, M.M. Overview of Wireless Sensor Network. In: MATIN, Mohammad A. (ed.). *Wireless Sensor Networks*. IntechOpen, 2012, kap. 1, s. 1–22. ISBN 978-953-51-0735-4. Dostupné z DOI: 10.5772/49376.
33. CUGOLA, Gianpaolo; MARGARA, Alessandro. Processing Flows of Information: From Data Stream to Complex Event Processing. *ACM Computing Surveys*. 2012, roč. 44, č. 3. ISSN 0360-0300. Dostupné z DOI: 10.1145/2187671.2187677.
34. DJEDOUBOUM, Asside; ARI, Ado; GUEROUI, Abdelhak; MOHAMADOU, Alidou; ALIOUAT, Zibouda. Big Data Collection in Large-Scale Wireless Sensor Networks. *Sensors*. 2018, roč. 18. Dostupné z DOI: 10.3390/s18124474.
35. LAW, Yee Wei; CHATTERJEA, Supriyo; JIN, Jiong; HANSELMANN, Thomas; PALANISWAMI, Marimuthu. Energy-efficient data acquisition by adaptive sampling for wireless sensor networks. In: *Proceedings of the 2009 International Conference on Wireless Communications and Mobile Computing: Connecting the World Wirelessly*. Association for Computing Machinery, 2009, s. 1146–1151. IWCMC '09. ISBN 978-1-60558-569-7. Dostupné z DOI: 10.1145/1582379.1582631.
36. GUPTA, Manish; GAO, Jing; AGGARWAL, Charu C.; HAN, Jiawei. Outlier Detection for Temporal Data: A Survey. *IEEE Transactions on Knowledge and Data Engineering*. 2014, roč. 26, č. 9, s. 2250–2267. Dostupné z DOI: 10.1109/TKDE.2013.184.
37. BREUNIG, Markus M.; KRIEGEL, Hans-Peter; NG, Raymond T.; SANDER, Jörg. LOF: Identifying Density-Based Local Outliers. *SIGMOD Rec.* 2000, roč. 29, č. 2, s. 93–104. ISSN 0163-5808. Dostupné z DOI: 10.1145/335191.335388.

38. GURALNIK, Valery; SRIVASTAVA, Jaideep. Event Detection from Time Series Data. In: 1999, s. 33–42. Dostupné z DOI: 10.1145/312129.312190.
39. TRAN, Duc-Tan; LUU, Ha; NGUYEN, Tien Anh. A real-time vibration monitoring for vehicle based on 3-DOF MEMS accelerometer. In: 2010.
40. BASSEVILLE, Michèle; NIKIFOROV, Igor. *Detection of Abrupt Change Theory and Application*. 1993. ISBN 0-13-126780-9.
41. ARENAS-GARCÍA, Jerónimo; GÓMEZ-VERDEJO, Vanessa; NAVIA-VÁZQUEZ, Ángel. RLS Adaptation of One-Class SVM for Time Series Novelty Detection. 2004.
42. O'REILLY, Colin; GLUHAK, Alexander; IMRAN, Muhammad Ali; RAJASEGARAR, Sutharshan. Anomaly Detection in Wireless Sensor Networks in a Non-Stationary Environment. *IEEE Communications Surveys Tutorials*. 2014, roč. 16, č. 3, s. 1413–1432. Dostupné z DOI: 10.1109/SURV.2013.112813.00168.
43. HYNDMAN, Rob J.; WANG, Earo; LAPTEV, Nikolay. Large-Scale Unusual Time Series Detection. In: *2015 IEEE International Conference on Data Mining Workshop (ICDMW)*. 2015, s. 1616–1619. Dostupné z DOI: 10.1109/ICDMW.2015.104.
44. LIU, Jiang; WANG, Pengcheng; TIAN, Xincheng. Vibration displacement measurement based on three axes accelerometer. In: *2017 Chinese Automation Congress (CAC)*. 2017, s. 2374–2378. Dostupné z DOI: 10.1109/CAC.2017.8243173.
45. VARANIS, Marcus; SILVA, Anderson; MERELES, Arthur; PEDERIVA, Robson. MEMS accelerometers for mechanical vibrations analysis: a comprehensive review with applications. *Journal of the Brazilian Society of Mechanical Sciences and Engineering*. 2018, roč. 40. Dostupné z DOI: 10.1007/s40430-018-1445-5.
46. VERMA, Nishchal K.; GUPTA, Rajat; SEVAKULA, Rahul K.; SALOUR, Al. Signal transforms for feature extraction from vibration signal for air compressor monitoring. In: *TENCON 2014 - 2014 IEEE Region 10 Conference*. 2014, s. 1–6. Dostupné z DOI: 10.1109/TENCON.2014.7022275.

47. GHOSH, Ripul; AKULA, Aparna; KUMAR, Satish; SARDANA, Hk. Time–frequency analysis based robust vehicle detection using seismic sensor. *Journal of Sound and Vibration*. 2015, roč. 346, s. 424–434. Dostupné z DOI: 10.1016/j.jsv.2015.02.011.
48. SHIM, JaeSeok; KIM, GeoYoung; CHO, ByungJin; KOO, JeongSeo. Application of Vibration Signal Processing Methods to Detect and Diagnose Wheel Flats in Railway Vehicles. *Applied Sciences*. 2021, roč. 11, č. 5. ISSN 2076-3417. Dostupné z DOI: 10.3390/app11052151.
49. HAN, Sangbo. Measuring displacement signal with an accelerometer. *Journal of Mechanical Science and Technology*. 2010, roč. 24, s. 1329–1335. Dostupné z DOI: 10.1007/s12206-010-0336-1.
50. CHOWDHURY, Ranak Roy; ADNAN, Muhammad Abdullah; GUPTA, Rajesh K. Real-Time Principal Component Analysis. *ACM/IMS Trans. Data Sci.* 2020, roč. 1, č. 2. ISSN 2691-1922. Dostupné z DOI: 10.1145/3374750.
51. POTOČŇÁK, Tomáš; KOZUMPLÍK, Jiří. Časovo-frekvenčná analýza spánkového EEG s využitím metód založených na okamžitej frekvencii. *Elektrorevue*. 2017, roč. 19, č. 3. ISSN 1213-1539.
52. ROZINAJ, Gregor; RYBÁROVÁ, Renata; MINÁRIK, Ivan; KAČUR, Juraj. *Multimédiá*. 1. vyd. 2013. ISBN 978-80-01-05312-6.
53. WATTEYNE, Thomas; DOHERTY, Lance; SIMON, Jonathan; PISTER, Kris. Technical Overview of SmartMesh IP. In: *2013 Seventh International Conference on Innovative Mobile and Internet Services in Ubiquitous Computing*. 2013, s. 547–551. Dostupné z DOI: 10.1109/IMIS.2013.97.
54. YIU, Joseph. *The definitive guide to the ARM Cortex-M3*. Elsevier Inc., 2010. ISBN 978-1-85617-963-8.
55. RAHMAN, M.S.; CHOI, C.; KIM, Y.-P.; KIM, S. A simple and robustness algorithm for ECG R-peak detection. *Journal of Electrical Engineering and Technology*. 2018, roč. 13, s. 2080–2085. Dostupné z DOI: 10.5370/JEET.2018.13.5.2080.

Príloha A: Technická dokumentácia

Prílohy dopĺňajú hlavnú časť práce. Obsahujú napríklad podrobné informácie k jednotlivým etapám riešenia projektu. Typicky sa tu uvádza aj podstatná časť technickej dokumentácie. Pozor, prílohy nesmú obsahovať také informácie, ktoré sú pre pochopenie práce kľúčové. Tie musí obsahovať hlavná časť práce, ktorá musí byť úplná, celistvá.

Súčasťou príloh nie je len textový obsah, ale aj ďalšie artefakty, ktoré sú výsledkom projektu, napr. počítačový kód, dátové vzorky, vedecký článok či plagát. Zvláštnu pozornosť venujte tým artefaktom, ktoré sú potrebné pre replikovateľnosť postupov opisovaných v práci (napr. aby mohol oponent pri vyhodnocovaní práce zopakovať uvádzané postupy a prísť k rovnakým záverom).

Digitálne artefakty sa prikladajú na elektronickom médiu. K akémukoľvek digitálnemu obsahu treba uviesť v dokumente priebežnej či záverečnej správy bakalárskej/diplomovej práce primeraný textový opis, preto nezabudnite digitálne médium zdokumentovať. Prínajmenšom medzi prílohy zaradíte kapitolu "Obsah elektronického média". Na prílohy sa nezabudnite z hlavnej časti práce primerane odkazovať.

Obsah technickej dokumentácie závisí od povahy riešeného problému. Uvádza sa technická dokumentácia k systému (počítačový, softvérový), ktorý bol vytvorený v rámci riešenia projektu (ak sa toto v zadaní požadovalo). Samotný obsah a rozsah závisí aj od účelu vytvoreného systému (produkt, experimentovanie a pod.) V prípade softvérového systému technická dokumentácia spravidla obsahuje časti v náväznosti na etapy tvorby softvérového systému:

- dokumentáciu k etape špecifikácie požiadaviek
- dokumentáciu k etape návrhu projektu
- dokumentáciu k implementácii

- v prípade, že súčasťou riešenia sú programy, dokumentáciu k implementácii tvoria zdrojové texty programov
- v prípade, že súčasťou riešenia je návrh zariadenia, dokumentáciu k implementácii tvorí technická dokumentácia (schémy zapojenia, návrh dosiek plošných spojov, schémy rozmiestnenia súčiastok, zoznam použitých súčiastok, opis konektorov atď.)
- dokumentáciu k overeniu riešenia
- dokumentáciu k používaniu a údržbe (návod na použitie a údržbu projektu)

Príloha B: Harmonogram práce

B.1 Zimný semester

B.2 Letný semester

Príloha C: Obsah digitálneho média

Evidenčné číslo práce v informačnom systéme: FIIT-1234-98765

Obsah digitálnej časti práce (archív ZIP):

Názov odovzdaného archívu: ...zip