

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-5212-102927

Miroslav Hájek

Spracovanie dát generovaných senzorovou IoT sieťou

Priebežná správa o riešení BP1

Vedúci práce: Ing. Marcel Baláž, PhD.

December 2021

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-5212-102927

Miroslav Hájek

Spracovanie dát generovaných senzorovou IoT sieťou

Priebežná správa o riešení BP1

Študijný program: Informatika

Študijný odbor: Informatika

Miesto vypracovania: Ústav počítačového inžinierstva a aplikovanej informatiky

Vedúci práce: Ing. Marcel Baláž, PhD.

Pedagogický vedúci: Ing. Jakub Findura

December 2021



ZADANIE BAKALÁRSKEJ PRÁCE

Študent: **Miroslav Hájek**
ID študenta: 102927
Študijný program: informatika
Študijný odbor: informatika
Vedúci práce: Ing. Marcel Baláž, PhD.
Vedúci pracoviska: Ing. Katarína Jelemenská, PhD.
Pedagogický vedúci práce: Ing. Jakub Findura

Názov práce: **Spracovanie dát generovaných senzorovou IoT sieťou**

Jazyk, v ktorom sa práca vypracuje: slovenský jazyk

Špecifikácia zadania:

Senzorové IoT siete sa stali bežnou súčasťou rôznych priemyselných procesov. Ich primárnou úlohou je zbieranie rôznorodých dát z prostredia, ich ukladanie a vyhodnocovanie v reálnom čase. Analyzovanie a vyhodnocovanie dát pri nepredržitom monitorovaní už len z malého množstva senzorov predstavuje veľkú výzvu. Sensory produkujú veľké množstvo dát a anomálie nemusia byť na prvý pohľad detegovateľné. Cieľom projektu je analyzovať dáta zachytené senzorovou sieťou. Analyzovať algoritmy na ich ukladanie a spracovanie. Analyzujte jednotlivé úrovne senzorovej siete a identifikujte miesta, kde by sa dali dáta čiastočne spracovať. Na základe analýzy navrhnete spôsob ukladania a spracovania dát, prípadne optimalizáciu toku dát pre existujúcu senzorovú sieť. Vaše riešenie implementujte a otestujte jeho funkčnosť.

Rozsah práce: 40

Termín odovzdania bakalárskej práce: 16. 05. 2022
Dátum schválenia zadania bakalárskej práce: 23. 11. 2021
Zadanie bakalárskej práce schválil: doc. Ing. Valentino Vranič, PhD. – garant študijného programu

Obsah

1	Úvod	1
2	Analýza	3
2.1	Monitorovanie vibrácií a šoku	3
2.1.1	Meranie fyzikálnej veličiny akcelerácie	4
2.1.2	MEMS kapacitný akcelerometer	5
2.1.3	Analógovo-digitálny prevodník	7
2.1.4	Vlastnosti bežných akcelerometrov	9
2.1.5	Odvodzovanie rýchlosti a dráhy zo zrýchlenia	9
2.1.6	Numerická kvadratura	10
2.2	Metódy analýzy signálu v časovej doméne	12
2.2.1	Prúdové algoritmy	12
2.2.2	Posuvné a rozširujúce sa okná	13
2.2.3	Číselné charakteristiky štatistického rozdelenia	13
2.2.4	Algoritmy na rozpoznávanie špičiek	16
2.2.5	Metriky pre binárny klasifikátor	22
2.3	Frekvenčná a časovo-frekvenčná analýza signálu	23
2.3.1	Diskrétna fourierová a kosínusová transformácia	24
2.3.2	Algoritmus FFT	25
2.3.3	Oknové funkcie	27
2.3.4	Filtre s konečnou impulznou odozvou	28
2.4	Senzorová sieť	29
3	Návrh riešenia	33

Zoznam obrázkov

2.1	Model oscilujúceho systému s pružinou a tlmičom	4
2.2	Mikroštruktúra 3DOF MEMS kapacitného akcelerometra [3]	6
2.3	Digitalizácia signálu v analógovo-digitálnom prevodníku [5]	8
2.4	Porovnanie pravidiel numerickej integrácie	11
2.5	Dopad šikmosti a špicatosti na histogram distribúcie	16
2.6	Topografia priebehu signálu	20
2.7	Radix-2 FFT na štyroch bodoch [26]	26
2.8	Motýlikové diagramy algoritmu FFT	26

Zoznam rovníc

2.0	Fyzikálny model oscilujúceho systému s pružinou a tlmičom	5
2.1	Newtonov zákon sily	5
2.2	Magnitúda vektora akcelerácie	5
2.3	Nyquist-Shannonova veta o vzorkovaní	7
2.4	Konverzia merania na akceleráciu podľa rozlíšenia A/D prevodníka	8
2.5	Prevod A/D prevodníkom u akcelerometra s rozsahom v mg/LSB	9
2.6	Kinematické rovnice pre polohu, rýchlosť, zrýchlenie a rýv	10
2.7	Rýchlosť a poloha cez integrál akcelerácie	10
2.9	Pravidlá numerickej kvadratúry: obdĺžnikové, lichobežníkové, Simpsonovo	10
2.12	Amplitúda špička-špička	14
2.13	Efektívna amplitúda RMS	14
2.14	Výberový priemer alebo amplitúda jednosmernej zložky	14
2.15	Výberové miery rozptýlenosti: rozptyl, smerodajná odchýlka, MAD, IQR	15

2.19	Welfordov algoritmus na výpočet výberového rozptylu	15
2.22	Závislosť dvoch veličín cez kovarianciu a koreláciu	16
2.24	Lokálne extrémny funkcie	17
2.26	Detekcia špičiek prahovou úrovňou	17
2.27	Význačnosť vrchola spomedzi susedov	18
2.28	Metriky klasifikátora: senzitivita a špecifickosť	22
2.30	Metriky klasifikátora: správnosť, presnosť, chybovosť	23
2.33	Rozlíšenie vo frekvenčnej domény podľa vzorkovania	23
2.34	Diskrétna Fourierová transformácia	24
2.36	Exponenciálny faktor pre DFT v goniometrickom tvare	24
2.37	Magnitúdové spektrum absolútne a relatívne v decibeloch	24
2.39	Kosínusové transformácie: DCT-II, DCT-III, DCT-IV, MDCT	25

1 Úvod

2 Analýza

2.1 Monitorovanie vibrácií a šoku

Vibrácie sú periodickým kmitaním hmoty okolo rovnovážnej polohy vznikajúce excitáciou látky, ktorej je dodaná potenciálna energia, a zo zákona zachovania energie je následne premieňaná na kinetickú energiu. V realite dochádza pôsobením trenia k útlmu voľného oscilačného pohybu s časom a pohybová energia sa uvoľňuje v podobe tepelnej alebo akustickej emisie do okolitého prostredia. Častejšie ako presné harmonické kmity sú pozorované náhodné vibrácie, ktorých vývoj nevieme dopredu predvídať. Naproti tomu šok, alebo aj prechodový jav, je náhle uvoľnenie kinetickej energie krátkeho trvania oproti prirodzenej oscilácii systému.

Význam a dôležitosť sledovania vibrácií spočíva v ich výskyte u každého mechanického zariadenia a je zapríčinená pohybom jednotlivých súčiastok a trením v ložiskách. Ich nadmerná prítomnosť býva spôsobená opotrebením dielov stroja alebo nevyvážením rotačných častí, zakliesňovaním ozubených kolies, ako dôsledkoch iných technických defektov. V prevažnej väčšine prípadov ide o nežiaduci jav nakoľko zakladá zníženiu účinnosti so zvýšením hlučnosti ako vedľajšiemu produktu.

Ďalšou oblasťou hojnej prítomnosti vibrácií je preprava osôb alebo tovaru cestnými a železničnými dopravnými prostriedkami, kde sú zapríčinené nerovnosťami povrchu vozovky alebo koľaje v bode styku s kolesami vozidla. Na zvýšenie ovládateľnosti vozidla a komfortu pasažierov sú kabíny odpružené od kolies tlmičmi. Lietadlá sú zasa pod vplyvom trenia vzduchu s trupom a krídlami konštrukcie, ktoré je ďalej zosilnené vzdušnými prúdmi a turbulenciami.

Druhým významným faktorom podieľajúci sa na tvorbe vibrácii je aparát, ktorý uvádza vozidlo do pohybu alebo zastavuje, čiže hnací najčastejšie spaľovací, dieselový alebo elektrický motor a brzdoý systém. Jedná sa najmä o vplyv pohybu


piestov, alebo rotora u elektrických vozidiel, a prenosu otáčavého pohybu motora cez oje hriadeľa na nápravy. ABS brzdový systém prítomný pri väčšine automobilov zabraňuje šmyku striedavým zomknutím a uvoľňovaním brzdových kotúčov, čo má tiež vplyv na podmienky počas jazdy.

Detekciou nežiaducich vibrácií v preprave sa dokáže zabezpečiť aj bezpečnosť pasažierov včasnou výmenou súčiastky, ktorá by ovplyvnila prevádzkyschopnosť v kritických momentoch. Ich eliminácia dokáže predísť nenávratnému poškodeniu krehkých materiálov alebo znehodnoteniu reaktívnych substancií, či dokonca ich aktivácii v prípade výbušnín a pyrotechniky.

V neposlednom rade sú vibrácie súčasťou potenciálne nebezpečných prírodných úkazov a ich správna identifikácia má za následok varovania pre preventívnu evakuáciu obyvateľstva v oblasti, ktoré bude zasiahnutá zemetrasením, či erupciou sopky vedúcimi k ohrozenia zdravia osôb a poškodenia majetku.

2.1.1 Meranie fyzikálnej veličiny akcelerácie

Pohyb mechanického systému vystaveného vonkajším silám sa nazýva odozva, ktorej správanie opisuje zjednodušený model s jedným stupňom voľnosti (1DOF) kmitajúceho telesa s pružinou a tlmičom [1].



Obr. 2.1: Model oscilujúceho systému s pružinou a tlmičom

Pri pôsobení vonkajšej sily F na hmotu upevnenú na pružine vznikajú nútené vibrácie, ktoré ju vychýľujú z rovnovážnej polohy. Uvedená sila je charakterizovaná druhým Newtonovým zákonom v tvare $F = ma$, kde m je hmotnosť telesa a a predstavuje zrýchlenie. V protismere pôsobí sila vyvolaná pružinou $F_s = -kx$ a

tlmiacim členom $F_d = -cv$, kde k je tuhosť pružiny ovplynená jej konštrukciou, c je tlmiaci koeficient, x je vychýlenie z rovnovážneho stavu, a v rýchlosť vychýlenia.

Fyzickým obmedzením telesa, ktorým je viazaný na pevnú podložku dochádza pri zanedbaní deformácie k takmer zaručenému návratu do rovnovážnej polohy a to nám umožňuje merať intenzitu vibrácií cez zrýchlenie ťažidla. Výslednú silu v jednom smere získame sčítaním síl podieľajúcich sa na dynamike telesa.

$$F(t) = ma - cv - kx \quad (2.1)$$

Pri použití trojosového akcelerometra, kedy sú evidované všetky tri priestorové súradnice časovo-premennej akcelerácie dostávame nasledujúcu rovnicu vo vektorevom tvare:

$$\vec{a}(t) = \frac{\vec{F}(t)}{m} \quad (2.2)$$


Magnitúda akcelerácie s tromi súradnicami je daná L_2 normou vektora $\vec{a} = (a_x, a_y, a_z)$:

$$|a| = \sqrt{a_x^2 + a_y^2 + a_z^2} \quad (2.3)$$

2.1.2 MEMS kapacitný akcelerometer

Bežné inerciálne senzory na meranie zrýchlenia priamočiareho, ale aj rotačného pohybu (gyroskop), sa vyrábajú technológiou *MEMS* – *mikromechanický systém*, kedy je celé zariadenie vrátane všetkých mechanických súčastí umiestnené na kremík procesom mikrovýroby vo viacerých vrstvách. Sila spôsobujúca zrýchlenie je potom meraná vychýlením vstavanej odpruženej hmoty vzhľadom na pevné elektródy, ktoré môžu byť usporiadané jednostranne alebo ako diferenčný pár [2].

Pri diferenčnom páre spôsobí pohyb doštičky ťažidla medzi elektródami zmenu kapacít a ich rozdielom je možné zistiť aplikovanú silu a cez uvedený vzťah zrýchlenie. Na zvýšenie celkovej kapacity sa používa viacero párov elektród zapojených paralelne. Pred prevodom na číslicový signál musí napäťová úroveň zo senzora prejsť úpravou zahŕňajúcou nábojovocitlivý predzosilňovač, osovú demoduláciu a anti-aliasingové filtrovanie.



Obr. 2.2: Mikroštruktúra 3DOF MEMS kapacitného akcelerometra [3]

Viacosové akcelerometre vyžadujú viaceré opísané štruktúry orientované kolmo na seba, podľa obr. 2.2, s ohľadom na počet vyžadovaných stupňov voľnosti, pričom v skutočných senzoroch vždy existuje aspoň minimálna závislosť medzi osami rádo vo najviac v jednotkách percent. Teplota ovplyvňuje citlivosť MEMS akcelerometrov len nepatrne v stotinách percenta na stupeň Celzia.

Akcelerometre sa odlišujú v niekoľkých dôležitých vlastnostiach, ktoré zvyknú byť nastaviteľné vo výrobcovi stanovenom rozsahu prípustných hodnôt s príslušnými toleranciami [4].

Citlivosť stanovuje najmenšiu rozlíšiteľnú zmenu v odčítanom napätí ku zmene externého pohybu respektíve zrýchlenia. Uvádza sa v jednotkách mV/g (milivolt na tiažové zrýchlenie) pri analógovom výstupe, alebo mg/LSB (mili-g na najmenej významový bit). pri senzoroch so vstavaným analógovo-digitálnym prevodníkom. Jednotka mg/LSB vyjadruje o koľko sa zmení zrýchlenie keď zvýšime alebo ponížime binárne číslo na výstupe o jedna. Niekedy sa namiesto citlivosti uvádza mierka pre presnosť ako prevrátená hodnota citlivosti v LSB/g . Tiažové zrýchlenie g sa mierne líši podľa zemepisnej šírky, ale stanovený prepočet na jednotky SI je $1g = 9.80665 m/s^2$ ¹.

Dynamickej rozsah sa uvádza v tiažovom zrýchlení g . Hovorí o najmensej a najväčšej rozlíšiteľnej hodnote zrýchlenia nad úrovňou ktorej už dochádza k skresleniu

¹https://physics.nist.gov/cgi-bin/cuu/Value?gn|search_for=acceleration

signálu orezaním špičiek. S nevyhnutnými drobnými nepresnosťami výroby mikromechaniky je tzv. *zero-g napätie* popisujúce odchýlku skutočného od ideálneho výstupu, keď na sústavu nepôsobí žiadne zrýchlenie. Za ideálnych okolností bez pohybu na vodorovnom povrchu namerajú osi x a y zrýchlenie $0g$, zatiaľčo na z pôsobí $1g$. Očakávaním je nulová hodnota výstupného napätia a tým aj výstupného registra.

Šírka pásma senzora v Hz predurčuje rozsah frekvencií vibrácií, ktoré je možné zachytiť. Podmienená je zvolenou početnosťou čítania akcelerácie za sekundu, čiže vzorkovacou frekvenciou. Stanovuje sa tiež nastaviteľným parameterom *ODR* (Output Data Rate) - výstupný dátový tok, pričom šírka pásma je spravidla polovicou ODR. Menej uvádzanou vlastnosťou býva *frekvenčná odozva* senzora, ktorá určuje o koľko sa v rámci tolerancie odlišuje skutočná citlivosť od referenčnej pre zodpovedajúcu frekvenciu vibrácií.

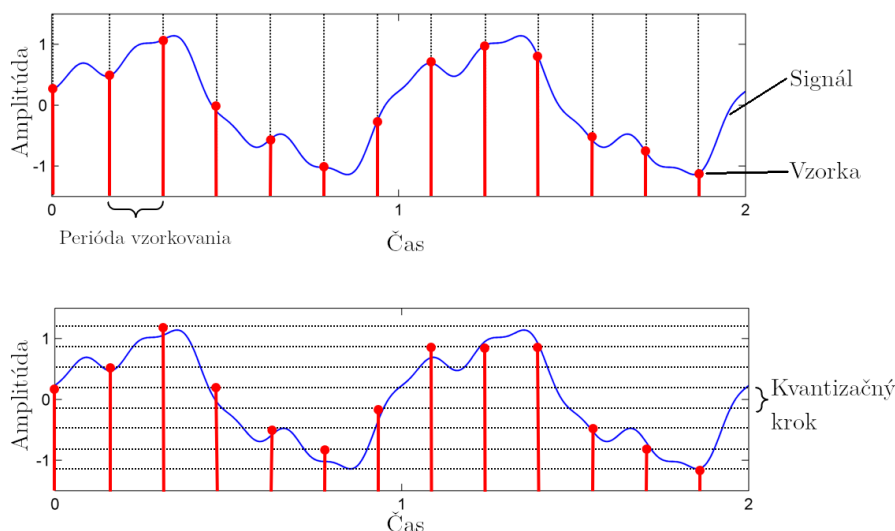
Na meranie zrýchlenia má nevyhnutný vplyv šum zapríčinený Brownovým pohybom a nedokonalosťou skutočných materiálov v štruktúre akcelerometra. Intenzita šumu rastie inverznou odmocninou so šírkou pásma, čiže s častejším meraním získavame menšiu presnosť. Pri dostatočnom odstupe signálu od šumu, $SNR = P_{signal}/P_{um}$, umožňuje hardvér akcelerometra vzorkovať amplitúdy až nad stanovený prah generovaním prerušenia, čím sa dokáže efektívne zbaviť nevýznamných fluktuácií.

2.1.3 Analógovo-digitálny prevodník

Spojité napäťová úroveň transformuje analógovo-digitálny (A/D) prevodník pre spracovanie digitálnym systémom do množiny diskretných hodnôt. Vstupný signál najprv prechádza fázou vzorkovania, kedy sa vzorky zaznamenávajú v pravidelných intervaloch. Počet vzoriek odčítaných za sekundu je vyjadrený vzorkovacou frekvenciou f_s v Hz . Časový rozdiel medzi vzorkami, nazývaný perióda vzorkovania, je prevrátenou hodnotou vzorkovacej frekvencie $T_s = \frac{1}{f_s}$. Pre presnú rekonštrukciu pásmovo obmedzeného signálu v hraniciach $[-f_{max}; f_{max}]$ je nevyhnuté podľa *Nyquist-Shannonovej vety* o vzorkovaní, aby vzorkovacia frekvencia bola najmenej dvojnásobkom maximálnej frekvencie snímaného signálu.

$$f_s \geq 2 \cdot f_{max} \quad (2.4)$$

V procese kvantovania je každej vzorke je následne priradená diskretná hodnota s konečným počtom n bitov, ktorá je najbližšia možná ku skutočnej hladine analógového vstupu. Dochádza pritom k istému zaokrúhľovaniu z dôvodu nepresnosti vyjadrenia spojitý domény amplitúd diskretným číslom. Tento jav označujeme ako kvantizačný šum, ktorý je najviac polovicou z maximálnej rozlíšiteľnej zmeny signálu a trpia nim všetky existujúce A/D prevodníky.



Obr. 2.3: Digitalizácia signálu v analógovo-digitálnom prevodníku [5]

Prevodníky integrované priamo s inerciálnymi jednotkami sa vyhotovujú v rozlíšeníach 12, 16 alebo 20 bitov. Umožňujú tak pripojiť akcelerometer rovno na sérové zbernice *SPI* alebo *I2C*. Všeobecne platí, že pri n bitoch je k dispozícii 2^n rozličných čísel. Kódovaním v dvojkovom doplnku pre zachytenie záporných hodnôt sa uvažuje s intervalom $[-2^{\frac{n}{2}}; 2^{\frac{n}{2}} - 1]$.

Číslicová hodnota v dvojkovom doplnku získaná konverziou \hat{x} je prepočítaná na štandardné fyzikálne jednotky pre zrýchlenie, a v m/s^2). R predstavuje nastavený dynamický rozsah v jednotkách g a n je počet bitov A/D prevodníka.

$$a = \hat{x} \cdot ((R \cdot g)/2^{n/2}) \quad (2.5)$$

Na základe už zmieneného ohľadom vlastností MEMS akcelerometrov, presnejší prevod dosiahneme využitkováním deklarovanej citlivosti senzora pri danom dyna-

mickom rozsahu S_R udávaného v mg/LSB .

$$a = \hat{x} \cdot (S_R \cdot g) / 1000 \quad (2.6)$$

2.1.4 Vlastnosti bežných akcelerometrov

Na ilustráciu uvádzame parametre zvolených najrozšírenejších typov akcelerometrov. Akcelerometer LSM9DS1 [6] umožňuje cez zbernicu SPI alebo I2C zvoliť zo štyroch dynamických rozsahov, pričom každé rozpätie sa vyznačuje svojou citlivosťou. Zvolením menšieho dynamického rozsahu zvýšime citlivosť. LSM9DS1 funguje pri rozsahoch $\pm 2g$, $\pm 4g$ a $\pm 8g$ a $\pm 16g$, postupne s citlivosťami 0.061 mg/LSB , 0.122 mg/LSB , 0.244 mg/LSB , 0.732 mg/LSB . Výstupný dátový tok (ODR) je možné nastaviť na 10Hz , 50Hz , 119Hz , 238Hz , 476Hz a najvyššie na 952 Hz . Navzorkované hodnoty sú ukladané do 16-bitového výstupného registra v dvojkovom doplnku.

Nízkoenergetický 3DOF MEMS akcelerometer ADXL362 [7] so spotrebou $2 \mu A$ pri 100Hz disponuje rozsahmi $\pm 2g$, $\pm 4g$ a $\pm 8g$ s citlivosťami 1 , 2 a 4 mg/LSB . Dostupné vzorkovacie frekvencie 12-bitového A/D prevodníka sú $12.5 - 400\text{Hz}$ v 8 krokoch vždy po násobkoch predošlého kroku. Pre rýchlejšie čítanie pri nižšom rozlíšení dokáže senzor zakódovať dáta do 8-bitového registra.

Vyrábajú sa tiež akcelerometre s väčšími dynamickými rozsahmi a nízkym šumom, ide napríklad o ADXL356 a ADXL357 [8] so škálami $\pm 10g$, $\pm 20g$ a $\pm 40g$ s citlivosťou $0,019 \text{ mg/LSB}$ po $0,078 \text{ mg/LSB}$ a rozlíšením A/D prevodníka 20 bitov pri ODR $4 - 4000\text{Hz}$. ADXL357 ponúka priamo analógové výstupy s citlivosťou $20 - 80 \text{ mV/g}$ pri napájaní 3.3 V .

2.1.5 Odvodzovanie rýchlosti a dráhy zo zrýchlenia

Meranie akcelerácie umožňuje zároveň nepriamo získať ďalšie údaje o pohybe celkom v priestore ako aj spôsobenom vibráciami. Zrýchlenie \vec{a} je definované ako časová zmena rýchlosti \vec{v} , zatiaľčo rýchlosť je časovou zmenou polohy \vec{r} . Na pozorovanie prechodových javov alebo na vyjadrenie miery plynulosti pohybu slúži ryv \vec{j} , ktorý je časovou zmenou akcelerácie. Pokiaľ nie sú známe počiatočné podmienky v okamihu začiatku snímania akcelerácie, budú hodnoty veličín relatívne vzhľadom na štart záznamu. Kinematika v diskretnom čase je potom opísaná nasledujúci rovnicami,

kde Δ je operátor diferencie $\Delta t = t(i) - t(i - 1)$:

$$\vec{v} = \frac{\Delta \vec{r}}{\Delta t}; \quad \vec{a} = \frac{\Delta \vec{v}}{\Delta t}; \quad \vec{j} = \frac{\Delta \vec{a}}{\Delta t} \quad (2.7)$$

Vyjadrenie neznámych premenných vzhľadom na akceleráciu spočíva v prenásobení rovníc členom Δt , čím sa získajú vzťahy pre okamžitú dráhu a okamžitú rýchlosť. Spočítaním čiastkových okamžitých rýchlostí na intervale dostaneme celkovú rýchlosť a rovnaký úsudok platí pre polohu. V spojitom čase, keď by vzorkovacia perióda bola nekonečne krátka, dochádza naproti tomu k integrovaniu funkcie akcelerácie. Dostávame, že rýchlosť je integrálom zrýchlenia a poloha je dvojným integrálom zrýchlenia:

$$\vec{v}(t) = \vec{a}_0 + \int \vec{a}(t) dt \quad (2.8)$$

$$\vec{r}(t) = \vec{r}_0 + \vec{v}_0 t + \iint \vec{a}(t) dt \quad (2.9)$$

2.1.6 Numerická kvadratura

Približný výpočet určitého integrálu funkcie akcelerácie je založený na geometrickej interpretácii integrálu ako plochy pod krivkou. Hovoríme vtedy o probléme numerickej kvadratúry, ktorý navrhuje nahradiť pôvodný integrand interpolačným polynómom [9]. Rád polynómu n implicitne stanoví priebeh funkcie medzi ekvidistantnými vzorkami a má dopad na presnosť aproximácie. Najčastejšie sa používajú konštantný ($n = 0$), lineárny ($n = 1$) alebo kvadratický ($n = 2$) polynóm, podľa toho rozlíšujeme obdĺžnikové pravidlo (vzorec 2.10), lichobežníkové pravidlo (vzorec 2.11) a Simpsonovo pravidlo (vzorec 2.12).


$$v(t_i) = T_s \cdot a \left(\frac{t_i + t_{i-1}}{2} \right) \quad (2.10)$$

$$v(t_i) = \frac{T_s}{2} \cdot [a(t_i) + a(t_{i-1})] \quad (2.11)$$

$$v(t_i) = \frac{T_s}{3} \cdot [a(t_{2i}) + 4a(t_{2i-1}) + a(t_{2i-2})] \quad (2.12)$$

Pri *obdĺžnikovom pravidle* (obr. 2.4a) nepripúšťame zmenu hodnoty zrýchlenia medzi vzorkami a okamžitú rýchlosť, čiže plochu, odhadneme ako dĺžku intervalu

vzorkovania vynásobenú priemerom výšok dvoch následných pozorovaní. Interpolčný polynóm je konštantná funkcia. *Lichobežníkové pravidlo* (obr. 2.4b) uvažuje s lineárnou zmenou veličiny medzi meraniami, preto interpoluje priamkou. *Simpsonovo pravidlo* (obr. 2.4c) sa snaží o ešte tesnejší odhad s využitím kvadratickej funkcie. Každé kvadráturne pravidlo sa síce vyznačuje presne vyčísliteľnou chybovosťou, ale k tomu je nevyhnutné poznať analytické vyjadrenie vibrácií, čo dáva realistický odhad len pri čisto periodických kmitoch.



Obr. 2.4: Porovnanie pravidiel numerickej integrácie

Priama integrácia zašumeného signálu zrýchlenia vedie k neskutočnému driftu, ktorý je ešte zvýraznený dvojitou integráciou pri odvodzovaní relatívneho posunutia. Dochádza k zosilneniu nízkych a potlačeniu vyšších frekvencií, čím sa začne dominovať neexistujúci trend vo výstupných dátach. Očakávané oscilujúce správanie vychýlenia u vibrácií so zväčšujúcim sa počtom sčítancov pri rekurentnom výpočte zaniká. Na zlepšenie stability integrátora sa uplatňuje korekcia cez obálky [10].

Najprv je na vstupnom signále vykonaná zvoleným pravidlom numerická kvadratura, ktorá môže byť realizovaná na krátkych úsekoch funkcie, aby sa predišlo pretečeniu pri výraznej akumulácii odklonu. Prichádza k identifikácii lokálnych extrémov, či už maxím, respektíve miním (pozri 2.2.4) a ich interpoláciou s kubickou B-spline sa sformuje horná $e_u(t)$, respektíve dolná obálka signálu $e_d(t)$. Obálky sú spriemerované $\bar{e}(t)$, čím vznikne odhad trendovej krivky, ktorá je od už integrovaného signálu odčítaná $g(t) = f(t) - \bar{e}(t)$. V prípade výpočtu polohy je možné aplikovať uvedený postup kaskádovito, čiže rovnako ako akcelerácia je aj signál rýchlosti opäť integrovaný a korigovaný obálkami. Trend je rovnako tak odstrániteľný filtrom na potlačenie prítomnosti jednosmernej zložky v podobe hornej priepuste (pozri 2.3.4).

2.2 Metódy analýzy signálu v časovej doméne

Pozorovania veličiny predstavujú udalosti merané sekvenčne v čase, kde je s každou obdržanou hodnotou x_i viazaná unikátna časová značka t_i . Postupnosť jednotlivých čítaní je jednorozmerný časový rad znázoriteľný ako usporiadaná množina dvojíc pečiatky rastúcej v čase a nasnímanej úrovne: $T = \{(t_1, x_1), (t_2, x_2), \dots, (t_n, x_n)\}$. Vzorkovaním v pravidelných intervaloch stačí uvažovať namiesto časových značiek o celočíselných indexoch, ktoré určujú pozíciu prvkov vo vektore pozorovaní: $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$. Keď sú súčasne zaznamenávané viaceré dátové body hovoríme o matici pozorovaní $X_{n,m}$, či o viacrozmernom časovom rade.

2.2.1 Prúdové algoritmy

Pri veľkom objeme prichádzajúcich vzoriek produkované senzormi, nie je uskutočniteľné ich úplné uchovanie ani spracovanie celého dátového toku naraz. Častokrát by stratégia neuváženeho odkladania viedla k plýtvaniu zdrojov a zbytočnému archivovaniu údajov s nízkou informačnou hodnotou. Vhodnejšie je agregovanie toku údajov podľa preddefinovaného zmysluplného kritéria, ktoré by umožňovalo zachytiť významné rysy a prompte zodpovedať na vyžadované dopyty.

Priamočiarou realizáciou agregácie je nahliadať na prvky časového radu postupne ako prichádzajú. Prúdové algoritmy pôsobiace v reálnom čase, a teda neschopné vidieť finálny vektor vzoriek vstupu sa vyznačujú vlastnosťou, že vyprodukujú len na základe takého čiastkového vstupu parciálny výsledok platný pre dosiaľ sa vyskytnutú podmnožinu.

Online algoritmus spracúvajúci neprestajný potenciálne nekonečne sa rozširujúcu vstupnú sadu sa ideálne vyznačuje sublineárnou alebo polylogaritmickou časovou zložitosťou spracovanie jednotlivých prvkov, celkové spracovanie, a sú žiaduce sublineárne pamäťové nároky [11].

Za ideálnych okolností by sa mal online algoritmus učiť kontinuálne bez ukladania predošlých bodov a detekcií. V rozhodnutiach algoritmu sú zahrnuté informácie o všetkých predošlých bodoch do terajšieho rozhodnutia. Mal by mať schopnosť sa adaptovať dynamickému prostrediu, v ktorom pôsobí, bez nutnosti manuálnych úprav parametrov modelu. Zároveň je žiaduce minimalizovať falošné pozitíva a ne-

gátiva pri detekcii udalostí. V turniketovom modeli sa pri online agregácii načítaný bod x_i zaráta do každého relevantného počítadla a môže byť ihneď zabudnutý [11].

2.2.2 Posuvné a rozširujúce sa okná

Časový rad $(x_i)_{i=0}^n$ s dĺžkou n môže byť pre účely výpočtu sumárnych štatistík rozdelený oknovou funkciou $\mathcal{W}_{l,d}$ na podpostupnosti nazývané okná.

Posuvné okná („rolling window“) majú spravidla konštantnú dĺžku l menšiu ako celkovú veľkosť radu a sú aplikované s krokom odstupe d pozorovaní. Rad pozorovaní pozostáva z $(n - (l - 1))/d$ okien [12]. Prirodzene sa posuvné okná objavujú pri manipulácii s vyrovnávacou pamäťou, ktoré sa využívajú pri blokovom prenose z adaptéra senzora do hlavnej pamäte. Vtedy sa veľkosť bloku sa rovná posunu $l = d$.

Rozširujúce sa okná („expanding window“) nachádzajú uplatnenie v menej prípadoch, spravidla sa jedná o inkrementálny odhad globálnej štatistiky, ktorá má zmysel prevažne pri sledovaní stabilného javu. [13]. Okno začína na stanovenej minimálnej veľkosti a s pribúdajúcim počtom bodov ich zahŕňa, čím sa zväčšuje. Dostavuje sa rovnaký výsledok ako v turniketovom modeli, ale navyše neplatí obmedzenie zahadzovania už započítaných údajov, ale dokážeme teoreticky operovať so všetkými vzorkami vrámci okna.

2.2.3 Číselné charakteristiky štatistického rozdelenia

Náhodné vibrácie vyskytujúce sa pri skutočných materiáloch sú stochastický proces, ktorý tvorí sekvencia časovo indexovaných náhodných premenných. Časový rad predstavuje realizáciu tohto stochastického procesu $\mathbf{Y} = (X_1, X_2, \dots, X_n)^T$, kde X_t je náhodná premenná so svojím rozdelením pravdepodobnosti. Všeobecne sa pri ideálnych stacionárnych otrasoch predpokladá, že premenné pochádzajú z unimodálnej Gaussovej distribúcie: $X_t \sim N(\mu, \sigma^2)$ [1].

Sumárna deskripcia nameraného deja pre extrakciu typických čŕt konkrétnych pozorovaných situácií sa uskutočňuje viacerými štatistikami $h(X_1, X_2, \dots, X_n)$ zosťručňujúcimi opis funkcie hustoty rozdelenie. Na rozmiestnenie hodnôt meraní v priebehu časového úseku sa nazerá z pohľadu polohy, rozptýlenosti a tvaru. Rozsah oboru hodnôt je amplitúda špička-špička („peak-to-peak“), ktorá je rozdielom

maximálnej a minimálnej úrovne, údaj známy tiež ako variančné rozpätie [14].

$$x_{pp} = \max_{t \in \mathcal{W}} \{x_t\} - \min_{t \in \mathcal{W}} \{x_t\} \quad (2.13)$$

Priemernú energiu obsiahnutú v signále predstavuje štvorec efektívnej amplitúdy RMS a určí sa ako kvadratický priemer pozorovaní:

$$x_{rms} = \sqrt{\frac{1}{n} \sum_{t=1}^n x_t^2} \quad (2.14)$$

Mierami polohy rozdelenia pozorovaní sú stredná hodnota, informujúca o centre hodnôt veličiny, a kvantily rozkladajúce usporiadaný vektor pozorovaní na určený počet rovnakých skupín. Nevychýleným bodovým odhadom strednej hodnoty je *výberový priemer*, ktorý je zároveň amplitúdou jednosmernej zložky signálu:

$$\bar{x} = \frac{1}{n} \sum_{t=1}^n x_t \quad (2.15)$$

Najvýznamnejším kvantilmi sú kvartily Q_q vytvárajúce štyri rovnako veľké časti z pôvodných dát, konkrétne dolný kvartil Q_1 oddelí 25% najmenších údajov, medián Q_2 predelí zoradené údaje na polovicu a horný kvartil Q_3 zahrnie 75% nižších hodnôt. Hľadaný kvartil je k -ty najmenší prvok v utriedenom zozname meraní, pričom podľa želaného kvartilu q a počtu pozorovaní je $k = \lceil n \cdot (1/q) \rceil$.

Zistenie k -teho najmenšieho prvku s časovou zložitou $\mathcal{O}(n \log n)$ umožňuje ľubovoľný lepší triediaci algoritmus napríklad triedenie zlučovaním (merge sort). Algoritmus *Quickselect* dokáže taký prvok objaviť v čase $\mathcal{O}(n)$. V každom kroku vyberie náhodný deliaci bod (pivot) a preskupí k sebe hodnoty menšie ako pivot naľavo a väčšie ako pivot napravo. Najmenší prvok následne hľadá v časti, kde zostalo viac ako k prvkov. Pokiaľ došlo k deleniu zoznamu, že pivot zaujme presne k -tu pozíciu prehľadávanie je ukončené a pivot prehlásený za riešenie. Nesprávnym výberom pivota môže v najhoršom prípade dôjsť až k zložitosti $\mathcal{O}(n^2)$, čomu sa predchádza výberom pivota cez medián mediánov.

Sústredovanie realizácie veličiny, respektíve jej rozptýlenosť okolo strednej hodnoty vieme opísať viacerými štatistikami ako sú *výberový rozptyl* (2.16), ktorej odmocninou dostaneme smerodajnú odchýlku, *priemerná absolútna odchýlka* (2.17),

mediánová absolútna odchýlka (2.18) a *medzikvartilové rozpätie* (2.19) [14]. Priemerná absolútna odchýlka je upraviteľné o mieru centrálnej tendencie, ktorou okrem priemeru môže byť aj medián alebo modus. Vyvarovanie sa príliš extrémnym a vychýlením hodnotám docielime zapojením práve mediánu do štatistík absolútnej odchýlky, rovnako tak to dosiahneme medzikvartilovým rozpätím obmedzením sa na 50% centrálnych dát.

$$s^2 = \frac{1}{n-1} \sum_{t=1}^n (x_t - \bar{x})^2 \quad (2.16)$$

$$d = \frac{1}{n} \sum_{t=1}^n (|x_t - \bar{x}|) \quad (2.17)$$

$$\text{MAD} = \text{med}(|x_t - \text{med}(\mathbf{x})|) \quad (2.18)$$

$$\text{IQR} = Q_3 - Q_1 \quad (2.19)$$

Numericky stabilné bežiacie štatistiky priemeru a smerodajnej odchýlky sa udržiavajú cez rekurentné rovnice *Welfordovho algoritmu* [15]. M_1 je aktuálna priemerná hodnota údajov v toku a S_1 je počítadlo pre rozptyl, z ktorého je v ktoromkoľvek okamihu získateľná smerodajná odchýlka súboru σ :

$$M_1 = x_1; \quad M_k = M_{k-1} + \frac{(x_k - M_{k-1})}{k} \quad (2.20)$$

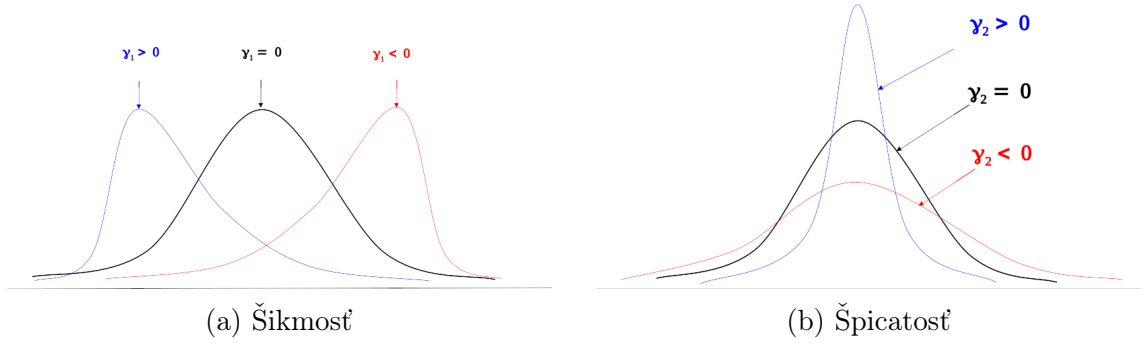
$$S_1 = 0; \quad S_k = S_{k-1} + (x_k - M_{k-1})(x_k + M_k) \quad (2.21)$$

$$\sigma = \sqrt{S_n / (n-1)} \quad (2.22)$$

Tvar distribúcie náhodnej premennej opisujú centrálné momenty šikmost' a špicatost'. Šikmost' $\gamma_1 = \mu^3 / \sigma^3$ udáva skosenie rozdelenia, pričom platí že záporná šikmost' značí dlhší ľavý chvost a modus funkcie hustoty sa prevažuje napravo. Zatiaľ čo u kladnej šikmosti je to naopak (obr. 2.5a).

Špicatost' $\gamma_2 = \mu^4 / \sigma^4 - 3$ (obr. 2.5b) porovnáva rozdelenie pozorovaní so strmosťou krivky normálneho rozdelenia, čiže viacej realizácií leží bližšie alebo ďalej od strednej hodnoty. Kladná špicatost' signalizuje strmejšiu a záporná zasa sploštenejšiu distribúciu. Platí, že μ_n je priemerom hodnôt $(x_t - \bar{x})^n$.

Závislosť dvojíc veličín sa vyjadruje *kovariancia* $\text{cov}(\mathbf{x}, \mathbf{y})$ a *korelácia* $\rho(\mathbf{x}, \mathbf{y})$. U vektora akcelerácie nás bude napríklad zaujímať vzájomná korelácia medzi osami



Obr. 2.5: Dopad šírky a špicatosti na histogram distribúcie

pohybu: $\rho(\vec{x}, \vec{y})$, $\rho(\vec{x}, \vec{z})$, $\rho(\vec{y}, \vec{z})$ upozorňujúca na diagonálny pohyb alebo podobné
 budenie v oboch korelovaných smeroch a tým umožňujúce redukciu údajov z dôvodu
 redundancie. Kovariancia je daná strednou hodnotou súčinu odchýlky od priemeru
 zodpovedajúcej premennej (vzťah 2.23). Normovaním kovariancie smerodajnými od-
 chýlkami veličín získame *Pearsonov korelačný koeficient* (vzťah 2.24), ktorý je z
 intervalu $[-1; 1]$. Hodnota koeficientu -1 značí nepriamu lineárnu závislosť a $+1$
 priamu závislosť.

$$\text{cov}(\mathbf{x}, \mathbf{y}) = \frac{1}{n} \sum_{t=1}^n (x_t - \bar{x})(y_t - \bar{y}) \quad (2.23)$$

$$\rho(\mathbf{x}, \mathbf{y}) = \frac{\text{cov}(\mathbf{x}, \mathbf{y})}{\sigma_x \sigma_y} \quad (2.24)$$

2.2.4 Algoritmy na rozpoznávanie špičiek

Detekcia udalostí a významných zmien signálového priebehu sa spolieha na hodno-
 vernú identifikáciu špičiek amplitúdy. Dôležitými indikátormi pre celkovú charakte-
 rizáciu javu slúži potom časová pozícia špičky v rámci prúdu, výška prejavujúca sa
 získanou úrovňou, šírka obsahujúca údaj o trvaní, či plocha stvárňujúca energiu.

Ekvivalentne sa špičky z matematického hľadiska stotožňujú s lokálnymi extrém-
 ami funkcie, čo sú maximá (vrcholy) a minimá (údolia). Podľa definície je lokálne
 maximum t_0 bodom, ktorý má vyššiu funkčnú hodnotu ako všetky ostatné body na
 intervale $t_0 \in I$ (2.25), lokálne minimum má na intervale najmenšiu hodnotu (2.26)

[16].

$$f[t_0] \geq f[t], \forall t \in I \quad (2.25)$$

$$f[t_0] \leq f[t], \forall t \in I \quad (2.26)$$

Kľúčové pre spoľahlivé určenie extrémov je práve interpretácia intervalu I v algoritmoch, ktoré zastupujú rozličné potreby korektného vyhodnotenia. Jediné minimum a maximum sa dosiahne zvolením celej dĺžky záznamu za interval, čím sa stratia dočasné disturbancie. Na druhej strane prílišným skrátením intervalu sa skoro všetky vzorky budú javiť ako náhle zmeny.

Skutočné signály sa potýkajú so šumom, ktorý sťažuje odlíšenie pravej tendencie od krátkodobých výkyvov. Pred samotným procesom hľadania špičiek je preto aplikovaný vyhladzovací filter, v prípade potreby aj opakovane na už vyhladený signál. Najčastejšie sa jedná o filter klzavého priemeru, Savitzky–Golay alebo Gaussov filter [17]. Filtrovanie sa realizuje diskretnou jednorozmernou konvolúciou vstupného signálu a masky filtra $y[n] = x[n] * w[n]$, ktorá býva hardvérovo akcelerovaná inštrukciami „fused multiply-add”².

Detekcia špičiek prahovou úrovňou

Za predpokladu, že priebeh meranej veličiny sa vyznačuje krátkymi impulzmi s viac-menej pravidelnou amplitúdou je priamočiarou metódou na odlíšenie špičiek od hladín nízkej aktivity určenie prahu θ , ktorý zaregistruje všetky väčšie hodnoty. Lokálne extrémy sú potom vzorky signálu spĺňajúce podmienku:

$$|f[t]| \geq \theta \quad (2.27)$$

Určenie takejto hraničnej hladiny prebieha zväčša empiricky alebo na základe heuristik, ktoré so sebou nesú domnienku o vlastnostiach priebehu pozorovaní. Uspokojivými odhadom za určitých okolností môžu byť prahy θ : viac ako priemer s toleranciou, horné 3/4 celkového nedávneho rozsahu hodnôt, či dokonca viac ako k smerodajných odchýlok. Odlišné nazeranie na prahovú hodnotu spočíva v jej nastavení pre rozpoznanie vzájomnej korelácie signálu a masky zodpovedajúcej tvaru

²<https://developer.arm.com/documentation/102198/0200/Convolution>

impulzu. Táto úvaha sa opiera o to, že impulz musí byť dostatočne pravidelný, aby bol nezameniteľne odlíšiteľný.

Význačnosť vrchola spomedzi susedov

Doplňkom ku rozpoznávaniu špičiek podľa absolútnej prahovej úrovne je porovnanie bodov na obe strany od preskúmaného vrchola, čím zistíme relatívnu významnosť extrému pre najbližšie susedstvo. Aby bola hodnota na danej pozícii t označená za špičku v okolí pozostávajúcom z k príslušných bodov, musí byť v porovnaní so všetkými väčšia. Pre okrajové dátové body $f[0]$ a $f[n]$ dochádza k porovnaniu iba z jednej strany [16].

$$f[t - i] < f[t] > f[t + i], \quad \forall i \in 1, 2, \dots, k \quad (2.28)$$

Algoritmus č.1 „najvyšší spomedzi susedov“³ prechádza postupne pozorovania veličiny zo zoznamu y a ku kandidátnej špičke na indexe i preveruje najbližších k hodnôt na obe strany, ak existujú. Keď po preskúmaní zostáva $y[i]$ najväčšou

Algoritmus 1 Najvyšší spomedzi susedov

```

1: function FIND_PEAKS_NEIGHBOURS( $y, k, \varepsilon, h_{rel}, h$ )
2:    $peaks \leftarrow []$  ▷ Zoznam indexov nájdených špičiek v signále  $y$ 
3:   for  $i \leftarrow 0$  to  $length(y)$  do
4:     if  $h \neq null$  and  $|y[i]| < h$  then ▷ Preskoč príliš nízke magnitúdy
5:       continue
6:     end if
7:      $possible\_peak \leftarrow true$ 
8:      $a \leftarrow max(i - k, 0)$ 
9:      $b \leftarrow min(i + k, length(y))$ 
10:    for  $j \leftarrow a$  to  $b$  do ▷ Porovnaj špičku s bodmi v susedstve
11:      if  $i \neq j$  and  $y[j] - y[i] > \varepsilon$  then
12:         $possible\_peak \leftarrow false$  ▷ Kopec nie je dostatočne strmý
13:      end if
14:    end for
15:    if  $possible\_peak = true$  and  $y[i] - \min(y[a], y[b]) > h_{rel}$  then
16:       $peaks \leftarrow peaks + [i]$  ▷ Kandidát je prehlásený za špičku
17:    end if
18:  end for
19:  return  $peaks$ 
20: end function

```

³<https://terpconnect.umd.edu/~toh/spectrum/PeakFindingandMeasurement.htm>

hodnotou spomedzi susedov v rozmedzí $[a; b]$, za tolerancie strmosti stúpania ε medzi pozorovaniam, a súčasne je relatívna výška vrcholu väčšia oproti nižšiemu okraju než nastavený parameter h_{rel} potom je kandidátny bod prehlásený za skutočnú špičku a pridaný do zoznamu *peaks*.

Súčasťou algoritmu je tiež preskočenie hodnôt, ktoré nespĺňajú základný predpoklad pre absolútnu amplitúdu h . Časová zložitosť pre rozhodnutie o jednej špičke je lineárna v závislosti od veľkosti posuvného okna uvažovaného susedstva $\mathcal{O}(2k)$.

Algoritmus prechodu nulou do záporu

Pomyselné vrcholy a údolia v zosnímaných hodnotách sú miestom, kde sa mení smer úrovni amplitúdy zo stúpania na klesanie alebo z klesania na stúpanie, čím na pomedzí týchto opozitných trendov vzniká stacionárny bod, kde je prvá diferenciá nulová: $\Delta f[i] = 0$. V lokálnom maxime dochádza súčasne k zmene znamienka prvej diferenciácie z kladného na záporné. Prudkosť kopca vyplýva z absolútnej hodnoty diferenciácie.

Viacnásobné vyhladenie signálu predom je nesmierne dôležité, pretože algoritmus č.2 „prechodu nulou do záporu“ (Negative Zero-Crossing) je nesmierne citlivý na zákmity a nesprávneby ich považoval za špičky. Zvýšenie odolnosti proti takýmto tendenciám sa dosahuje dlhšou sečnicou spájajúcou bod i s k -tou vzorkou vedľa, ktorá sa použije namiesto diferenciácie s jednotkovým krokom.

Algoritmus 2 Prechod prvej derivácie nulou do záporu

```
1: function FIND_PEAKS_ZERO_CROSSING( $y, k, \varepsilon, slope$ )
2:    $peaks \leftarrow []$ 
3:   for  $i \leftarrow k$  to  $length(y) - k$  do
4:     if  $(|y[i + k] - y[i - k]| \leq \varepsilon$  and
5:        $(y[i + k] - y[i]) - (y[i] - y[i - k]) < 0$  and
6:        $|(y[i + k] - y[i]) - (y[i] - y[i - k])| > slope)$  then
7:        $peaks \leftarrow peaks + [i]$ 
8:     end if
9:   end for
10:  return  $peaks$ 
11: end function
```

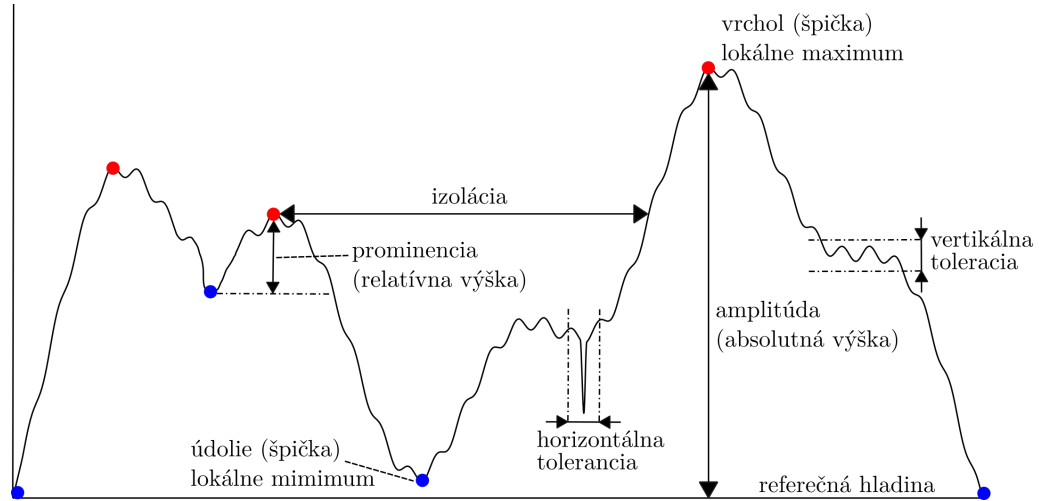
Označenie kandidátneho bodu za špičku v zozname hodnôt y stojí na teda troch kritériách. Sklon sečnice sa musí v rámci tolerancie ε blížiť nule, rozdiel prvých diferencií $\Delta y[i + k] - \Delta[i]$ musí byť záporný a veľkosť rozdielu diferencií prekračuje

prahovú strmosť kopca *slope*, kde leží uvažovaný vrchol. Časová zložitosť pre jednu špičku je $\mathcal{O}(1)$.

Algoritmus horského turistu

Zanesením do grafu pripomína priebeh funkcie kmitajúceho deja členité pohorie. Na problém rozhodovania sa o tom, či danú lokalitu považovať za vrchol možno nahliadať z pohľadu chodca cestujúceho po krivke z lineárne interpolovaných vzoriek. V princípe ide myšlienkou o jednoduchý stavový automat sledujúci aktuálny stav terénu a konajúci rozhodnutia na základe predošlej skúsenosti v intenciách rozhodovacích pravidiel.

Algoritmus č.3 horského turistu na začiatku púte z počiatočných bodov zistí, ktorým z dvoch vertikálnych smerov sa krivka ubera. V prípade, že po druhom kroku dôjde k zmene smeru zapíše sa indikácia možného spádu kopca. Výchyľka môže byť v dôsledku neprekročenia prahových úrovní v horizontálnej (*hole*) a vertikálnej (*tolerance*) osi ignorovaná, lebo ani na lesnom chodníku sa nepovažuje každá jama alebo vydutie za horu.



Obr. 2.6: Topografia priebehu signálu

Domnelý vrchol je označený za lokálne maximum, keď spĺňa parametre pre topografické vlastnosti minimálnej akceptovateľnej prominencie a izolácie (obr. 2.6). Prominencia znamená relatívnu výšku oproti predošlej navštívenej doline. Izolácia vyčíslňuje vzdialenosť k najbližšiemu skoršiemu vrcholu. Podobný algoritmus už existuje v literatúre [18], avšak nižšie prezentovaný pseudokód je oproti nemu zjednodušený a doplnený o požadované tolerancie.

Algoritmus 3 Algoritmus horského turistu

```
1: function FIND_PEAKS_HILL_WALKER(y, tolerance, hole, prominence,  
   isolation)  
2:   peaks  $\leftarrow$  []  
3:   i_change  $\leftarrow$  0  
4:   y_valley  $\leftarrow$  0  
5:   possible_change  $\leftarrow$  false  
6:   uphill  $\leftarrow$  (y[1] - y[0])  $\geq$  0  
7:   for i  $\leftarrow$  1 to length(y) do  
8:     y_step  $\leftarrow$  y[i] - y[i - 1]  
9:     slope  $\leftarrow$  y_step  $\geq$  0  
10:    if possible_change = false and uphill  $\neq$  slope then  
11:      possible_change  $\leftarrow$  true ▷ Označenie potenciálneho extrému  
12:      i_change  $\leftarrow$  i - 1  
13:    else if possible_change = true and uphill = slope then  
14:      possible_change  $\leftarrow$  false ▷ Potenciálny extrém bol zachvením  
15:    end if  
16:    if (possible_change = true  
17:      and uphill  $\neq$  slope  
18:      and |i - i_change| > hole  
19:      and |y[i] - y[i_change] > tolerance) then  
20:      possible_change  $\leftarrow$  False ▷ Významný lokálny extrém potvrdený  
21:      prev_uphill  $\leftarrow$  uphill  
22:      uphill  $\leftarrow$  slope  
23:      if prev_uphill = false and uphill = true then  
24:        y_valley  $\leftarrow$  y[i_change] ▷ Nájdené údolie  
25:      else if (prev_uphill = true  
26:        and uphill = false  
27:        and |y[i - hole] - y_valley| > prominence)  
28:        and |y[i - hole] - y[last(peaks)] > isolation) then  
29:          y_peak  $\leftarrow$  y[i_change] ▷ Skutočný vrchol identifikovaný  
30:          peaks  $\leftarrow$  peaks + [i_change]  
31:        end if  
32:      end if  
33:    end for  
34:    return peaks  
35: end function
```

2.2.5 Metriky pre binárny klasifikátor

Uviedli sme tri rozdielne rovnocenné prístupy odhalenia špičiek. Rozobrali sme algoritmus porovnávajúci susedov na obe strany, algoritmus využívajúci sklon sečníc vychádzajúc s vlastností prvej derivácie a napokon stavový automat odvolávajúci sa na sekvenčne preskúmanú topografiu krivky grafu. Spoločným rysom zmienených techník je vykonávanie binárne zaradenie pre každú vzorku, či sa sa nachádza alebo nenachádza na aktuálnej pozícii vrchol.

Rozhodnutie môže viesť k správne (P) alebo nesprávne (N) riešeniu vzhľadom na objektívnu pravdu sprostredkovanú anotovanými dátami. Keď sa kategorizácia zhoduje s realitou dostávame skupiny skutočne pozitívnych TP a skutočne negatívnych TN . V prípade, že sa klasifikátor pomýli vyjde buď chyba prvého rádu FP , kedy registrujeme neexistujúcu špičku, alebo chyba druhého rádu FN , kedy ju prehliadneme. Umiestnením počtov charakteru rozhodnutí do tabuľky vzniká matica zámen [19].

Úspešnosť klasifikačných algoritmov pre ich vzájomné porovnanie kvantifikujú viaceré metriky. Na odladenie parametrov vplyvujúcich na náchylnosť preferovať kladné alebo záporné výsledky sa vzťahuje *prevalencia* výskytu očakávaného javu: $P/(P + N)$ v samotných dátach. Snahou rozhodovania je maximalizovať senzitivitu a špecifickosť výsledkov algoritmu. *Senzitivita* (2.29) udáva koľko bodov, ktoré sú prehlásené za špičky naozaj je špičkami. *Špecifickosť* (2.30) sa zameriava na potvrdenie, aké množstvo pozorovaní nepovažovaných za špičky, nie sú nimi aj skutočne.

$$TPR = \frac{TP}{P} = \frac{TP}{TP + FN} \quad (2.29)$$

$$TNR = \frac{TN}{N} = \frac{TN}{TN + FP} \quad (2.30)$$

Presnosť určenia lokálneho extrému sa skladá z správnosti (2.31) a precíznosti (2.32), ktoré je rovnako žiaduce dosahovať čo najbližšie sto percentám, pri nízkej

chybovosti (2.33), čiže nízkeho počtu falošných poplachov.

$$PPV = \frac{TP}{TP + FP} \quad (2.31)$$

$$ACC = \frac{TP + TN}{P + N} \quad (2.32)$$

$$FPR = \frac{FP}{FP + TN} \quad (2.33)$$

Štandardným nástrojom na vyjadrenie kvality binárneho klasifikátora je *ROC krivka* zakresľujúca senzitivitu TPR vo zvislom smere voči vodorovnej chybovosti FPR . ROC vytvoríme postupným posúvaním prahu pre klasifikáciu prostredníctvom parametrov algoritmu. Použiteľný algoritmus sa vyznačuje vypuklou krivkou smerom k ľavému hornému rohu nad diagonálou, ktorá by sprevádzala počínanie náhodného rozhodovania. Dokonalá metóda pri dosahovala stopercentnú senzitivitu za nulovej chyby. Vyjadrením plochy pod ROC krivkou je miera AUC, ktorá umožňuje približné číselné porovnanie rôznych získaných kriviek [20].

2.3 Frekvenčná a časovo-frekvenčná analýza signálu

Cyklicky sa opakujúce deje v signále sú extrahované zo sekvencie vzoriek v časovej doméne transformovaným do domény frekvenčnej. Premenou dochádza k odhadu sumárnej intenzity jednotlivých rozsahov zložiek spektra, pričom rozlíšenie je podmienené vzorkovacou frekvenciou f_s a celkovým počtom meraní N (2.34) [21].

$$\Delta f = \frac{f_s}{N} \quad (2.34)$$

Kompromis potrebný urobiť pri spektrálnej analýze tkvie vo vyvážení dĺžky úseku pre časovú lokalizáciu frekvenčného obrazu, a jeho výslednej detailnosti na strane druhej. Prechod medzi časovou a frekvenčnou doménou postihuje princíp neurčitosti znamenajúci, že pri raste rozlíšenia v čase strácame rozlíšenie vo frekvenciách a naopak. O požadovanom množstve pozorovaní pre konkrétnu rozlíšiteľnosť spektra taktiež hovorí vzťah (2.34). Rozpätie frekvencií spadajúcich do diskrétného frekvenčného vedierka k sú počínajúc $k\Delta f$ po $(k + 1)\Delta f$.

2.3.1 Diskrétna fourierová a kosínusová transformácia

Diskrétna Fourierová transformácia (DFT) slúži na učenie harmonického zloženia signálu (2.35) rozkladom na súčet sínusov a kosínusov rôznych frekvencií. Zobrazuje vektor komplexných čísel y dĺžky N do vektora N frekvenčných komponentov. Na vypočítanie k -teho frekvenčného vedierka sú prvky sekvencie pozorovaní prenáso-bené zodpovedajúcim exponenciálnym členom tzv. *twiddle factor* (2.36). Inverzná transformácia sa líši iba opačným znamienkom exponenta a získané hodnoty sa zvyknú normovať delením N .

$$Y[k] = \sum_{n=0}^{N-1} x[n] \cdot W_N^{nk}; \quad k = 0, \dots, N-1 \quad (2.35)$$

$$W_N^{nk} = \exp(-i2\pi nk / N) \quad (2.36)$$

Alternatívne exponenciálny faktor vyjadruje v goniometrickom tvare ako kosínusovú reálnu časť a sínusovú imaginárnu časť:

$$W_N^{nk} = \cos(2\pi nk/N) - i \cdot \sin(2\pi nk/N) \quad (2.37)$$

Spektrálne komponenty opísané vektorom komplexných Fourierových koeficientov majú magnitúdy dané veľkosťami komplexných čísel (2.38). Pre reálne čísla je výstup z DFT zrkadlovo symetrický, čo zapríčiňuje nadbytočnosť výsledkov nad pozíciou $N/2$. Rovnako naznačuje reformulácia vety o vzorkovaní, že za vzorkovacej frekvencie f_s sú zapríčinením aliasingu v signále prítomné frekvencie do maximálnej polovice f_s . Energia nesená frekvenciou je druhou mocninou magnitúdy, ale častejšie sa objavuje reprezentácia relatívneho energetického spektra v decibeloch (2.39) [21].

$$|Y[k]| = \sqrt{\Re\{Y[k]\}^2 + \Im\{Y[k]\}^2} \quad (2.38)$$

$$Y_{dB}[k] = 20 \cdot \log_{10} \left(\frac{|Y[m]|}{\max\{|Y[m]|\}} \right) \quad (2.39)$$

Sekvencia pozorovaní vyjadrená cez súčet kosínusoid namiesto exponenciálneho faktora tvorí rodinu diskretných kosínusových transformácií (DCT). Vyznačujú sa dobrou dekoreláciu vstupu a energetickou kompresiou, čiže pomerne veľká časť cel-

kovej spektrálne energie je sústredená v málo koeficientoch [22]. Navyše oproti DFT umožňuje redukciu výpočtovej náročnosti odstránením súčinov v komplexných číslach.

Podľa charakteru obmien kosínusovej bázy rozlišujeme štyri typy DCT, z nich najvýznačnejšie sú transformácie DCT-II, ktorej inverziou je DCT-III, a DCT-IV, ktorá je inverzná sama sebe [23]. Z DCT-IV vychádza MDCT, ktorá navyše spracováva prekrývajúce sa bloky, tak že druhá polovica vzoriek pochádza z prvej polovice ďalšieho bloku. Dokopy vytvorí z $2N$ vzoriek N koeficientov. MDCT sa hojne využíva pri stratovej kompresii zvuku, pretože sa prelínaním blokom vyvaruje artefaktom na hraniciach blokov [24].

$$W_N^{nk} = \cos \left[\left(n + \frac{1}{2} \right) k \frac{\pi}{N} \right] \quad (\text{DCT-II})$$

$$W_N^{nk} = \cos \left[n \left(k + \frac{1}{2} \right) \frac{\pi}{N} \right] \quad (\text{DCT-III})$$

$$W_N^{nk} = \cos \left[\left(n + \frac{1}{2} \right) \left(k + \frac{1}{2} \right) \frac{\pi}{N} \right] \quad (\text{DCT-IV})$$

$$W_N^{nk} = \cos \left[\left(n + \frac{1}{2} + \frac{N}{2} \right) \left(k + \frac{1}{2} \right) \frac{\pi}{N} \right]; \quad n = 0, \dots, 2N - 1 \quad (\text{MDCT})$$


2.3.2 Algoritmus FFT

Priamočiarou implementáciou vzťahom na výpočet Fourierovej a kosínusovej transformácie dosiahneme časovú zložitosť rádu $\mathcal{O}(N^2)$. Aplikáciám v reálnom čase na prúdoch dát takáto výpočtová náročnosť zďaleka nepostačuje. Algoritmus rýchlej fourierovej transformácie (FFT) uplatňujúci prístup rozdeľuj a panuj zvládne zrealizovať DFT v čase $\mathcal{O}(N \log N)$.

Celkovo pozostáva z N sčítaní a $N/2$ násobení v komplexných číslach. Najbežnejšia varianta algoritmu FFT radix-2 vyžaduje, aby veľkosť vstupu bol mocninou dvojky: $N = 2^k$. Značná výpočtová úspora sa nadobúda uvažovaním s periodicitou goniometrických funkcií pri twiddle faktoroch W_N a z toho vyplývajúcich symetrií Fourierovej matice, keďže len N z N^2 prvkov matice je odlišných [25].


Podľa spôsobu dekompozície vstupného vektora sú známe dve verzie Radix-2 FFT nazvané decimácia v čase (DIT) a decimácia vo frekvencii (DIF). Decimácia v čase (obr. 2.7a) rekurzívne delí hodnoty na párne a nepárne pozície v čase, zatiaľ čo

decimácia vo frekvencii (obr. 2.7b) rozdeľuje na tieto na párne a nepárne frekvenčné vedierka [26]. Výpočet prebieha v $\log_2(n)$ deliacich fázach. Poradie prvkov vo výstupnom vektore je vždy bitovo invertované, čiže poradové číslo zapísané ako bitový reťazec má obrátené poradie. Na dosiahnutie výstupu poradí rastúcich pozícií musí byť pred spustením FFT vstup preusporiadaný [27].



Obr. 2.7: Radix-2 FFT na štyroch bodoch [26]

Základným prvkom schémy výpočtu je motýlikový diagram („butterfly”), ktorý je odlišný pre DIT (obr. 2.8a) a pre DIF verziu (obr. 2.8b). Motýlik obsahuje vynásobenie jedného z príchodzích operandov s vopred vypočítaným exponenciálnym členom W_N^j pre $j = 0, \dots, N/2 - 1$ [25], a následné prirátanie a tiež odpočítanie od druhého operandu.



Obr. 2.8: Motýlikové diagramy algoritmu FFT

Efektívnejšie na celkový počet aritmetický počet operácií oproti FFT s radixom 2 je *split-radix*, ktorý kombinuje výhody vyplývajúce z radix-4 pre nepárne členy DFT a radix-2 pre párne členy. Veľkosť vstupného vektora musí byť násobkom štyroch. Dosahuje okolo 30% zníženie počtu násobení a 10% pokles počtu sčítaní oproti radix-2 [28].

Algoritmus FFT je aplikovateľný taktiež na výpočet DCT vhodným zoradením vstupného vektora. DCT-II N -bodovej reálnej postupnosti \mathbf{x} sa odvodzuje uskutoč-

nením jej $2N$ -bodového párneho rozšírenia a vynásobenie výsledku twiddle faktorom $2W_{2N}^k$ a ponechaní reálnej časti. Na ilustráciu uvádzame prípad DCT 4-bodovej sekvencie (x_1, x_2, x_3, x_4) , ktorej párnym rozšírením \mathbf{y} je $(x_1, x_2, x_3, x_4, x_4, x_3, x_2, x_1)$. Rovnako by postačovalo vyplniť pôvodnú postupnosť nulami do dĺžky $2N$, čiže dostávame $(x_1, x_2, x_3, x_4, 0, 0, 0, 0)$. Postačuje však realizovať N -bodovú FFT sekvencie párnych alebo nepárnych prvkov z \mathbf{y} , ktoré sú vzájomným reverzom. Na základe predošlého predošlého príkladu dostaneme postupnosť (x_1, x_3, x_4, x_2) [29].

Široké použitie FFT pri spracovaní signálov sa prejavuje dostupnosťou implementácií rôznych obmien algoritmu v širokej škále programovacích jazykov a optimalizované pre konkrétne hardvérové platformy. V jazyku C stoja za zmienku knižnice: FFTW, FFTPACK, GNU Scientific Library, CMSIS DSP a Espressif DSP. Na účely analýzy údajov je FFT prítomné pre jazyk Python v balíkoch *numpy* a *scipy*, tiež napr. v jazyku R je súčasťou *stats* modulu.

2.3.3 Oknové funkcie

Oknové funkcie ováhujú vstupný vektor. Krátkodobá FT DFT implicitne predpokladá periodickosť, že časový rad dĺžky N sa opakuje cyklicky do nekonečna. Ak frekvencia sínusového vstupu nie je presným násobkom frekvenčného rozlíšenia, čiže nespadá presne do centra frekvenčného vedierka (bin), tento predpoklad nie je naplnený a DFT sa bude chovať akoby v prítomnosti nespojitosti medzi poslednou a prvou vzorkou, z dôvodu cyklického opakovania. Diskontinuita sa rozšíri naprieč spektrom prejavom Gibbsovo javu.

Oknové funkcie vyžadujú kompromis medzi šírkou výsledných špičiek v frekvenčnej doméne, presnosti v amplitúde a miera poklesu úniku spektra (spectral leakage) do ostatných frekvenčných vedierok. [30]

Dochádza k vynásobenie zdrojového signálu koeficientmi okna pre odstránenie hraničných efektov, ktoré spôsobujú/vnášajú neexistujúce periodické komponenty, na okraji okna preto znižuje úroveň na nulu. Snahou je dokonalé izolovanie frekvenčného pásma, ale pri FT dostávame sinc.

Prehľad okien - symetrické okolo stredu [21]

$$w(n) = 1, n = 0, 1, \dots, N - 1 \quad (\text{Obdĺžnikové})$$

$$w(n) = \begin{cases} \frac{n}{N/2}; n = 0, \dots, N/2 \\ 2 - \frac{n}{N/2}; n = N/2 + 1, \dots, N - 1 \end{cases} \quad (\text{Trojuholníkové})$$

$$w(n) = 1 - ((2n/N) - 1)^2 \quad (\text{Welch})$$

$$w(n) = \cos^2((2\pi n/N - \pi)/N) \quad (\text{Hann})$$

$$w(n) = 0.54 - 0.46 \cos(2\pi n/N) \quad (\text{Hamming})$$

výhodné percentá prekryvu FT, čím užšie okno tým vyžadujú väčší prekryv
Priemerovanie a prekryv: - Amplitude Flatness (AF) - Power Flatness (PF) - Overlap Correlation (OC)

Welchova metóda na zníženie šumu, spriemerovanie spektier z po sebe idúcich úsekov na zníženie rozpylu pri spektre stochastického javu.

2.3.4 Filtre s konečnou impulznou odozvou

Roziel medzi FIR a IIR, Dolná pripuť, pásmová priepuť, horná pripuť, pre ideálny filter Konvolúcia a konvolučné jadro, konvolučná veta, účel: identifikácia prítomnosti známej frekvencie v signále akcelerácie

$$y[k] = \sum_{k=0}^{N-1} x[k] \cdot h(n - k) = x[n] * h[n] \quad (2.40)$$

Prenosová funkcia - koeficienty filtra [31] s.125 + popísať, že je možné aplikovať FFT pri výpočte konvolúcie Konvolučná veta Frekvenčná odozva filtra je daná fourierovu transformáciu sinc, keď chceme fitrovať nejakú frekv. musíme aplikovať sinc kernel (maska)

$$h(n) = \frac{1}{\pi n} \cdot (\sin(\omega_2 n) - \sin(\omega_1 n)); \quad \omega = 2\pi f; \quad \text{sinc}(x) = \frac{\sin(\pi x)}{\pi x} \quad h(n) = 2f_2 \cdot \text{sinc}(2f_2 n) - 2f_1 \cdot \text{sinc}(2f_1 n)$$

Detektor obálok

⁴ ⁵ - Square-Law / Full-Wave - umocnenie dvomi (alebo absolútna hodnota) - amplifikácia faktorom 2 (zostane iba horná polovica) - decimácia 1.5 (podvzorkovanie) - dolná priepusť FIR - druhá odmocnina pre odstránenie skreslenia spôsobeného úvodným umocnením

2.4 Senzorová sieť

Nízko-energetické zariadenia komunikujúce cez odľahčené sieťové protokoly so snahou spracovania v reálnom čase a ponechaním najdôležitejších informácií dolovaním z veľkého množstva zdrojových dát. Cloud / Hmlové počítanie. Edge computing okrajový a sink (zoskupujúci) uzol [32] [33] [34]

Vlastnosti senzorovej siete

- Autokonfigurácia senzora - reakcia na zmeny v sieti a prostredia pôsobenia
- Škálovateľnosť - veľké množstvo senzorov so spoločným účelom a schopnosťou vzájomnej kooperácie a interoperability.
- Odolnosť voči chybám - v prípade pridania alebo odobratia uzla budú spojenia bez prerušenia.
- Energeticky efektívna komunikácia uzlov - s upravenými protokolmi štandardného sieťového zásobníka
 - Event-driven - stály zber dát a reakcia na náhle zmeny. posielajú údaje až po prekročení kritického prahu
 - Query-driven - zbierajú údaje iba po prijatí dopytu od používateľa
 - Time-driven - pravidelne odosielať údaje sinku. vzorkovaciu frekvenciu volí sink

[35]

Spracovanie toku informácií (IFP - Information flow processing) - nástroj na včasné spracovanie dát ako tečie z periférií do centra systému. Snahou je ukladanie

⁴<https://www.mathworks.com/help/dsp/ug/envelope-detection.html>

⁵<https://www.dsprelated.com/showarticle/938.php>

agregovaných štatistík, napr. detektor požiaru za použitia čidiel teploty a dymu nepotrebuje ukladať jednotlivé merania, lebo sú samo o sebe nepodstatné. Keď nastane varovná situácia, je potrebné aby tá obsahoval všetky údaje na lokalizáciu ohniska.

CEP - Complex event processing - spracúva toky udalosti zo zdrojov reálneho sveta na základe aplikovania aktívnych pravidiel stanovených správcami systému a upraví toky do komplexnejšieho výstupu. Pravidlá sú v tvare Event-Condition-Action (ECA).

- Udalosť - definuje zdroje ako generátory udalostí
- Podmienka - uvažuje ktorá časť udalosti bude braná do úvahy pri spracovaní, napr. môže ísť o prekročenie prahu
- Akcia - aká sada úloh má byť vykonaná pri detekcii udalosti

[36]

Súčasti senzorovej jednotky: Zberná jednotka, Výpočtová jednotka, Komunikačná jednotka, Napájacia jednotka

Obmedzenia na senzorové uzly

- Spotreba energie - energetická autonómia uzlov vo WSN umožňuje nasadzovanie zariadení do odľahlých miest pre využitie v inteligentných mestách alebo na účely ochrany prírody. Životnosť senzorovej jednotky je ohraničená kapacitou batérie.
- Dosah komunikácie - Sensory disponujú obmedzenou energiou na vysielanie a dosah je negatívne ovplyvnený silou signálu na anténe. Z toho vyplývajú aj nižšie prenosové rýchlosti.
- Výpočtový výkon a úložisko - Nízka taktovacia frekvencia procesora v megahertzoch a veľkosti pracovných pamätí v stovkách kilobajoch alebo megabajtoch.

[37]

Edge computing is a form of distributed computing

distributed computing divides a single task between multiple computers to achieve a common goal

address the same problem: proximity. Moving the computer workload closer to the consumer reduces latency, bandwidth and overhead for the centralized data center, komunikujú a koorinujú svoje aktivity výmenou / zasielaním (predávaním) správ medzi komponentami, pamäť je oddelená

Improved response time, Offline availability, Offline availability

Like the edge, fog computing moves the workload closer to the network edge, reducing data travel, latency and bandwidth. Whereas edge computing moves the process to devices, though, fog computing happens across one or more nodes in a network.

Bluetooth, BLE - IEEE 802.15.1 bezdrôtová technológia s krátkym dosahom spravidla do 10 m (0,5mW pri 0.5m, 1mW pri 1m, 2.5mW pre 10m, 10mW pre 20m) na ultra krátkych vlnách 2.402 GHz - 2.48 GHz. SDP, RFCOMM náhradou za sériové porty + L2CAP. (symetrická komunikácia) <https://www.bluetooth.com/specifications/specs/rfcomm-1-2/> Wifi - 802.11 (klient-server cez prístupový bod) - TCP/IP sieťový zásobník, CoAP, MQTT na 6LoWPAN LoRa 863-870Hz IEEE802.15.4e (Smart Mesh IP) Time Synchronized Mesh Protocol (TSMP) The TSMP includes a Time Slotted Channel Hopping (TSCH) media access layer (MAC). TSCH works by dividing time into 'slots', and providing a mechanism to map time slots to channels with a pre-assigned hopping sequence. Zigbee

3 Návrh riešenia

Požiadavky

- Najvhodnejší spôsob identifikácie špičiek vo frekvenčnej doméne
- Možnosti redukcie zberu dát za cenu redukcie energetické nároky a prenosu významných črt signálu
- Pravidlový systém na definíciu udalostí záujmu a ich spoľahlivá identifikácia

Riešenia: Pravidlá - Zbieranie vzoriek nad určitý prah - redukcia formátu, agregácia za okná, - Detekcia zmien (Zhromažďovanie oknových štatistík) - Pipeline detekcie frekvenčných zložiek: - Nastavenie vzorkovania podľa rozlíšenia - Výber osí alebo získanie magnitúdy - Odstránenie trendu (obálky) a jednosmernej zložky (odstránenie priemeru) - Oknovanie (porovnanie oknových funkcií, dĺžka okna) - Prevod do frekvenčnej domény (porovnanie algoritmov) - Priemerovanie spektrogramov - Vyhľadzovanie cez Mean filter - Priemerovanie spektrogramov Welchov metódou pre stálejší obraz spektra - Detekcia špičiek - Vygenerovanie udalostí podľa frekvenčných binov (frekvencia, čas trvania) podľa parametrov - Pozorovanie prítomnosti konkrétnych zložiek cez FIR filter - Extrahovanie rýchlosti a zrýchlenia Sumarizácia: Proces FT - Preprocessing: DC and trend removal: Oknovanie (predpočítané koeficienty okna pre N) a FFT motýliky (predpočítané twiddle factors pre N)

Literatúra

1. BROCH, Jens Trampe. *Mechanical Vibration and Shock Measurements*. 2. vyd. Brüel & Kjær, 1984. ISBN 87-87355-3-4-5.
2. MOHAMMED, Zakriya; ELFADEL, Ibrahim (Abe) M.; RASRAS, Mahmoud. Monolithic Multi Degree of Freedom (MDoF) Capacitive MEMS Accelerometers. *Micromachines*. 2018, roč. 9, č. 11. ISSN 2072-666X. Dostupné z DOI: 10.3390/mi9110602.
3. TSAI, Ming-Han; LIU, Yu-Chia; SUN, Chih-Ming; WANG, Chuanwei; CHENG, Chun-Wen; FANG, Weileun. A $400 \times 400 \mu\text{m}^2$ 3-axis CMOS-MEMS accelerometer with vertically integrated fully-differential sensing electrodes. In: *2011 16th International Solid-State Sensors, Actuators and Microsystems Conference*. 2011, s. 811–814. Dostupné z DOI: 10.1109/TRANSDUCERS.2011.5969154.
4. DADAFSHAR, Majid. *Accelerometer and Gyroscopes Sensors: Operation, Sensing, and Applications*. 2014.
5. MÜLLER, Meinard. *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*. 1st. Springer, Inc., 2015. ISBN 978-3-319-21945-5. Dostupné z DOI: 10.1007/978-3-319-21945-5.
6. *iNEMO inertial module: 3D accelerometer, 3D gyroscope, 3D magnetometer*. 2015. Č. LSM9DS1. Rev. 3.
7. *Micropower, 3-Axis, $\pm 2 \text{ g}/\pm 4 \text{ g}/\pm 8 \text{ g}$ Digital Output MEMS Accelerometer*. 2019. Č. ADXL362. Rev. F.
8. *Low Noise, Low Drift, Low Power, 3-Axis MEMS Accelerometers*. 2020. Č. ADXL356. Rev. A.

-
9. QUARTERONI, Alfio; SACCO, Riccardo; SALERI, Fausto. Numerical Mathematics. In: Springer Inc., 2000, kap. 9. Numerical Integration, s. 371–398. ISBN 0-387-98959-5.
 10. YANG, Yanli; ZHAO, Yanfei; KANG, Dali. Integration on acceleration signals by adjusting with envelopes. *Journal of Measurements in Engineering*, 2016, roč. 4, s. 117–121.
 11. MUTHUKRISHNAN, S. Data Streams: Algorithms and Applications. *Foundations and Trends in Theoretical Computer Science*. 2005, roč. 1, č. 2, s. 117–236. ISSN 1551-305X. Dostupné z DOI: 10.1561/04000000002.
 12. PAJUREK, Tomáš. *Online Anomaly Detection in Time-Series*. Fakulta informačních technologií, České vysoké učení technické v Praze, 2018. Dostupné tiež z: <https://dspace.cvut.cz/bitstream/handle/10467/76417/F8-DP-2018-Pajurek-Tomas-thesis.pdf>. Dipl. pr.
 13. NIELSEN, Aileen. *Practical Time Series Analysis: Prediction with Statistics and Machine Learning*. O'Reilly Media, 2019. ISBN 978-1-492-04165-8.
 14. NEUBAUER, Jiří; SEDLÁČEK, Marek; KŘÍŽ, Oldřich. *Základy statistiky - Aplikace v technických a ekonomických oborech*. 1. vyd. Grada Publishing, a.s., 2012. ISBN 978-80-247-4273-1.
 15. KNUTH, Donald E. The Art of Computer Programming. In: 2. vyd. Addison-Wesley, 1981, zv. 2, kap. 4.2.2, s. 216. ISBN 0-201-03822-6.
 16. SCHNEIDER, Roger. Survey of Peaks/Valleys identification in Time Series. 2011. Department of Informatics, University of Zürich.
 17. YANG, Chao; HE, Zengyou; YU, Weichuan. Comparison of public peak detection algorithms for MALDI mass spectrometry data analysis. *BMC bioinformatics*. 2009, roč. 10, s. 4. Dostupné z DOI: 10.1186/1471-2105-10-4.
 18. ARGÜELLO-PRADA, Erick Javier. The mountaineer's method for peak detection in photoplethysmographic signals. *Revista Facultad de Ingeniería Universidad de Antioquia*. 2019, č. 90, s. 42–50. Dostupné z DOI: 10.17533/udea.redin.n90a06.

19. RASCHKA, Sebastian. An Overview of General Performance Metrics of Binary Classifier Systems. *CoRR*. 2014, roč. abs/1410.5330. Dostupné z arXiv: 1410.5330.
20. FAWCETT, Tom. An introduction to ROC analysis. *Pattern Recognition Letters*. 2006, roč. 27, č. 8, s. 861–874. ISSN 0167-8655. Dostupné z DOI: <https://doi.org/10.1016/j.patrec.2005.10.010>. ROC Analysis in Pattern Recognition.
21. LYONS, Richard G. *Understanding Digital Signal Processing*. 3. vyd. Pearson Education, Inc., 2011. ISBN 978-0-13-702741-5.
22. KHAYAM, Syed Ali. The Discrete Cosine Transform (DCT): Theory and Application. *Course Notes, Department of Electrical & Computer Engineering*. 2003.
23. STRANG, Gilbert. The Discrete Cosine Transform. *SIAM Rev.* 1999, roč. 41, č. 1, s. 135–147. ISSN 0036-1445. Dostupné z DOI: 10.1137/S0036144598336745.
24. SHAO, Xuancheng; JOHNSON, Steven G. Type-IV DCT, DST, and MDCT algorithms with reduced numbers of arithmetic operations. *CoRR*. 2007, roč. abs/0708.4399. Dostupné tiež z: <http://arxiv.org/abs/0708.4399>.
25. CHU, Eleanor; GEORGE, Alan. *Inside the FFT Blackbox: Serial and Parallel Fast Fourier Transform Algorithms*. CRC Press LLC, 2000. Computational Mathematics. ISBN 0-8493-0270-6.
26. KUMAR, G Ganesh; SAHOO, Subhendu; MEHER, P.K. 50 Years of FFT Algorithms and Applications. *Circuits, Systems, and Signal Processing*. 2019, roč. 38. Dostupné z DOI: 10.1007/s00034-019-01136-8.
27. ŠIKUDOVÁ, Elena; ČERNEKOVÁ, Zuzana; BENEŠOVÁ, Wanda; HALADOVÁ, Zuzana; KUČEROVÁ, Júlia. Počítačové videnie. Detekcia a rozpoznávanie objektov. In: 1. vyd. Wikina, 2011, kap. 1.3.3. Rýchla Fourierova transformácia, s. 17–21. ISBN 978-80-87925-06-5.
28. DUHAMEL, P.; HOLLMANN, Henk. ‘Split radix’ FFT algorithm. *Electronics Letters*. 1984, roč. 20, s. 14–16. Dostupné z DOI: 10.1049/e1:19840012.

-
29. MAKHOUL, J. A fast cosine transform in one and two dimensions. *IEEE Transactions on Acoustics, Speech, and Signal Processing*. 1980, roč. 28, č. 1, s. 27–34. Dostupné z DOI: 10.1109/TASSP.1980.1163351.
 30. HEINZEL, G.; RÜDIGER, A.; SCHILLING, R. Spectrum and spectral density estimation by the Discrete Fourier transform (DFT), including a comprehensive list of window functions and some new at-top windows. In: 2002.
 31. PRANDONI, Paolo; VETTERLI, Martin. *Signal Processing for Communications*. EPFL Press, 2008. ISBN 978-2-940222-20-9.
 32. MAGESH, S.; INDUMATHI, J.; S, Radha RamMohan.; R, Niveditha V.; PRABHA, P. Shanmuga. Concepts and Contributions of Edge Computing in Internet of Things (IoT): A Survey. In: 2020, zv. 7, s. 146–156. Č. 5. Dostupné z DOI: 10.22247/ijcna/2020/203914.
 33. SHI, Weisong; CAO, Jie; ZHANG, Quan; LI, Youhuizi; XU, Lanyu. Edge Computing: Vision and Challenges. *IEEE Internet of Things Journal*. 2016, roč. 3, č. 5, s. 637–646. Dostupné z DOI: 10.1109/JIOT.2016.2579198.
 34. CAO, Keyan; LIU, Yefan; MENG, Gongjie; SUN, Qimeng. An Overview on Edge Computing Research. *IEEE Access*. 2020, roč. PP, s. 1–1. Dostupné z DOI: 10.1109/ACCESS.2020.2991734.
 35. MATIN, M.A.; ISLAM, M.M. Overview of Wireless Sensor Network. In: MATIN, Mohammad A. (ed.). *Wireless Sensor Networks*. IntechOpen, 2012, kap. 1, s. 1–22. ISBN 978-953-51-0735-4. Dostupné z DOI: 10.5772/49376.
 36. CUGOLA, Gianpaolo; MARGARA, Alessandro. Processing Flows of Information: From Data Stream to Complex Event Processing. *ACM Computing Surveys*. 2012, roč. 44, č. 3. ISSN 0360-0300. Dostupné z DOI: 10.1145/2187671.2187677.
 37. DJEDOUBOUM, Asside; ARI, Ado; GUEROUI, Abdelhak; MOHAMADOU, Alidou; ALIOUAT, Zibouda. Big Data Collection in Large-Scale Wireless Sensor Networks. *Sensors*. 2018, roč. 18. Dostupné z DOI: 10.3390/s18124474.