

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-5212-102927

Miroslav Hájek

Spracovanie dát generovaných senzorovou IoT sieťou

Priebežná správa o riešení BP1

Vedúci práce: Ing. Marcel Baláž, PhD.

December 2021

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-5212-102927

Miroslav Hájek

Spracovanie dát generovaných senzorovou IoT sieťou

Priebežná správa o riešení BP1

Študijný program: Informatika

Študijný odbor: Informatika

Miesto vypracovania: Ústav počítačového inžinierstva a aplikovanej informatiky

Vedúci práce: Ing. Marcel Baláž, PhD.

Pedagogický vedúci: Ing. Jakub Findura

December 2021



ZADANIE BAKALÁRSKEJ PRÁCE

Študent: **Miroslav Hájek**
ID študenta: 102927
Študijný program: informatika
Študijný odbor: informatika
Vedúci práce: Ing. Marcel Baláž, PhD.
Vedúci pracoviska: Ing. Katarína Jelemenská, PhD.
Pedagogický vedúci práce: Ing. Jakub Findura

Názov práce: **Spracovanie dát generovaných senzorovou IoT sieťou**

Jazyk, v ktorom sa práca vypracuje: slovenský jazyk

Špecifikácia zadania:

Senzorové IoT siete sa stali bežnou súčasťou rôznych priemyselných procesov. Ich primárnou úlohou je zbieranie rôznorodých dát z prostredia, ich ukladanie a vyhodnocovanie v reálnom čase. Analyzovanie a vyhodnocovanie dát pri nepredržitom monitorovaní už len z malého množstva senzorov predstavuje veľkú výzvu. Sensory produkujú veľké množstvo dát a anomálie nemusia byť na prvý pohľad detegovateľné. Cieľom projektu je analyzovať dáta zachytené senzorovou sieťou. Analyzovať algoritmy na ich ukladanie a spracovanie. Analyzujte jednotlivé úrovne senzorovej siete a identifikujte miesta, kde by sa dali dáta čiastočne spracovať. Na základe analýzy navrhnete spôsob ukladania a spracovania dát, prípadne optimalizáciu toku dát pre existujúcu senzorovú sieť. Vaše riešenie implementujte a otestujte jeho funkčnosť.

Rozsah práce: 40

Termín odovzdania bakalárskej práce: 16. 05. 2022
Dátum schválenia zadania bakalárskej práce: 23. 11. 2021
Zadanie bakalárskej práce schválil: doc. Ing. Valentino Vranič, PhD. – garant študijného programu

Anotácia

Slovenská technická univerzita v Bratislave

Fakulta informatiky a informačných technológií

Študijný program: Informatika

Autor: Miroslav Hájek

Priebežná správa o riešení BP1: Spracovanie dát generovaných senzorovou IoT sieťou

Vedúci bakalárskej práce: Ing. Marcel Baláž, PhD.

Pedagogický vedúci: Ing. Jakub Findura

December 2021

V bakalárskej práci sa zameriavame na spôsoby spracovania signálov z vibrácií pri preprave, zachytených senzormi akcelerácie. Zámerom je extrakcia črt záujmu z prúdu vzoriek do udalostí, čím sa redukovujú vymieňané dáta v senzorovej sieti. Analytická časť sa venuje fyzikálnemu opisu a číslicovému meraniu zrýchlenia s MEMS akcelerometrom, z ktorého je možné získať ostatné kinematické veličiny.

V časovej doméne nahliadame na sledovaný dej ako stochastický proces vyjadriteľný metrikami deskriptívnej štatistiky. Významné okamihy sa prejavujú náhlou zmenou oproti predošlému správaniu alebo nadprahovou úrovňou, čo sa zachytáva algoritmami na detekciu špičiek, ktoré predstavujú formu binárneho klasifikátora. Vibrácie obsahujú rôzne frekvenčné zložky separovateľné Fourierovou a kosínusovou transformáciou algoritmom rýchlej Fourierovej transformácie vo viacerých obmenách za aplikovania oknových funkcií.

Spomenuté sú tiež filtre s konečnou impulznou odozvou zohrávajúce úlohu pri úprave zdrojového signálu pred ďalšími stupňami spracovania. Prihliadame na obmedzenia vyplývajúce s nasadenia riešenia na zariadenia Internetu vecí v kontexte Edge computing architektúry.

Annotation

Slovak University of Technology Bratislava

Faculty of Informatics and Information Technologies

Degree course:	Informatics
Author:	Miroslav Hájek
Bachelor's Thesis:	Data Processing for Sensor IoT Network
Supervisor:	Dr. Marcel Baláž
Departmental advisor:	Jakub Findura

2021, December

In the bachelor thesis we focus on signal processing of vibrations during transport, captured using acceleration sensors. The intention is to extract features of interest from the stream of samples into events, thereby reducing data exchange in the sensor network. The analytical part deals with the physical description of acceleration and its digital measurement with the MEMS accelerometer, from which it is possible to obtain other kinematic quantities.

In the time domain, we look at the observed phenomenon as a stochastic process expressed by various descriptive statistics. Significant moments are manifested by a sudden change from the previous behavior or levels above the threshold noticed by peak detection algorithms, which are a form of binary classifier. The vibrations contain different frequency components separable by Fourier and cosine transform by the Fast Fourier transform algorithm in several variants with the application of window functions.

Finite impulse response filters are also mentioned as playing a role in adjusting the source signal before the next stages of the pipeline. We take into account the limitations of deployment on the Internet of Things devices in the context of the Edge computing architecture.

Obsah

1	Úvod	1
2	Analýza	3
2.1	Monitorovanie vibrácií a šoku	3
2.1.1	Meranie fyzikálnej veličiny akcelerácie	3
2.1.2	MEMS kapacitný akcelerometer	4
2.1.3	Analógovo-digitálny prevodník	6
2.1.4	Vlastnosti bežných akcelerometrov	7
2.1.5	Odvodzovanie rýchlosti a dráhy zo zrýchlenia	8
2.1.6	Numerická kvadratura	9
2.2	Metódy analýzy signálu v časovej doméne	10
2.2.1	Prúdové algoritmy	11
2.2.2	Posuvné a rozširujúce sa okná	11
2.2.3	Číselné charakteristiky štatistického rozdelenia	12
2.2.4	Algoritmy na rozpoznávanie špičiek	15
2.2.5	Metriky pre binárny klasifikátor	20
2.3	Frekvenčná a časovo-frekvenčná analýza signálu	21
2.3.1	Diskrétna fourierová a kosínusová transformácia	22
2.3.2	Algoritmus FFT	23
2.3.3	Oknové funkcie	25
2.3.4	Filtre s konečnou impulznou odozvou	27
2.4	Senzorová sieť	29
3	Návrh riešenia	33
A	Harmonogram práce	

Zoznam obrázkov

2.1	Model oscilujúceho systému s pružinou a tlmičom	3
2.2	Mikroštruktúra 3DOF MEMS kapacitného akcelerometra [3]	5
2.3	Digitalizácia signálu v analógovo-digitálnom prevodníku [5]	7
2.4	Porovnanie pravidiel numerickej integrácie	10
2.5	Dopad šikmosti a špicatosti na histogram distribúcie	14
2.6	Topografia priebehu signálu	18
2.7	Radix-2 FFT na štyroch bodoch [28]	24
2.8	Motýlikové diagramy algoritmu FFT	25
2.9	Tvar oknových funkcií s dĺžkou $N = 31$	27
2.10	Bloková schéma FIR filtra rádu k	28
2.11	Prvky architektúry Edge computing [37]	31
3.1	Diagram aktivít navrhovaného systému na spracovanie dát zo senzora	34

Zoznam rovníc

2.0	Fyzikálny model oscilujúceho systému s pružinou a tlmičom	4
2.1	Newtonov zákon sily	4
2.2	Magnitúda vektora akcelerácie	4
2.3	Nyquist-Shannonova veta o vzorkovaní	6
2.4	Konverzia merania na akceleráciu podľa rozlíšenia A/D prevodníka	7
2.5	Prevod A/D prevodníkom u akcelerometra s rozsahom v mg/LSB	7
2.6	Kinematické rovnice pre polohu, rýchlosť, zrýchlenie a rýv	8
2.7	Rýchlosť a poloha cez integrál akcelerácie	9

2.9	Pravidlá numerickej kvadratury: obdĺžnikové, lichobežníkové, Simpsonovo	9
2.12	Amplitúda špička-špička	12
2.13	Efektívna amplitúda RMS	12
2.14	Výberový priemer alebo amplitúda jednosmernej zložky	12
2.15	Výberové miery rozptýlenosti: rozptyl, smerodajná odchýlka, MAD, IQR	13
2.19	Welfordov algoritmus na výpočet výberového rozptylu	14
2.22	Závislosť dvoch veličín cez kovarianciu a koreláciu	15
2.24	Lokálne extrémny funkcie	15
2.26	Detekcia špičiek prahovou úrovňou	16
2.27	Význačnosť vrchola spomedzi susedov	16
2.28	Metriky klasifikátora: senzitivita a špecifickosť	21
2.30	Metriky klasifikátora: správnosť, precíznosť, chybovosť	21
2.33	Rozlíšenie vo frekvenčnej domény podľa vzorkovania	21
2.34	Diskrétna Fourierová transformácia	22
2.36	Exponenciálny faktor pre DFT v goniometrickom tvare	22
2.37	Magnitúdové spektrum absolútne a relatívne v decibeloch	23
2.39	Kosínusové transformácie: DCT-II, DCT-III, DCT-IV, MDCT	23
2.39	Oknové funkcie: obdĺžnik, Bartlett, Hann, Hamming, Blackman	26
2.44	Výpočet FIR filtra cez konvolúciu	28
2.45	Koeficienty FIR filtra pre dolnú, hornú a pásmovú priepusť	28

1 Úvod

Inteligentné senzorové systémy zariadení Internetu vecí (IoT) zaznamenávajú obrovskú kvantitu údajov z prostredia, kde pôsobia. Prúdy vzoriek meraných veličín majú sami o sebe nízku informačnú hodnotu a zbytočne zaťažujú prenosové pásmo komunikačných kanálov a kapacitu úložísk. Monitorovanie širokého rozsahu kladie požiadavky na čo najmenšie výrobné náklady senzorových jednotiek a dlhodobú výdrž pri napájaní z batérií za minimálnej údržby. Existuje preto potreba získané dáta spracovať do istej miery už v blízkosti ich zdroja, aby došlo k efektívnemu využitiu dostupných prostriedkov.

Zameriame sa na sledovanie vibrácií a dolovanie črt záujmu z nich. Význam a dôležitosť sledovania vibrácií spočíva v ich výskyte u každého mechanického zariadenia pohybom jednotlivých súčiastok a trením v ložiskách. Ich nadmerná prítomnosť býva spôsobená opotrebením dielov stroja a dôsledkom technických defektov. Ďalšou oblasťou hojnej prítomnosti vibrácií je preprava osôb alebo tovaru, kde ich zapríčiňujú nerovnosti povrchu vozovky alebo koľaje v bode styku s kolesami, či aparát ovplyvňujúci pohyb vozidla, čiže spaľovací alebo elektrický motor a brzdomý systém.

Detekciou nežiaducich vibrácií v preprave sa dokáže zabezpečiť bezpečnosť pasažierov včasnou výmenou súčiastky, ktorá by ovplyvnila prevádzkyschopnosť v kritických momentoch, a predísť nenávratnému poškodeniu krehkých materiálov, znehodnoteniu reaktívnych substancií, či ich aktivácii v prípade výbušnín a pyrotechniky. Vibrácie sú súčasťou nebezpečných prírodných úkazov a ich správna identifikácia má za následok varovania pre evakuáciu obyvateľstva v oblasti postihnutej zemetrasením, či erupciou sopky, vedúcimi k ohrozenia zdravia osôb a poškodenia majetku.

V analýze problematiky sa zapodievame fyzikálnym modelom opisom vibrácií, od čoho sa odvíja metodika ich snímania akcelerometrami typu MEMS a prevod

do číslicovej podoby analógovo-digitálnym prevodníkom. Na spracovanie priebehu signálu zrýchlenia sa pozrieme z troch hlavných hľadísk.

Integračné metódy umožňujú nadobudnúť odhad o relatívnej rýchlosti a polohe z akcelerácie. Na postupnosti pozorovaní je možné nahliadať tiež v časovej doméne zužitkovaním základných agregáčnych a korelačných štatistík na odhalenie náhlych zmien. Významne vyčlenené úrovne sú detegované algoritmami na detekciu špičiek za rozličnej úspešnosti. Metódami transformácie do frekvenčnej oblasti sa objavujú periodicky prítomné zložky, kde je opäť žiaduce upozorniť na momentálne prevládajúci spektrálny obsah. Modely operujúce s vibračnými dátami by mali nasadené na IoT zariadenie kladúce svoje špecifické nároky a obmedzenia.

Navrhujeme kroky postupov na generovanie významných udalostí z nameranej akcelerácie. Po vyhodnotení úspešnosti modelov v vlastných dátových sadách bude zámerom implementácia konfigurovateľnej senzorovej IoT jednotky.


2 Analýza

2.1 Monitorovanie vibrácií a šoku

Vibrácie sú periodickým kmitaním hmoty okolo rovnovážnej polohy vznikajúce excitáciou látky, ktorej je dodaná potenciálna energia, a zo zákona zachovania energie je následne premieňaná na kinetickú energiu. V realite dochádza pôsobením trenia k útlmu voľného oscilačného pohybu s časom a pohybová energia sa uvoľňuje v podobe tepelnej alebo akustickej emisie do okolitého prostredia. Častejšie ako presné harmonické kmity sú pozorované náhodné vibrácie, ktorých vývoj nevieme dopredu predvídať. Naproti tomu šok, alebo aj prechodový jav, je náhle uvoľnenie kinetickej energie krátkeho trvania oproti prirodzenej oscilácii systému.

2.1.1 Meranie fyzikálnej veličiny akcelerácie

Pohyb mechanického systému vystaveného vonkajším silám sa nazýva odozva, ktorej správanie opisuje zjednodušený model s jedným stupňom voľnosti (1DOF) kmitajúceho telesa s pružinou a tlmičom [1].



Obr. 2.1: Model oscilujúceho systému s pružinou a tlmičom

Pri pôsobení vonkajšej sily F na hmotu upevnenú na pružine vznikajú nútené vibrácie, ktoré ju vychýľujú z rovnovážnej polohy. Uvedená sila je charakterizovaná druhým Newtonovým zákonom v tvare $F = ma$, kde m je hmotnosť telesa a a predstavuje zrýchlenie. V protismere pôsobí sila vyvolaná pružinou $F_s = -kx$ a tlmiacim členom $F_d = -cv$, kde k je tuhosť pružiny ovplynená jej konštrukciou, c je tlmiaci koeficient, x je vychýlenie z rovnovážneho stavu, a v rýchlosť vychýlenia.

Obmedzením telesa viazaním na pevnú podložku dochádza pri zanedbaní deformácie k takmer zaručenému návratu do rovnovážnej polohy a to nám umožňuje merať intenzitu vibrácií cez zrýchlenie ťažidla. Výslednú silu v jednom smere získame sčítaním síl podieľajúcich sa na dynamike telesa.

$$F(t) = ma - cv - kx \quad (2.1)$$

Pri použití trojosového akcelerometra, kedy sú evidované všetky tri priestorové súradnice časovo-premennej akcelerácie dostávame nasledujúcu rovnicu vo vektorovom tvare:

$$\vec{a}(t) = \frac{\vec{F}(t)}{m} \quad (2.2)$$


Magnitúda akcelerácie s tromi súradnicami je daná L_2 normou vektora $\vec{a} = (a_x, a_y, a_z)$:

$$|a| = \sqrt{a_x^2 + a_y^2 + a_z^2} \quad (2.3)$$

2.1.2 MEMS kapacitný akcelerometer

Bežné inerciálne senzory na meranie zrýchlenia priamočiareho, ale aj rotačného pohybu (gyroskop), sa vyrábajú technológiou *MEMS* – *mikromechanický systém*, kedy je celé zariadenie vrátane všetkých mechanických súčastí umiestnené na kremík procesom mikrovýroby vo viacerých vrstvách. Sila spôsobujúca zrýchlenie je potom meraná vychýlením vstavanej odpruženej hmoty vzhľadom na pevné elektródy, ktoré môžu byť usporiadané jednostranne alebo ako diferenčný pár [2].

Pri diferenčnom páre spôsobí pohyb doštičky ťažidla medzi elektródami zmenu kapacít a ich rozdielom je možné zistiť aplikovanú silu a cez uvedený vzťah zrých-



Obr. 2.2: Mikroštruktúra 3DOF MEMS kapacitného akcelerometra [3]

lenie. Na zvýšenie celkovej kapacity sa používa viacero párov elektród zapojených paralelne. Pred prevodom na číslicový signál musí napäťová úroveň zo senzora prejsť úpravou zahŕňajúcou nábojovocitlivý predzosilňovač, osovú demoduláciu a anti-aliasingové filtrovanie.

Viacosové akcelerometre vyžadujú viaceré opísané štruktúry orientované kolmo na seba, podľa obr. 2.2, s ohľadom na počet vyžadovaných stupňov voľnosti, pričom v skutočných senzoroach vždy existuje aspoň minimálna závislosť medzi osami rádovo najviac v jednotkách percent. Teplota ovplyvňuje citlivosť MEMS akcelerometrov len nepatrne v stotinách percenta na stupeň Celzia.

Akcelerometre sa odlišujú v niekoľkých dôležitých vlastnostiach, ktoré zvyknú byť nastaviteľné vo výrobcom stanovenom rozsahu prípustných hodnôt s príslušnými toleranciami [4].

Citlivosť stanovuje najmenšiu rozlíšiteľnú zmenu v odčítanom napätí ku zmene externého pohybu respektíve zrýchlenia. Uvádza sa v jednotkách mV/g (milivolt na tiažové zrýchlenie) pri analógovom výstupe, alebo mg/LSB (mili-g na najmenej významový bit) pri senzoroach so vstavaným analógovo-digitálnym prevodníkom. Jednotka mg/LSB vyjadruje o koľko sa zmení zrýchlenie keď zvýšime alebo ponížime binárne číslo na výstupe o jedna. Niekedy sa namiesto citlivosti uvádza mierka pre presnosť ako prevrátená hodnota citlivosti v LSB/g. Tiažové zrýchlenie g sa mierne líši podľa zemepisnej šírky, ale prepočet na jednotky SI platí: $1\text{ g} = 9.80665\text{ m/s}^2$.

Dynamický rozsah sa uvádza v tiažovom zrýchlení g . Hovorí o najmenšej a najväčšej rozlíšiteľnej hodnote zrýchlenia nad úrovňou ktorej už dochádza k skresleniu signálu orezaním špičiek. Nevyhnutnými drobnými nepresnosťami výroby mikro-mechaniky vzniká *zero-g napätie* popisujúce odchýlku skutočného od ideálneho výstupu, keď na sústavu nepôsobí žiadne zrýchlenie. Za ideálnych okolností bez pohybu na vodorovnom povrchu namerajú osi x a y zrýchlenie $0g$, zatiaľčo na z pôsobí $1g$. Očakávaním je nulová hodnota výstupného napätia a tým aj výstupného registra.

Šírka pásma senzora v Hz predurčuje rozsah frekvencie vibrácií, ktoré je možné zachytiť. Podmienená je zvolenou početnosťou čítania akcelerácie za sekundu, čiže vzorkovacou frekvenciou. Stanovuje sa tiež nastaviteľným parameterom *ODR* (Output Data Rate) - výstupný dátový tok, pričom šírka pásma je spravidla polovicou ODR. *Frekvenčná odozva* senzora potom hovorí o koľko sa v rámci tolerancie odlišuje skutočná citlivosť od referenčnej pre zodpovedajúcu frekvenciu vibrácií.


Na meranie zrýchlenia má vplyv šum zapríčinený Brownovým pohybom a nedokonalosťou skutočných materiálov v štruktúre akcelerometra. Intenzita šumu rastie inverznou odmocninou so šírkou pásma, čiže s častejším meraním získavame menšiu presnosť. Hardvér akcelerometra umožňuje vzorkovať amplitúdy až nad stanovený prah generovaním prerušenia, čím sa efektívne odstránia nevýznamné fluktuácie, za predpokladu dostatočného odstupu signálu od šumu ($SNR = P_{signal}/P_{noise}$).

2.1.3 Analógovo-digitálny prevodník

Spojitú napäťovú úroveň transformuje analógovo-digitálny (A/D) prevodník pre spracovanie digitálnym systémom do množiny diskretných hodnôt. Vstupný signál najprv prechádza fázou vzorkovania, kedy sa vzorky zaznamenávajú v pravidelných intervaloch. Počet vzoriek odčítaných za sekundu je vyjadrený vzorkovacou frekvenciou f_s v Hz. Časový rozdiel medzi vzorkami, nazývaný perióda vzorkovania, je prevrátenou hodnotou vzorkovacej frekvencie $T_s = 1/f_s$. Pre presnú rekonštrukciu pásmovo obmedzeného signálu v hraniciach $[-f_{max}; f_{max}]$ je nevyhnuté podľa *Nyquist-Shannonovej vety* o vzorkovaní, aby vzorkovacia frekvencia bola najmenej dvojnásobkom maximálnej frekvencie snímaného signálu:

$$f_s \geq 2 \cdot f_{max} \quad (2.4)$$

V procese kvantovania je každej vzorke je následne priradená diskretná hodnota s konečným počtom bitov, ktorá je najbližšia možná ku skutočnej hladine analógového vstupu. Dochádza pritom k istému zaokrúhľovaniu z dôvodu nepresnosti vyjadrenia spojitý domény amplitúd diskretným číslom, čo zapríčiňuje kvantizačný šum. Ten predstavuje najviac polovicu z maximálnej rozlíšiteľnej zmeny signálu.



Obr. 2.3: Digitalizácia signálu v analógovo-digitálnom prevodníku [5]

Pri n bitoch je k dispozícii 2^n rozličných čísel. Kódovaním v dvojkovom doplnku pre zachytenie záporných hodnôt sa uvažuje s intervalom $[-2^{\frac{n}{2}}; 2^{\frac{n}{2}} - 1]$. Digitálna hodnota v dvojkovom doplnku získaná konverziou \hat{x} je prepočítaná na štandardné fyzikálne jednotky pre zrýchlenie, a v m/s^2 . R predstavuje nastavený dynamický rozsah v jednotkách g a n je počet bitov A/D prevodníka:

$$a = \hat{x} \cdot ((R \cdot g) / 2^{n/2}) \quad (2.5)$$

Presnejší prevod dosiahneme využitím deklarovanej citlivosti senzora pri danom dynamickom rozsahu S_R udávaného v mg/LSB .

$$a = \hat{x} \cdot (S_R \cdot g) / 1000 \quad (2.6)$$

2.1.4 Vlastnosti bežných akcelerometrov

Na ilustráciu uvádzame parametre zvolených najrozšírenejších typov akcelerometrov. Akcelerometer LSM9DS1 [6] umožňuje cez zbernicu SPI alebo I²C zvoliť zo

štyroch dynamických rozsahov, pričom každé rozpätie sa vyznačuje svojou citlivosťou. Zvolením menšieho dynamického rozsahu zvýšime citlivosť. LSM9DS1 funguje pri rozsahoch $\pm 2g$, $\pm 4g$ a $\pm 8g$ a $\pm 16g$, postupne s citlivosťami 0.061 mg/LSB, 0.122 mg/LSB, 0.244 mg/LSB, 0.732 mg/LSB. Výstupný dátový tok (ODR) je možné nastaviť na 10Hz, 50Hz, 119Hz, 238Hz, 476Hz a najvyššie na 952 Hz. Navzorkované hodnoty sú ukladané do 16-bitového výstupného registra v dvojkovom doplnku.

Nízkoenergetický 3DOF MEMS akcelerometer ADXL362 [7] so spotrebou $2\mu A$ pri 100Hz disponuje rozsahmi $\pm 2g$, $\pm 4g$ a $\pm 8g$ s citlivosťami 1, 2 a 4 mg/LSB. Dostupné vzorkovacie frekvencie 12-bitového A/D prevodníka sú 12.5 – 400Hz v 8 krokoch vždy po násobkoch predošlého kroku. Pre rýchlejšie čítanie pri nižšom rozlíšení dokáže senzor zakódovať dáta do 8-bitového registra.

Vyrábajú sa tiež akcelerometre s väčšími dynamickými rozsahmi a nízkym šumom, ide napríklad o ADXL356 a ADXL357 [8] so škálami $\pm 10g$, $\pm 20g$ a $\pm 40g$ s citlivosťou 0,019 mg/LSB po 0,078 mg/LSB a rozlíšením A/D prevodníka 20 bitov pri ODR 4 – 4000Hz. ADXL357 ponúka priamo analógové výstupy s citlivosťou 20 – 80 mV/g pri napájaní 3.3 V.

2.1.5 Odvodzovanie rýchlosti a dráhy zo zrýchlenia

Meranie akcelerácie umožňuje zároveň nepriamo získať ďalšie údaje o celkovom pohybe v priestore ako aj spôsobenom vibráciami. Zrýchlenie \vec{a} je definované ako časová zmena rýchlosti \vec{v} , zatiaľ čo rýchlosť je časovou zmenou polohy \vec{r} . Na pozorovanie prechodových javov alebo na vyjadrenie miery plynulosti pohybu slúži ryv \vec{j} , ktorý je časovou zmenou akcelerácie. Pokiaľ nie sú známe počiatočné podmienky v okamihu začiatku snímania akcelerácie, budú hodnoty veličín relatívne vzhľadom na štart záznamu. Kinematika v diskretnom čase je potom opísaná nasledujúci rovnicami, kde Δ je operátor diferencie $\Delta t = t(i) - t(i - 1)$:

$$\vec{v} = \frac{\Delta \vec{r}}{\Delta t}; \quad \vec{a} = \frac{\Delta \vec{v}}{\Delta t}; \quad \vec{j} = \frac{\Delta \vec{a}}{\Delta t} \quad (2.7)$$

Vyjadrenie neznámych premenných vzhľadom na akceleráciu spočíva v prenásobení rovníc členom Δt , čím sa získajú vzťahy pre okamžitú dráhu a okamžitú rýchlosť. Spočítaním čiastkových okamžitých rýchlostí na intervale dostaneme cel-

kovú rýchlosť a rovnaký úsudok platí pre polohu. V spojitom čase, keď by vzorkovacia perióda bola nekonečne krátka, dochádza naproti tomu k integrovaniu funkcie akcelerácie. Dostávame, že rýchlosť je integrálom zrýchlenia a poloha je dvojným integrálom zrýchlenia:

$$\vec{v}(t) = \vec{a}_0 + \int \vec{a}(t) dt \quad (2.8)$$

$$\vec{r}(t) = \vec{r}_0 + \vec{v}_0 t + \iint \vec{a}(t) dt \quad (2.9)$$

2.1.6 Numerická kvadratura


Približný výpočet určitého integrálu funkcie akcelerácie je založený na geometrickej interpretácii integrálu ako plochy pod krivkou. Vtedy sa jedná o problém numerickej kvadratury navrhujúci nahradenie pôvodného integrandu interpolačným polynómom [9]. Rád polynómu n implicitne stanoví priebeh funkcie medzi ekvidistantnými vzorkami a má dopad na presnosť aproximácie. Najčastejšie sa používajú konštantný ($n = 0$), lineárny ($n = 1$) alebo kvadratický ($n = 2$) polynóm, podľa toho rozlišujeme obdĺžnikové pravidlo (vzorec 2.10), lichobežníkové pravidlo (vzorec 2.11) a Simpsonovo pravidlo (vzorec 2.12).

$$v(t_i) = T_s \cdot a \left(\frac{t_i + t_{i-1}}{2} \right) \quad (2.10)$$

$$v(t_i) = \frac{T_s}{2} \cdot [a(t_i) + a(t_{i-1})] \quad (2.11)$$

$$v(t_i) = \frac{T_s}{3} \cdot [a(t_{2i}) + 4a(t_{2i-1}) + a(t_{2i-2})] \quad (2.12)$$

Pri obdĺžnikovom pravidle (obr. 2.4a) nepripúšťame zmenu hodnoty zrýchlenia medzi vzorkami a okamžitú rýchlosť, čiže plochu, odhadneme ako dĺžku intervalu vzorkovania vynásobenú priemerom výšok dvoch následných pozorovaní. Interpoláčny polynóm je konštantná funkcia. Lichobežníkové pravidlo (obr. 2.4b) uvažuje s lineárnou zmenou veličiny medzi meraniami, preto interpoluje priamkou. Simpsonovo pravidlo (obr. 2.4c) sa snaží o ešte tesnejší odhad s využitím kvadratickej funkcie. Každé kvadráturne pravidlo sa síce vyznačuje presne vyčísliteľnou chybou, ale k tomu je nevyhnutné poznať analytické vyjadrenie vibrácií, čo dáva realistický odhad len pri čisto periodických kmitoch.



Obr. 2.4: Porovnanie pravidiel numerickej integrácie

Priama integrácia zašumeného signálu zrýchlenia vedie k neskutočnému driftu, ktorý je ešte zvýraznený dvojitou integráciou pri odvodzovaní relatívneho posunutia. Dochádza k zosilneniu nízkych a potlačeniu vyšších frekvencií, čím začne dominovať neexistujúci trend vo výstupných dátach. Očakávané oscilujúce správanie vychýlenia u vibrácií so zväčšujúcim sa počtom sčítancov pri rekurentnom výpočte zaniká. Na zlepšenie stability integrátora sa uplatňuje korekcia cez obálky [10].

Najprv je na vstupnom signále vykonaná zvoleným pravidlom numerická kvadratura, ktorá môže byť realizovaná na krátkych úsekoch funkcie, aby sa predišlo pretečeniu pri výraznej akumulácii odklonu. Prichádza k identifikácii lokálnych extrémov a ich interpoláciou s kubickou B-spline sa sformuje horná $e_u(t)$, respektíve dolná obálka signálu $e_d(t)$. Obálky sú spriemerované $\bar{e}(t)$ za vzniku odhadu trendovej krivky, ktorá je od už integrovaného signálu odčítaná $g(t) = f(t) - \bar{e}(t)$. V prípade výpočtu polohy je možné aplikovať uvedený postup kaskádovito, čiže rovnako ako akcelerácia je aj signál rýchlosti opäť integrovaný a korigovaný obálkami.

2.2 Metódy analýzy signálu v časovej doméne

Pozorovania veličiny predstavujú udalosti merané sekvenčne v čase, kde je s každou obdržanou hodnotou x_i viazaná unikátna časová značka t_i . Postupnosť jednotlivých čítaní je jednorozmerný časový rad znázoriteľný ako usporiadaná množina dvojíc pečiatky rastúcej v čase a nasnímanej úrovne: $T = \{(t_1, x_1), (t_2, x_2), \dots, (t_n, x_n)\}$. Vzorkovaním v pravidelných intervaloch stačí uvažovať namiesto časových značiek o celočíselných indexoch, ktoré určujú pozíciu prvkov vo vektore pozorovaní: $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$.

2.2.1 Prúdové algoritmy

Pri veľkom objeme prichádzajúcich vzoriek produkovaných senzormi nie je uskutočniteľné ich úplné uchovanie ani spracovanie celkého dátového toku naraz. Častokrát by stratégia neuváženeho odkladania viedla k plytvaniu zdrojov a zbytočnému archivovaniu údajov s nízkou informačnou hodnotou. Vhodnejšie je agregovanie toku údajov podľa preddefinovaného zmysluplného kritéria, ktoré zachytáva významné rysy a umožňuje prompte zodpovedať na vyžadované dopyty.

Priamočiarou realizáciou agregácie je nahliadať na prvky časového radu postupne ako prichádzajú. Prúdové algoritmy pôsobiace v reálnom čase, a teda neschopné vidieť finálny vektor vzoriek vstupu sa vyznačujú vlastnosťou, že vyprodukujú parciálny výsledok platný pre dosiaľ sa vyskytnutú podmnožinu len na základe čiastkového vstupu.

Za ideálnych okolností by sa mal online algoritmus učiť kontinuálne bez ukladania predošlých bodov a detekcií. V rozhodnutiach algoritmu budú v takom prípade zahrnuté informácie o všetkých predošlých bodoch do terajšieho rozhodnutia. Mal by mať schopnosť adaptovať sa dynamickému prostrediu, v ktorom pôsobí, bez nutnosti manuálnych úprav parametrov modelu. Zároveň je žiaduce minimalizovať falošné pozitíva a negatíva pri detekcii udalostí. [11].

2.2.2 Posuvné a rozširujúce sa okná

Časový rad $(x_i)_{i=0}^n$ s dĺžkou n môže byť pre účely výpočtu sumárnych štatistík rozdelený oknovou funkciou $\mathcal{W}_{l,d}$ na podpostupnosti nazývané okná.

Posuvné okná („rolling window“) majú spravidla konštantnú dĺžku l menšiu ako celkovú veľkosť radu a sú aplikované s krokom odstupe d pozorovaní. Rad pozorovaní pozostáva z $(n - (l - 1))/d$ okien [12]. Prirodzene sa posuvné okná objavujú pri manipulácii s vyrovňavacou pamäťou, ktoré sa využívajú pri blokovom prenose z adaptéra senzora do hlavnej pamäte. Vtedy sa veľkosť bloku sa rovná posunu $l = d$.

Rozširujúce sa okná („expanding window“) nachádzajú uplatnenie v menej prípadoch, spravidla sa jedná o inkrementálny odhad globálnej štatistiky, ktorá má zmysel prevažne pri sledovaní stabilného javu. [13]. Okno začína na stanovenej minimálnej veľkosti a s pribúdajúcim počtom bodov ich zahŕňa, čím sa zväčšuje.

2.2.3 Číselné charakteristiky štatistického rozdelenia

Náhodné vibrácie vyskytujúce sa pri skutočných materiáloch sú stochastický proces, ktorý tvorí sekvencia časovo indexovaných náhodných premenných. Časový rad predstavuje realizáciu tohto stochastického procesu $\mathbf{Y} = (X_1, X_2, \dots, X_n)^T$, kde X_t je náhodná premenná so svojím rozdelením pravdepodobnosti. Všeobecne sa pri ideálnych stacionárnych otrasoch predpokladá, že premenné pochádzajú z unimodálnej Gaussovej distribúcie: $X_t \sim N(\mu, \sigma^2)$ [1].

Sumárna deskripcia nameraného deja pre extrakciu typických črt konkrétnych pozorovaných situácií sa uskutočňuje viacerými štatistikami $h(X_1, X_2, \dots, X_n)$ zosťručujúcimi opis funkcie hustoty rozdelenia. Na rozmiestnenie hodnôt meraní v priebehu časového úseku sa nazerá z pohľadu polohy, rozptýlenosti a tvaru. Rozsah oboru hodnôt je amplitúda špička-špička („peak-to-peak”), ktorá je rozdielom maximálnej a minimálnej úrovne, údaj známy tiež ako variančné rozpätie [14].

$$x_{pp} = \max_{t \in \mathcal{W}} \{x_t\} - \min_{t \in \mathcal{W}} \{x_t\} \quad (2.13)$$

Priemernú energiu obsiahnutú v signále predstavuje štvorec efektívnej amplitúdy RMS a určí sa ako kvadratický priemer pozorovaní:

$$x_{rms} = \sqrt{\frac{1}{n} \sum_{t=1}^n x_t^2} \quad (2.14)$$

Mierami polohy rozdelenia pozorovaní sú stredná hodnota, informujúca o centre hodnôt veličiny, a kvantily rozkladajúce usporiadaný vektor pozorovaní na určený počet rovnakých skupín. Nevychýleným bodovým odhadom strednej hodnoty je *výberový priemer*, ktorý je zároveň amplitúdou jednosmernej zložky signálu:

$$\bar{x} = \frac{1}{n} \sum_{t=1}^n x_t \quad (2.15)$$

Najvýznamnejším kvantilmi sú kvartily Q_q vytvárajúce štyri rovnako veľké časti z pôvodných dát, konkrétne dolný kvartil Q_1 oddelí 25% najmenších údajov, medián Q_2 predelí zoradené údaje na polovicu a horný kvartil Q_3 zahrnie 75% nižších hodnôt. Hľadaný kvartil je k -ty najmenší prvok v utriedenom zozname meraní, pričom podľa

želaného kvartilu q a počtu pozorovaní je $k = \lceil n \cdot (1/q) \rceil$.

Zistenie k -teho najmenšieho prvku s časovou zložitou $\mathcal{O}(n \log n)$ umožňuje ľubovoľný lepší triediaci algoritmus napríklad triedenie zlučováním (merge sort). Algoritmus Quickselect dokáže taký prvok objaviť v čase $\mathcal{O}(n)$. V každom kroku vyberie náhodný deliaci bod (pivot) a preskupí k sebe hodnoty menšie ako pivot naľavo a väčšie ako pivot napravo. Najmenší prvok následne hľadá v časti, kde zostalo viac ako k prvkov. Pokiaľ došlo k deleniu zoznamu, že pivot zaujme presne k -tu pozíciu, prehľadávanie je ukončené a pivot prehlásený za riešenie. Nesprávnym výberom pivota môže v najhoršom prípade dôjsť až k zložitosti $\mathcal{O}(n^2)$, čomu sa predchádza výberom pivota stratégiou medián mediánov.

Sústredovanie realizácie veličiny, respektíve jej rozptýlenosť okolo strednej hodnoty vieme opísať viacerými štatistikami ako sú výberový rozptyl (2.16), jej odmocninou smerodajnou odchýlkou, priemerná absolútna odchýlka (2.17), mediánová absolútna odchýlka (2.18) a medzikvartilové rozpätie (2.19) [14]. Priemerná absolútna odchýlka je upraviteľné o mieru centrálnej tendencie, ktorou okrem priemeru môže byť aj medián alebo modus. Vyvarovanie sa príliš extrémnym a vychýlením hodnotám docielime zapojením práve mediánu do štatistík absolútnej odchýlky, rovnako tak to dosiahneme medzikvartilovým rozpätím obmedzením sa na 50% centrálnych dát.

$$s^2 = \frac{1}{n-1} \sum_{t=1}^n (x_t - \bar{x})^2 \quad (2.16)$$

$$d = \frac{1}{n} \sum_{t=1}^n (|x_t - \bar{x}|) \quad (2.17)$$

$$\text{MAD} = \text{med}(|x_t - \text{med}(\mathbf{x})|) \quad (2.18)$$

$$\text{IQR} = Q_3 - Q_1 \quad (2.19)$$

Numericky stabilné bežiacie štatistiky priemeru a smerodajnej odchýlky sa udržiavajú cez rekurentné rovnice *Welfordovho algoritmu* [15]. M_1 je aktuálna priemerná hodnota údajov v toku a S_1 je počítadlo pre rozptyl, z ktorého je v ktoromkoľvek

okamihu získateľná smerodajná odchýlka súboru σ :


$$M_1 = x_1; \quad M_k = M_{k-1} + \frac{(x_k - M_{k-1})}{k} \quad (2.20)$$

$$S_1 = 0; \quad S_k = S_{k-1} + (x_k - M_{k-1})(x_k + M_k) \quad (2.21)$$

$$\sigma = \sqrt{S_n/(n-1)} \quad (2.22)$$

Tvar distribúcie náhodnej premennej opisujú centrálné momenty šikmost' a špicatost'. Šikmost' $\gamma_1 = \mu^3/\sigma^3$ udáva skosenie rozdelenia, pričom platí že záporná šikmost' značí dlhší ľavý chvost a modus funkcie hustoty sa prevažuje napravo. Zatiaľ čo u kladnej šikmosti je to naopak (obr. 2.5a).

Špicatost' $\gamma_2 = \mu^4/\sigma^4 - 3$ (obr. 2.5b) porovnáva rozdelenie pozorovaní so strmou krivkou normálneho rozdelenia, čiže viacej realizácií leží bližšie alebo ďalej od strednej hodnoty. Kladná špicatost' signalizuje strmejšiu a záporná zasa sploštenejšiu distribúciu. Platí, že μ_n je priemerom hodnôt $(x_t - \bar{x})^n$.



Obr. 2.5: Dopad šikmosti a špicatosti na histogram distribúcie

Závislosť dvojíc veličín sa vyjadruje kovariancia $cov(\mathbf{x}, \mathbf{y})$ a korelácia $\rho(\mathbf{x}, \mathbf{y})$. U vektora akcelerácie nás bude napríklad zaujímať vzájomná korelácia medzi osami pohybu: $\rho(\vec{x}, \vec{y})$, $\rho(\vec{x}, \vec{z})$, $\rho(\vec{y}, \vec{z})$ upozorňujúca na diagonálny pohyb alebo podobné budenie v oboch korelovaných smeroch a tým umožňujúce redukciu údajov z dôvodu redundancie. Kovariancia je daná strednou hodnotou súčinu odchýlky od priemeru zodpovedajúcej premennej (vzťah 2.23). Normovaním kovariancie smerodajnými odchýlkami veličín získame Pearsonov korelačný koeficient (vzťah 2.24), ktorý je z intervalu $[-1; 1]$. Hodnota koeficientu -1 značí nepriamu lineárnu závislosť a $+1$

priamu závislosť.

$$\text{cov}(\mathbf{x}, \mathbf{y}) = \frac{1}{n} \sum_{t=1}^n (x_t - \bar{x})(y_t - \bar{y}) \quad (2.23)$$

$$\rho(\mathbf{x}, \mathbf{y}) = \frac{\text{cov}(\mathbf{x}, \mathbf{y})}{\sigma_x \sigma_y} \quad (2.24)$$

2.2.4 Algoritmy na rozpoznávanie špičiek

Detekcia udalostí a významných zmien signálového priebehu sa spolieha na hodnotnú identifikáciu špičiek amplitúdy. Dôležitými indikátormi pre celkovú charakterizáciu javu slúži potom časová pozícia špičky v rámci prúdu, výška prejavujúca sa nadobudnutou úrovňou, šírka obsahujúca údaj o trvaní, či plocha stvárňujúca energiu.

Ekvivalentne sa špičky z matematického hľadiska stotožňujú s lokálnymi extrémami funkcie, čo sú maximá (vrcholy) a minimá (údolia). Podľa definície je lokálne maximum t_0 bodom, ktorý má vyššiu funkčnú hodnotu ako všetky ostatné body na intervale $t_0 \in I$ (2.25), lokálne minimum má na intervale najmenšiu hodnotu (2.26) [16].

$$f[t_0] \geq f[t], \forall t \in I \quad (2.25)$$

$$f[t_0] \leq f[t], \forall t \in I \quad (2.26)$$

Kľúčové pre spoľahlivé určenie extrémov je práve interpretácia intervalu I v algoritmoch, ktoré zastupujú rozličné potreby korektného vyhodnotenia. Jediné minimum a maximum sa dosiahne zvolením celej dĺžky záznamu za interval, čím sa stratia dočasné disturbancie. Na druhej strane prílišným skrátením intervalu sa skoro všetky vzorky budú javiť ako náhle zmeny.

Skutočné signály sa potýkajú so šumom, ktorý sťažuje odlíšenie pravej tendencie od krátkodobých výkyvov. Pred samotným procesom hľadania špičiek je preto aplikovaný vyhladzovací filter, v prípade potreby aj opakovane na už vyhladení signál. Najčastejšie sa jedná o filter klzavého priemeru, Savitzky–Golay alebo Gaussov filter [17]. Filtrovanie sa realizuje diskretnou jednorozmernou konvolúciou vstupného signálu a masky filtra $y[n] = x[n] * h[n]$, ktorá býva hardvérovo akcelеровaná

inštrukciami vynásob a sčítaj („multiply-accumulate”) za zvýšenia presnosti.

Detekcia špičiek prahovou úrovňou

Za predpokladu, že priebeh meranej veličiny sa vyznačuje krátkymi impulzmi s viac-menej pravidelnou amplitúdou je priamočiarou metódou na odlíšenie špičiek od hladín nízkej aktivity určenie prahu θ , ktorý zaregistruje všetky väčšie hodnoty. Lokálne extrémny sú potom vzorky signálu spĺňajúce podmienku:

$$|f[t]| \geq \theta \quad (2.27)$$

Určenie takejto hraničnej hladiny prebieha zväčša empiricky alebo na základe heuristik, ktoré so sebou nesú domnienku o vlastnostiach priebehu pozorovaní. Uspokojivými odhadom za určitých okolností môžu byť prahy θ : viac ako priemer s toleranciou, horné $3/4$ celkového nedávneho rozsahu hodnôt, či dokonca viac ako k smerodajných odchýlok. Odlišné nazeranie na prahovú hodnotu spočíva v jej nastavení pre rozpoznanie vzájomnej korelácie signálu a masky zodpovedajúcej tvaru impulzu. Táto úvaha sa opiera o to, že impulz musí byť dostatočne pravidelný, aby bol nezameniteľne odlíšiteľný.

Význačnosť vrchola spomedzi susedov

Doplňkom ku rozpoznávaniu špičiek podľa absolútnej prahovej úrovne je porovnanie bodov na obe strany od preskúmaného vrchola, čím zistíme relatívnu významnosť extrému pre najbližšie susedstvo. Aby bola hodnota na danej pozícii t označená za špičku v okolí pozostávajúcom z k príľahlých bodov, musí byť v porovnaní so všetkými väčšia. Pre okrajové dátové body $f[0]$ a $f[n]$ dochádza k porovnaniu iba z jednej strany [16]:

$$f[t-i] < f[t] > f[t+i], \quad \forall i \in 1, 2, \dots, k \quad (2.28)$$

Algoritmus č.1 „najvyšší spomedzi susedov” [18] prechádza postupne pozorovania veličiny zo zoznamu y a ku kandidátnej špičke na indexe i preveruje najbližších k hodnôt na obe strany, ak existujú. Keď po preskúmaní zostáva $y[i]$ najväčšou hodnotou spomedzi susedov v rozmedzí $[a; b]$, za tolerance strmosti stúpania ε medzi

Algoritmus 1 Najvyšší spomedzi susedov

```

1: function FIND_PEAKS_NEIGHBOURS( $y, k, \epsilon, h_{rel}, h$ )
2:    $peaks \leftarrow []$  ▷ Zoznam indexov nájdených špičiek v signále  $y$ 
3:   for  $i \leftarrow 0$  to  $length(y)$  do
4:     if  $h \neq null$  and  $|y[i]| < h$  then ▷ Preskoč príliš nízke magnitúdy
5:       continue
6:     end if
7:      $possible\_peak \leftarrow true$ 
8:      $a \leftarrow max(i - k, 0)$ 
9:      $b \leftarrow min(i + k, length(y))$ 
10:    for  $j \leftarrow a$  to  $b$  do ▷ Porovnaj špičku s bodmi v susedstve
11:      if  $i \neq j$  and  $y[j] - y[i] > \epsilon$  then
12:         $possible\_peak \leftarrow false$  ▷ Kopec nie je dostatočne strmý
13:      end if
14:    end for
15:    if  $possible\_peak = true$  and  $y[i] - \min(y[a], y[b]) > h_{rel}$  then
16:       $peaks \leftarrow peaks + [i]$  ▷ Kandidát je prehlásený za špičku
17:    end if
18:  end for
19:  return  $peaks$ 
20: end function

```

pozorovaniam, a súčasne je relatívna výška vrcholu väčšia oproti nižšiemu okraju než nastavený parameter h_{rel} potom je kandidátny bod prehlásený za skutočnú špičku a pridaný do zoznamu $peaks$.

Súčasťou algoritmu je tiež preskočenie hodnôt, ktoré nespĺňajú základný predpoklad pre absolútnu amplitúdu h . Časová zložitosť pre rozhodnutie o jednej špičke je lineárna v závislosti od veľkosti posuvného okna uvažovaného susedstva $\mathcal{O}(2k)$.

Algoritmus prechodu nulou do záporu

Pomyselné vrcholy a údolia v zosnímaných hodnotách sú miestom, kde sa mení smer úrovni amplitúdy zo stúpania na klesanie alebo z klesania na stúpanie, čím na pomedzí týchto opozitných trendov vzniká stacionárny bod, kde je prvá diferenciá nulová: $\Delta f[i] = 0$. V lokálnom maxime dochádza súčasne k zmene znamienka prvej diferenciácie z kladného na záporné. Prudkosť kopca vyplýva z absolútnej hodnoty diferenciácie.

Viacnásobné vyhladenie signálu predom je nesmierne dôležité, pretože algoritmus č.2 „prechodu nulou do záporu“ (Negative Zero-Crossing) je nesmierne citlivý na zákmity a nesprávne by ich považoval za špičky. Zvýšenie odolnosti proti takýmto

tendenciám sa dosahuje dlhšou sečnicou spájajúcou bod i s k -tou vzorkou vedľa, ktorá sa použije namiesto diferencie s jednotkovým krokom.


Algoritmus 2 Prechod prvej derivácie nulou do záporu

```

1: function FIND_PEAKS_ZERO_CROSSING( $y, k, \varepsilon, slope$ )
2:    $peaks \leftarrow []$ 
3:   for  $i \leftarrow k$  to  $length(y) - k$  do
4:     if  $(|y[i + k] - y[i - k]| \leq \varepsilon$  and
5:        $(y[i + k] - y[i]) - (y[i] - y[i - k]) < 0$  and
6:        $|(y[i + k] - y[i]) - (y[i] - y[i - k])| > slope)$  then
7:        $peaks \leftarrow peaks + [i]$ 
8:     end if
9:   end for
10:  return  $peaks$ 
11: end function

```

Označenie kandidátneho bodu za špičku v zozname hodnôt y stojí na teda troch kritériách. Sklon sečnice sa musí v rámci tolerance ε blížiť nule, rozdiel prvých diferencií $\Delta y[i + k] - \Delta[i]$ musí byť záporný a veľkosť rozdielu diferencií prekračuje prahovú strmosť kopca $slope$, kde leží uvažovaný vrchol. Časová zložitosť pre jednu špičku je $\mathcal{O}(1)$.



Obr. 2.6: Topografia priebehu signálu

Algoritmus horského turistu

Zanesením do grafu pripomína priebeh funkcie kmitajúceho deja členité pohorie. Na problém rozhodovania sa o tom, či danú lokalitu považovať za vrchol možno nahliadať z pohľadu chodca cestujúceho po krivke z lineárne interpolovaných vzoriek. V princípe ide myšlienkou o jednoduchý stavový automat sledujúci aktuálny stav

terénu a konajúci rozhodnutia na základe predošlej skúsenosti v intenciách rozhodovacích pravidiel.

Algoritmus 3 Algoritmus horského turistu

```

1: function FIND_PEAKS_HILL_WALKER(y, tolerance, hole, prominence,
   isolation)
2:   peaks  $\leftarrow$  []
3:   i_change  $\leftarrow$  0
4:   y_valley  $\leftarrow$  0
5:   possible_change  $\leftarrow$  false
6:   uphill  $\leftarrow$  (y[1] - y[0])  $\geq$  0
7:   for i  $\leftarrow$  1 to length(y) do
8:     y_step  $\leftarrow$  y[i] - y[i - 1]
9:     slope  $\leftarrow$  y_step  $\geq$  0
10:    if possible_change = false and uphill  $\neq$  slope then
11:      possible_change  $\leftarrow$  true           ▷ Označenie potenciálneho extrému
12:      i_change  $\leftarrow$  i - 1
13:    else if possible_change = true and uphill = slope then
14:      possible_change  $\leftarrow$  false           ▷ Potenciálny extrém bol zachvením
15:    end if
16:    if (possible_change = true
17:      and uphill  $\neq$  slope
18:      and |i - i_change| > hole
19:      and |y[i] - y[i_change] > tolerance) then
20:      possible_change  $\leftarrow$  False           ▷ Významný lokálny extrém potvrdený
21:      prev_uphill  $\leftarrow$  uphill
22:      uphill  $\leftarrow$  slope
23:      if prev_uphill = false and uphill = true then
24:        y_valley  $\leftarrow$  y[i_change]           ▷ Nájdené údolie
25:      else if (prev_uphill = true
26:        and uphill = false
27:        and |y[i - hole] - y_valley| > prominence)
28:        and |y[i - hole] - y[last(peaks)] > isolation) then
29:          y_peak  $\leftarrow$  y[i_change]           ▷ Skutočný vrchol identifikovaný
30:          peaks  $\leftarrow$  peaks + [i_change]
31:        end if
32:      end if
33:    end for
34:    return peaks
35: end function

```

Algoritmus č.3 horského turistu na začiatku púte z počiatočných bodov zistí, ktorým z dvoch vertikálnych smerov sa krivka uberá. V prípade, že po druhom kroku dôjde k zmene smeru zapíše sa indikácia možného spádu kopca. Výchylka môže byť v dôsledku neprekročenia prahových úrovní v horizontálnej (*hole*) a vertikálnej

(*tolerance*) osi ignorovaná, lebo ani na lesnom chodníku sa nepovažuje každá jama alebo vydutie za horu.

Domnelý vrchol je označený za lokálne maximum, keď spĺňa parametre pre topografické vlastnosti minimálnej akceptovateľnej prominencie a izolácie (obr. 2.6). Prominencia znamená relatívnu výšku oproti predošlej navštívenej doline. Izolácia vyčísluje vzdialenosť k najbližšiemu skoršiemu vrcholu. Podobný algoritmus už existuje v literatúre [19], avšak prezentovaný pseudokód je oproti nemu zjednodušený a doplnený o požadované tolerancie.

2.2.5 Metriky pre binárny klasifikátor

Uviedli sme tri rozdielne rovnocenné prístupy odhalenia špičiek. Rozobrali sme algoritmus porovnávajúci susedov na obe strany, algoritmus využívajúci sklon sečníc vychádzajúc s vlastnosťí prvej derivácie a napokon stavový automat odvolávajúci sa na sekvenčne preskúmanú topografiu krivky grafu. Spoločným rysom zmienených techník je vykonávanie binárne zaradenie pre každú vzorku, či sa sa nachádza alebo nenachádza na aktuálnej pozícii vrchol.

Rozhodnutie môže viesť k správne (P) alebo nesprávne (N) riešeniu vzhľadom na objektívnu pravdu sprostredkovanú anotovanými dátami. Keď sa kategorizácia zhoduje s realitou dostávame skupiny skutočne pozitívnych TP a skutočne negatívnych TN . V prípade, že sa klasifikátor pomýli vyjde buď chyba prvého rádu FP , kedy registrujeme neexistujúcu špičku, alebo chyba druhého rádu FN , kedy ju prehliadneme. Umiestnením počtov charakteru rozhodnutí do tabuľky vzniká matica zámen [20].

Úspešnosť klasifikačných algoritmov pre ich vzájomné porovnanie kvantifikujú viaceré metriky. Na odladenie parametrov vplývajúcich na náchylnosť preferovať kladné alebo záporné výsledky sa vzťahuje *prevalencia* výskytu očakávaného javu: $P/(P + N)$ v samotných dátach. Snahou rozhodovania je maximalizovať senzitivitu a špecifickosť výsledkov algoritmu. *Senzitivita* (2.29) udáva koľko bodov, ktoré sú prehlásené za špičky naozaj je špičkami. *Špecifickosť* (2.30) sa zameriava na potvrdenie, aké množstvo pozorovaní nepovažovaných za špičky, nie sú nimi aj skutočne.

$$TPR = \frac{TP}{P} = \frac{TP}{TP + FN} \quad (2.29)$$

$$TNR = \frac{TN}{N} = \frac{TN}{TN + FP} \quad (2.30)$$

Presnosť určenia lokálneho extrému sa skladá z správnosti (2.31) a precíznosti (2.32), ktoré je rovnako žiaduce dosahovať čo najbližšie sto percentám, pri nízkej chybovosti (2.33), čiže nízkeho počtu falošných poplachov.

$$PPV = \frac{TP}{TP + FP} \quad (2.31)$$

$$ACC = \frac{TP + TN}{P + N} \quad (2.32)$$

$$FPR = \frac{FP}{FP + TN} \quad (2.33)$$

Štandardným nástrojom na vyjadrenie kvality binárneho klasifikátora je *ROC krivka* zakresľujúca senzitivitu TPR vo zvislom smere voči vodorovnej chybovosti FPR . ROC vytvoríme postupným posúvaním prahu pre klasifikáciu prostredníctvom parametrov algoritmu. Použiteľný algoritmus sa vyznačuje vypuklou krivkou smerom k ľavému hornému rohu nad diagonálou, ktorá by sprevádzala počínanie náhodného rozhodovania. Dokonalá metóda pri dosahovala stopercentnú senzitivitu za nulovej chyby. Vyjadrením plochy pod ROC krivkou je miera AUC, ktorá umožňuje približné číselné porovnanie rôznych získaných kriviek [21].

2.3 Frekvenčná a časovo-frekvenčná analýza signálu

Cyklicky sa opakujúce deje v signále sú extrahované zo sekvencie vzoriek v časovej doméne transformovaným do domény frekvenčnej. Premenou dochádza k odhadu sumárnej intenzity jednotlivých rozsahov zložiek spektra, pričom rozlíšenie je podmienené vzorkovacou frekvenciou f_s a celkovým počtom meraní N (2.34) [22].

$$\Delta f = \frac{f_s}{N} \quad (2.34)$$

Kompromis potrebný urobiť pri spektrálnej analýze tkvie vo vyvážení dĺžky úseku

pre časovú lokalizáciu frekvenčného obrazu, a jeho výslednej detailnosti na strane druhej. Prechod medzi časovou a frekvenčnou doménou postihuje princíp neurčitosti znamenajúci, že pri raste rozlíšenia v čase strácame rozlíšenie vo frekvenciách a naopak [23]. O požadovanom množstve pozorovaní pre konkrétnu rozlíšiteľnosť spektra taktiež hovorí vzťah (2.34). Rozpätie frekvencií spadajúcich do diskrétného frekvenčného vedierka k sú počínajúc $k\Delta f$ po $(k+1)\Delta f$.

2.3.1 Diskrétna fourierová a kosínusová transformácia

Diskrétna Fourierová transformácia (DFT) slúži na učenie harmonického zloženia signálu (2.35) rozkladom na súčet sínusov a kosínusov rôznych frekvencií. Zobrazuje vektor komplexných čísel y dĺžky N do vektora N frekvenčných komponentov. Na vypočítanie k -teho frekvenčného vedierka sú prvky sekvencie pozorovaní prenásobené zodpovedajúcim exponenciálnym členom tzv. *twiddle factor* (2.36). Inverzná transformácia sa líši iba opačným znamienkom exponenta a získané hodnoty sa zvyknú normovať delením N .

$$Y[k] = \sum_{n=0}^{N-1} x[n] \cdot W_N^{nk}; \quad k = 0, \dots, N-1 \quad (2.35)$$

$$W_N^{nk} = \exp(-i2\pi nk / N) \quad (2.36)$$

Alternatívne sa exponenciálny faktor vyjadruje v goniometrickom tvare ako kosínusovú reálnu časť a sínusovú imaginárnu časť:

$$W_N^{nk} = \cos(2\pi nk/N) - i \cdot \sin(2\pi nk/N) \quad (2.37)$$

Spektrálne komponenty opísané vektorom komplexných Fourierových koeficientov majú magnitúdy dané veľkosťami komplexných čísel (2.38). Pre vstupy $x \in \mathbb{R}$ je výstup z DFT zrkadlovo symetrický, čiže druhá polovica výstupu je komplexne združená k prvej $x[m] = x^*[N-m]$. Symetrickosť zapríčiňuje nadbytočnosť výsledkov nad pozíciou $N/2$. Rovnako naznačuje reformulácia vety o vzorkovaní, že za vzorkovacej frekvencie f_s sú zapríčinením aliasingu v signále prítomné frekvencie do maximálne polovice f_s . Energia vo frekvenčnom vedierku je druhou mocninou magnitúdy, ale častejšie sa objavuje reprezentácia relatívneho energetického spektra

v decibeloch (2.39) [22].

$$|Y[k]| = \sqrt{\Re\{Y[k]\}^2 + \Im\{Y[k]\}^2} \quad (2.38)$$

$$Y_{dB}[k] = 20 \cdot \log_{10} \left(\frac{|Y[m]|}{\max\{|Y[m]|\}} \right) \quad (2.39)$$

Sekvencia pozorovaní vyjadrená cez súčet kosínusoid namiesto exponenciálneho faktora tvorí rodinu diskrétnych kosínusových transformácií (DCT). Vyznačujú sa dobrou dekoreláciu vstupu a energetickou kompresiou, čiže pomerne veľká časť celkovej spektrálnej energie je sústredená v málo koeficientoch [24]. Navyše oproti DFT umožňuje redukcii výpočtovej náročnosti odstránením súčinov v komplexných číslach.

Podľa charakteru obmien kosínusovej bázy rozlišujeme štyri typy DCT, z nich najvýznačnejšie sú transformácie DCT-II, ktorej inverziou je DCT-III, a DCT-IV, ktorá je inverzná sama sebe [25]. Z DCT-IV vychádza MDCT, ktorá navyše spracováva prekrývajúce sa bloky, tak že druhá polovica vzoriek pochádza z prvej polovice ďalšieho bloku. Dokopy vytvorí z $2N$ vzoriek N koeficientov. MDCT sa hojne využíva pri stratovej kompresii zvuku, pretože sa prelínaním blokom vyvaruje artefaktom na hraniciach blokov [26].

$$W_N^{nk} = \cos \left[\left(n + \frac{1}{2} \right) k \frac{\pi}{N} \right] \quad (\text{DCT-II})$$

$$W_N^{nk} = \cos \left[n \left(k + \frac{1}{2} \right) \frac{\pi}{N} \right] \quad (\text{DCT-III})$$

$$W_N^{nk} = \cos \left[\left(n + \frac{1}{2} \right) \left(k + \frac{1}{2} \right) \frac{\pi}{N} \right] \quad (\text{DCT-IV})$$


$$W_N^{nk} = \cos \left[\left(n + \frac{1}{2} + \frac{N}{2} \right) \left(k + \frac{1}{2} \right) \frac{\pi}{N} \right]; \quad n = 0, \dots, 2N - 1 \quad (\text{MDCT})$$

2.3.2 Algoritmus FFT

Priamočiarou implementáciou vzťahom na výpočet Fourierovej a kosínusovej transformácie dosiahneme časovú zložitosť rádu $\mathcal{O}(N^2)$. Aplikáciám v reálnom čase na prúdoch dát takáto výpočtová náročnosť zďaleka nepostačuje. Algoritmus rýchlej Fourierovej transformácie (FFT) uplatňujúci prístup rozdeľuj a panuj zvládne zrealizovať DFT v čase $\mathcal{O}(N \log N)$.

Celkovo pozostáva z N sčítaní a $N/2$ násobení v komplexných číslach. Najbežnejšia varianta algoritmu FFT radix-2 vyžaduje, aby veľkosť vstupu bol mocninou dvojky: $N = 2^k$. Značná výpočtová úspora sa nadobúda uvažovaním s periodicitou goniometrických funkcií pri twiddle faktoroch W_N a z toho vyplývajúcich symetrií Fourierovej matice, keďže len N z N^2 prvkov matice je odlišných [27].

Podľa spôsobu dekompozície vstupného vektora sú známe dve verzie Radix-2 FFT nazvané decimácia v čase (DIT) a decimácia vo frekvencii (DIF). Decimácia v čase (obr. 2.7a) rekurzívne delí hodnoty na párne a nepárne pozície v čase, zatiaľ čo decimácia vo frekvencii (obr. 2.7b) rozdeľuje na tieto na párne a nepárne frekvenčné vedierka [28]. Výpočet prebieha v $\log_2(n)$ deliacich fázach. Poradie prvkov vo výstupnom vektore je vždy bitovo invertované, čiže poradové číslo zapísané ako bitový reťazec má obrátené poradie. Na dosiahnutie výstupu poradí rastúcich pozícií musí byť pred spustením FFT vstup preusporiadaný [27].




Obr. 2.7: Radix-2 FFT na štyroch bodoch [28]

Základným prvkom schémy výpočtu je motýlikový diagram („butterfly”), ktorý je odlišný pre DIT (obr. 2.8a) a pre DIF verziu (obr. 2.8b). Motýlik obsahuje vynásobenie jedného z príchodzích operandov s vopred vypočítaným exponenciálnym členom W_N^j pre $j = 0, \dots, N/2 - 1$ [27], a následné prirátanie a tiež odpočítanie od druhého operandu.

Efektívnejšie na celkový počet aritmetických počet operácií oproti FFT s radixom 2 je *split-radix*, ktorý kombinuje výhody vyplývajúce z radix-4 pre nepárne členy DFT a radix-2 pre párne členy. Veľkosť vstupného vektora musí byť násobkom štyroch. Dosahuje okolo 30% zníženie počtu násobení a 10% pokles počtu sčítaní oproti radix-2 [29].

Algoritmus FFT je aplikovateľný taktiež na výpočet DCT vhodným zoradením vstupného vektora. DCT-II N -bodovej reálnej postupnosti \mathbf{x} sa odvodzuje usku-



Obr. 2.8: Motýlikové diagramy algoritmu FFT

točnením jej $2N$ -bodového párneho rozšírenia a vynásobením výsledku twiddle faktorom $2W_{2N}^k$ a ponechaním reálnej časti. Ďalej uvádzame prípad DCT 4-bodovej sekvencie (x_1, x_2, x_3, x_4) , ktorej párnym rozšírením \mathbf{y} je $(x_1, x_2, x_3, x_4, x_4, x_3, x_2, x_1)$. Rovnako by postačovalo vyplniť pôvodnú postupnosť nulami do dĺžky $2N$, čiže dostávame $(x_1, x_2, x_3, x_4, 0, 0, 0, 0)$. Postačuje však realizovať N -bodovú FFT sekvencie párných alebo nepárných prvkov z \mathbf{y} , ktoré sú vzájomným reverzom. Na základe predošlého predošlého príkladu dostaneme postupnosť (x_1, x_3, x_4, x_2) [30].

Široké použitie FFT pri spracovaní signálov sa prejavuje dostupnosťou implementácií rôznych obmien algoritmu v širokej škále programovacích jazykov a optimalizovaných pre konkrétne hardvérové platformy. V jazyku C stoja za zmienku knižnice: FFTW, FFTPACK, GNU Scientific Library, CMSIS DSP a Espressif DSP. Na účely analýzy údajov je FFT prítomné pre jazyk Python v balíkoch *numpy* a *scipy*, tiež napr. v jazyku R je súčasťou *stats* modulu.

2.3.3 Oknové funkcie

U stochastického signálu má zmysel delenie na rovnako dlhé úseky, pretože sa s časom mení jeho spektrálny obsah, ktorý je žiaduce zachytiť čo najpresnejšie. Krátkodobá Fourierová transformácia zahŕňa preto ováňovanie meraní v časovej doméne koeficientmi posuvnej oknovej funkcie. Mimo intervalu pôsobnosti okna sú vzorky vynulované.

DFT predpokladá periodicitu časového radu do nekonečna, preto ak frekvencia sínusového vstupu nie je presným násobkom frekvenčného rozlíšenia, čiže priebeh exaktne nepripadá frekvenčnému vedierku, dochádza k úniku spektra (spectral leakage). Prejavom je hraničný efekt pre odlišnosť poslednej a prvej vzorky, ktorá je považovaná za nespojitosť a prejavuje sa zvlnením v okolí diskontinuity podľa

Gibsovho javu [22].

Existuje množstvo oknových funkcií líšiacich sa mierou kompromisu medzi šírkou výsledných špičiek vo frekvenčnej doméne, presnosti v amplitúde a spôsobu poklesu úniku spektra do ostatných vedierok. Medzi najpoužívanéjšie sa zaraďujú: obdĺžnikové (2.40), Bartlettovo (2.41), Hannovo (2.42), Hammingovo (2.43) a Blackman-novo okno 2.44. Uvedené okná sú stredovo súmerné (obr. 2.9a). Plochejšie okná, napríklad obdĺžnikové, sa vyznačujú ponechaním ostrejších špičiek s neskreslenou amplitúdou za cenu väčšieho spektrálneho úniku, čím sa znižuje odstup od šumu. Predchádzanie hraničným javom sa dosahuje plynulým znižovaním hodnôt k okrajom okna až na nulu, čím špičky strácajú na amplitúde (scallop loss) [31].

$$w(n) = 1, n = 0, 1, \dots, N - 1 \quad (2.40)$$

$$w(n) = \frac{2}{N-1} \left(\frac{N-1}{2} - \left| n - \frac{N-1}{2} \right| \right) \quad (2.41)$$

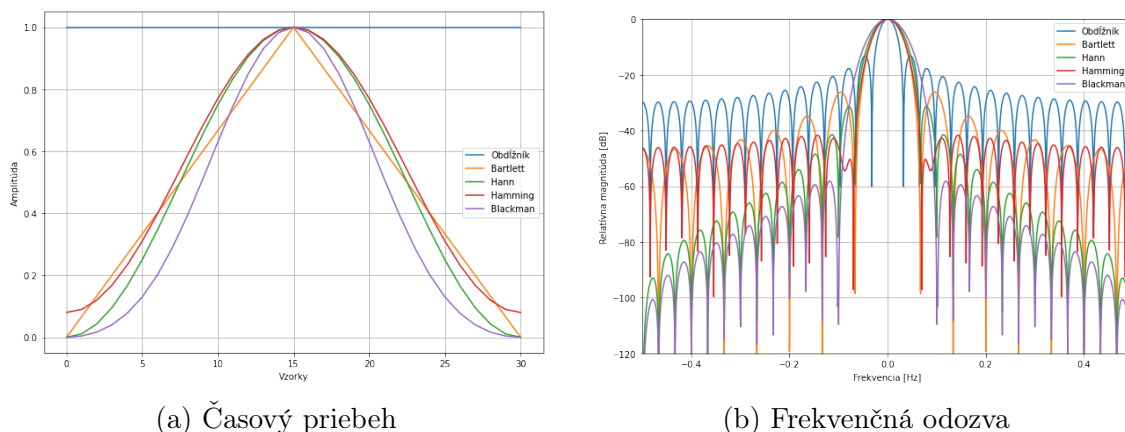
$$w(n) = \cos^2((2\pi n/N - \pi)/N) \quad (2.42)$$

$$w(n) = 0.54 - 0.46 \cos(2\pi n/N) \quad (2.43)$$

$$w(n) = 0.42 - 0.5 \cos(2\pi n/N) + 0.08 \cos(4\pi n/N) \quad (2.44)$$

Fourierou transformáciou okna dostávame frekvenčnú odozvu, ktorá má tvar funkcie $\text{sinc}(x) = \sin(x)/x$ (obr. 2.9b) Priebeh odozvy sa vyznačuje hlavným a vedľajšími vrcholmi (mainlobe a sidelobes). Hlavný vrchol sa snažia rôzne oknové funkcie udržať čo najužší, lebo zodpovedá za šírku spektrálneho úniku do okolitých vedierok. Vedľajšie vrcholy sú nežiaduce a podmieňujú najmä úroveň odstupu od šumu.

Vzhľadom na skutočnosť, že oknové funkcie sa typicky blížlia nule smerom k okrajom, bola by veľká časť pozorovaní časového radu ignorovaná. Prekrývaním okien vo vhodnom pomere je umožnený rovnomerný vplyv hodnôt, ktoré pripadnú na okraj niektorého okna. Pomer sa stanovuje štandardne na 50%, aj s ohľadom na rastúcu výpočtovú záťaž s väčším prekrývaním. Výnimkou je obdĺžnikové okno kde to nemá zmysel. Platí, že pri iných užších oknách je potrebné rátať s väčším presahovaním ako pri širších. Vyhodnotenie veľkosti prekrývania sa zakladá na korelácii spektrogramov a plochosti amplitúdy, čiže pomeru minimálnej váhy na pozorovanie vo všetkých oknách ku maximálnej dosiahnutej amplitúde ideálne rovnajúce sa

Obr. 2.9: Tvar oknových funkcií s dĺžkou $N = 31$

jednotke [31].

Jediný odhad frekvenčných zložiek postupnosti vzoriek vedie k vysokej neurčitosti odhadov pre frekvenčné vedierka, keďže smerodajná odchýlka odhadu je totožná s odhadom samotným [31]. Welchova metóda spriemerovania upravených periodogramov spresní úrovně frekvencií cez priemer viacerých prekrývajúcich sa energetických spektier [32].

2.3.4 Filtre s konečnou impulznou odozvou

Predspracovanie signálu do podoby vhodnejšej na analýzu, extrakciu črt a detekciu udalostí sa vykonáva filtrovaním. Častými činnosťami býva odstránenie posunu alebo jednosmernej zložky, eliminovanie šumu rozptýleného medzi vysokofrekvenčné komponenty, a oddelenie známeho frekvenčného pásma od zvyšku spektra. Dolná priepusť prepustí nízke frekvencie až po medznú frekvenciu, od ktorej nahor frekvencie utlmuje. Horná priepusť sa správa opačne a potláča nižšie frekvencie. Pásmová priepusť ponechá frekvencie v obmedzenom rozsahu z oboch strán.

Ideálne filtre majú okamžitý útlm dovoľujúci prechod striktne vymedzeným zložkám signálu. Vo frekvenčnej doméne oblasti nadobúdajú preto tvar obdĺžnikového okna. Transformáciou do časovej domény sa obdĺžnik zmení na konvolučnú masku, resp. impulznú odozvu $h[k]$, s priebehom sinc funkcie, ktorá nie je vyjadriteľná nekonečne presne, čím vznikajú prechodové javy vo frekvenčnej odozve filtra a menšia strmosť útlmu s kratším filtrom.

Konečná impulzná odozva v názve FIR filtra znamená, že pri vyjadrení filtra

sa obmedzíme na konečný počet koeficientov orezaním impulznej odozvy rovného rádu filtra k . Výpočet upravenej hodnoty sa v časovej doméne počíta ako diskretná konvolúcia s časovou zložitou $\mathcal{O}(nk)$, pre časový rad dĺžky n . Diagram výpočtu je zachytený na obr. 2.10.

$$y[n] = x[n] * h[n] = \sum_{i=0}^K h[i] \cdot x[n-i] \quad (2.45)$$

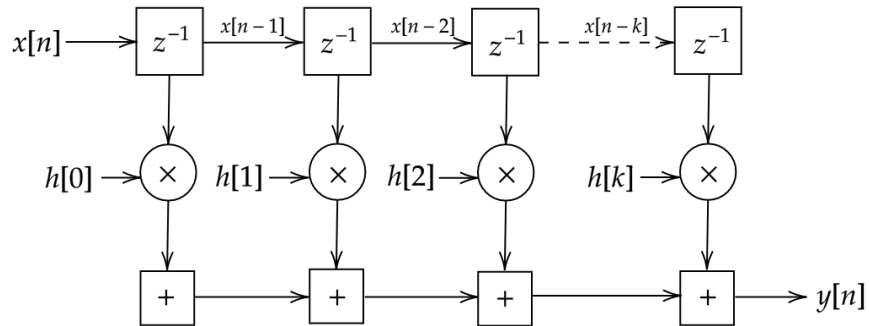
Masky dolnej (2.46), hornej (2.47) a pásmovej priepuste (2.48) popisujú uvedené vzťahy pre medznú normalizovanú frekvenciu $f_c = f/f_s$ a $n = -k/2, \dots, 0, \dots, k/2$. Zvlnenie v prechodovom pásme medzi rozsahmi so ziskom a útlmom je vylepšené návrhom filtra za použitia oknovej funkcie (napr. Blackman) na žiadanú frekvenčnú odozvu.

$$h_{LPF}[n] = \text{sinc}(2f_c n) \quad (2.46)$$

$$h_{HPF}[n] = (-1)^n \cdot h_{LPF}[n] \quad (2.47)$$

$$h_{BPF}[n] = \text{sinc}(2f_{c2} n) - \text{sinc}(2f_{c1} n) \quad (2.48)$$

Podľa konvolučnej vety platí, že konvolúcia v čase je násobením vo frekvenciách, umožňujúc urýchlenie filtrovania pre veľké masky. Kým vtedy sa blíži zložitosť konvolúcie ku kvadratickej, na násobenie vo frekvenčnej doméne so stačí vykonať FFT a IFFT dohromady v rádovo $\mathcal{O}(n \log n)$.



Obr. 2.10: Bloková schéma FIR filtra rádu k

2.4 Senzorová sieť

Zber údajov meraní z prostredia zabezpečujú samočinné senzorové jednotky schopné dlhodobej prevádzky často za vystavenia nepriaznivým okolitým podmienkam. Hlavnou limitáciou prevádzky senzoriky je spotreba energie, pretože doba funkčnosti zariadenia ohraničuje kapacita batérií, ktoré sú obtiažne vymeniteľné pri nasadení v nedostupných lokalitách alebo pozíciach. Senzor musí byť ideálne schopný autonómnej konfigurácie reakciou na zmenu nastatých okolností a s tým súvisí zotavenie z neočakávaných a chybových stavov [33].

Výpočtový výkon býva za cenu zníženia elektrického odberu redukovaný znížením taktovacej frekvencie a snahou efektívny manažment periférií distribúciou hodín a dostupnými úspornými režimami. Menej dostupných cyklov procesora povoľuje realizáciu jednoduchších výpočtov, ktoré zväzuje u niektorých aplikácií nutnosť odozvy v reálnom čase. Aby sa zachovala nízka cena zariadení šetrí sa na lokálne dostupnom úložisku, ktoré sa počíta v kilobajtoch nanajvýš megabajtoch.

Senzorové jednotky si buď získané dáta ukladajú na externú flash pamäť, alebo sa od nich vyžaduje komunikácia cez bezdrôtové spojenie. Prepojením na internet sa zaraďujú k zariadeniam Internetu vecí (IoT). Na rýchlosť sieťového prenosu má dopad okrem šírky pásma a réžie protokolov vzdialenosť od sieťovej brány v prípade hviezdicovej topológie alebo najbližšieho susedného uzla v mesh alebo point-to-point rozložení. Vynaloženým výkonom na príjem a vysielanie je postihnutý dosah, ktorý ovplyvňujú aj prekážky na trase a iné interferencie. Štandardne používané bezdrôtové technológie v pásmach ISM sú uvedené v tabuľke 2.1.

Na harmonizáciu využívania rádiového frekvenčného spektra pre zariadenia s krátkym dosahom sa v Slovenskej republike vzťahuje vykonávacie rozhodnutie Komisie Európskej únie 2019/1345. Definujú sa tam voľné frekvenčné pásma s povoľovaním príslušného maximálneho legálneho vysielacieho výkonu zariadení [34].

V Sub-1 GHz oblasti je k dispozícii rozsah 863 - 870 MHz využívaný LPWAN (Low-Power Wide Area Network) obmedzený časom vysielania na 0.1%, 1%, alebo 10% z hodiny a výkonom do 25 mW. Wifi (IEEE 803.11) a Bluetooth zaberajú rozsah 2400 - 2 483,5 MHz s povoleným výkonom do 100 mW na 100 KHz. Protokoly ako Bluetooth sa navyše označujú triedami podľa ponúkaného dosahu. Trieda 1 deklaruje

Bezdrôtový protokol	Frekvenčné pásmo v EÚ	Prenos max. (Mbit/s)	Prenos typ. (Mbit/s)	Dosah cca (m)
Bluetooth LE 4	2,4 GHz	1	0,3	10 - 30
Bluetooth LE 5	2,4 GHz	2	1,3	30 - 50
Wifi: 803.11 b	2,4 GHz	11	5	35 - 140
Wifi: 803.11 n	2,4 GHz	54	25	35 - 140
Wifi: 803.11 g	2,4 / 5 GHz	300 / 600	150	70 - 250
ZigBee: 802.15.4	868 MHz 2,4 GHz	20 kbit/s 250 kbit/s		10 - 100
Z-Wave	868 MHz	40 - 100 kbit/s		30 - 100
LoRaWAN	863 MHz	0,3 - 50 kbit/s		5 - 20 km
Narrowband IoT	mobilná sieť	250 kbit/s		1 - 10 km

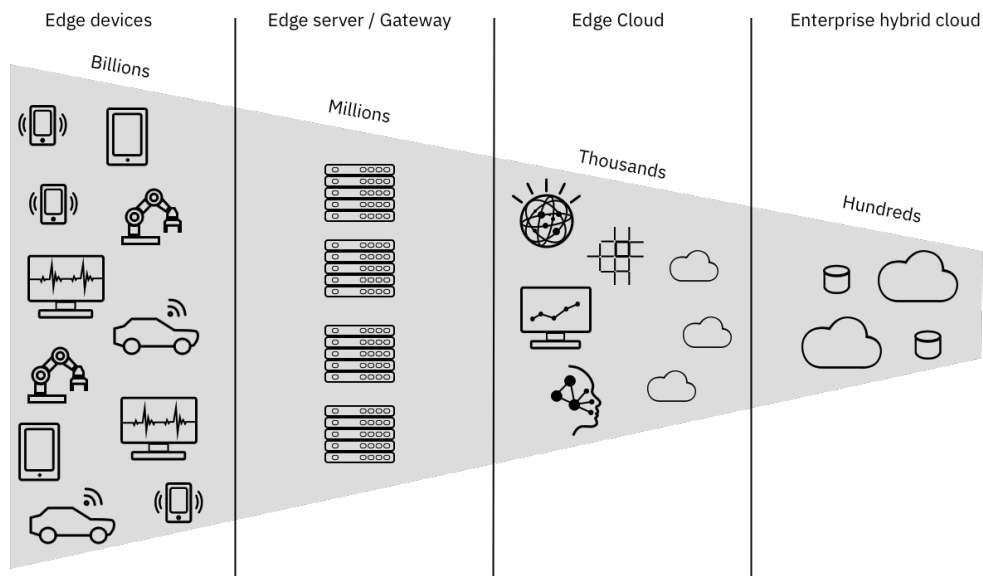
Tabuľka 2.1: Prehľad najpoužívanějších typov sietí pri IoT komunikácii

dosah do 100 metrov za výkonu do 100 mW, trieda 2 je približne do 10 metrov a do 2,5 mW a trieda 3 je na 1 meter a 1 mW [35]. IoT tiež využíva na komunikáciu mobilné siete poskytované operátormi (napr. NB-IoT, GPRS, 3G, 4G/LTE a 5G), tam sú frekvencie licencované.

Operácia uzlov sa rozdeľuje podľa podnecujúceho činiteľa ako založené na udalostiach (event-driven), dopytoch (query-driven) alebo čase (time-driven) [36]. Event-driven nepretržite vyhodnocuje vstupy ale upozorní až po zachytení náhlej zmeny alebo prekročení prahovej úrovne. Query-driven systém reaguje na aktuálne požiadavky od používateľa a odpovie so sadou dát zodpovedajúcej požiadavke. Time-driven systém pravidelne odosiela zozbierané údaje do siete podľa nastavení od riadiaceho uzla.

IoT zariadenia na okrajoch siete vytvárajú veľký objem dát, ktorý sa tradične posielal na zhromaždenie, spracovanie a analýzu na centrálny server alebo do cloudu. Posunom paradigmy s cieľom vyhodnotenia dát, čo najbližšie ku zdroju dát za zníženia latencie pri spracovaní, sieťovej premávky a záťaže na cloudové riešenie, a zvýšením bezpečnosti sa rozširuje edge computing („počítanie na okraji”) (obr. 2.11).

Edge computing je viacvrstvová distribuovaná architektúra vyvažujúca zodpovednosti a záťaž medzi tri vzájomne sa dopĺňajúce úrovne: Device edge, Local edge a Cloud [38]. Na okraji siete vrámci device edge pôsobia samotné IoT zariadenia



Obr. 2.11: Prvky architektúry Edge computing [37]

získavajúce dáta z fyzických veličín prostredia a posielajú ich sieťovým edge bránam. Local Edge zahŕňa aktívne sieťové prvky a aplikácie s úlohami, ktoré nie je možné realizovať okrajovými zariadeniami. V cloude sa zhromažďujú dáta do dlhodobého úložiska pre komplexnú a celistvú analytiku. Zároveň cloud obsahuje softvér na spravovanie a monitorovanie zdrojov.

3 Návrh riešenia

Východiskom pre riešenie spracovania akceleračných dát budú nasledujúce výskumné otázky, ktoré sa pokúsime zodpovedať za kontrolovaných aj reálnych podmienok primárne na vlastných datasetoch:


- Ako vplýva nastavenie parametrov metód časovej a frekvenčnej analýzy na úspešnosť detekcie význačných udalostí, teda náhlych zmien distribúcie v čase a hlavných frekvenčných komponentov?
- Aká úspora v množstve prenášaných dát sa dosiahne rozličnými technikami na sumarizáciu vzoriek?
- Aká je výpočtová náročnosť a časť odozvy spôsobov detekcie udalostí?
- Aká je presnosť odhadu rýchlosti a polohy z akcelerácie?
- Aká syntax pravidiel môže byť vhodná na vzdialenú konfiguráciu dátovej pipeline IoT zariadenia?
- Ktorý bezdrôtový komunikačný protokol postačuje pre implementované modely spracovania?

Navrhované zariadenie bude postavené na platforme mikrokontroléra ESP32 od Espressif, pretože pri nízkej obstarávacej cene ponúka možnosť konektivity s Wifi a Bluetooth a v porovnaní s podobnými zariadeniami dostatočný výpočtový výkon a kapacitu pamätí, čo ho činí vhodný na experimentovanie. Diagram aktivít na obr. 3.1 vizualizuje navrhovaný beh činností na zariadení.

Po zapnutí sa začne čítanie vzoriek z akcelerometra s nastaveným dynamickým rozsahom, nad určitú prahovú úroveň amplitúdy a so vzorkovacou frekvenciou podľa ODR. Podľa pravidiel aktivovaných modulmi bude súbežne vykonateľných 5 ciest spracovania.

Frekvenčná analýza bude pozostávať z krokov oknovania signálu zvoliteľnou oknovou funkciou nastaviteľnej veľkosti, následne sa signál transformuje do frekvenč-

nej domény, kde dôjde k vyhladeniu spektra kľavým priemerom alebo Welchovou metódou a nakoniec sa podľa prítomnosti špičiek vo frekvenčnom vedierku vytvorí udalosť na začiatku a na konci súvislého časového pôsobenia. Časová analýza bude detegovať náhle zmeny v priebehu signálu na základe štatistík polohy, rozptýlenosti a tvaru distribúcie vzhľadom na predošlé okná. Okrem toho sa môžu po podvzorkovaní odosielať alebo ukladať „surové dáta” hodnôt veličiny v čase alebo frekvenčných vedierok. Numerická kvadratura korigovaná obálkami umožní extrahovať zo snímaného zrýchlenia odhad o rýchlosti a polohe.



Obr. 3.1: Diagram aktivít navrhovaného systému na spracovanie dát zo senzora

Literatúra

1. BROCH, Jens Trampe. *Mechanical Vibration and Shock Measurements*. 2. vyd. Brüel & Kjær, 1984. ISBN 87-87355-34-5.
2. MOHAMMED, Zakriya; ELFADEL, Ibrahim (Abe) M.; RASRAS, Mahmoud. Monolithic Multi Degree of Freedom (MDoF) Capacitive MEMS Accelerometers. *Micromachines*. 2018, roč. 9, č. 11. ISSN 2072-666X. Dostupné z DOI: 10.3390/mi9110602.
3. TSAI, Ming-Han; LIU, Yu-Chia; SUN, Chih-Ming; WANG, Chuanwei; CHENG, Chun-Wen; FANG, Weileun. A $400 \times 400 \mu\text{m}^2$ 3-axis CMOS-MEMS accelerometer with vertically integrated fully-differential sensing electrodes. In: *2011 16th International Solid-State Sensors, Actuators and Microsystems Conference*. 2011, s. 811–814. Dostupné z DOI: 10.1109/TRANSDUCERS.2011.5969154.
4. DADAFSHAR, Majid. *Accelerometer and Gyroscopes Sensors: Operation, Sensing, and Applications*. 2014.
5. MÜLLER, Meinard. *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*. 1st. Springer, Inc., 2015. ISBN 978-3-319-21945-5. Dostupné z DOI: 10.1007/978-3-319-21945-5.
6. *iNEMO inertial module: 3D accelerometer, 3D gyroscope, 3D magnetometer*. 2015. Č. LSM9DS1. Rev. 3.
7. *Micropower, 3-Axis, $\pm 2 \text{ g}/\pm 4 \text{ g}/\pm 8 \text{ g}$ Digital Output MEMS Accelerometer*. 2019. Č. ADXL362. Rev. F.
8. *Low Noise, Low Drift, Low Power, 3-Axis MEMS Accelerometers*. 2020. Č. ADXL356. Rev. A.

-
9. QUARTERONI, Alfio; SACCO, Riccardo; SALERI, Fausto. Numerical Mathematics. In: Springer Inc., 2000, kap. 9. Numerical Integration, s. 371–398. ISBN 0-387-98959-5.
 10. YANG, Yanli; ZHAO, Yanfei; KANG, Dali. Integration on acceleration signals by adjusting with envelopes. *Journal of Measurements in Engineering*, 2016, roč. 4, s. 117–121.
 11. MUTHUKRISHNAN, S. Data Streams: Algorithms and Applications. *Foundations and Trends in Theoretical Computer Science*. 2005, roč. 1, č. 2, s. 117–236. ISSN 1551-305X. Dostupné z DOI: 10.1561/04000000002.
 12. PAJUREK, Tomáš. *Online Anomaly Detection in Time-Series*. Fakulta informačních technologií, České vysoké učení technické v Praze, 2018. Dostupné tiež z: <https://dspace.cvut.cz/bitstream/handle/10467/76417/F8-DP-2018-Pajurek-Tomas-thesis.pdf>. Dipl. pr.
 13. NIELSEN, Aileen. *Practical Time Series Analysis: Prediction with Statistics and Machine Learning*. O'Reilly Media, 2019. ISBN 978-1-4920-4165-8.
 14. NEUBAUER, Jiří; SEDLÁČEK, Marek; KŘÍŽ, Oldřich. *Základy statistiky - Aplikace v technických a ekonomických oborech*. 1. vyd. Grada Publishing, a.s., 2012. ISBN 978-80-247-4273-1.
 15. KNUTH, Donald E. The Art of Computer Programming. In: 2. vyd. Addison-Wesley, 1981, zv. 2, kap. 4.2.2, s. 216. ISBN 0-201-03822-6.
 16. SCHNEIDER, Roger. Survey of Peaks/Valleys identification in Time Series. 2011. Department of Informatics, University of Zürich.
 17. YANG, Chao; HE, Zengyou; YU, Weichuan. Comparison of public peak detection algorithms for MALDI mass spectrometry data analysis. *BMC bioinformatics*. 2009, roč. 10, s. 4. Dostupné z DOI: 10.1186/1471-2105-10-4.
 18. O'HAYER, Thomas. A Pragmatic Introduction to Signal Processing. In: 2020, kap. Peak Finding and Measurement. ISBN 979-86-11-26668-7. Dostupné tiež z: <https://terpconnect.umd.edu/~toh/spectrum/>.

19. ARGÜELLO-PRADA, Erick Javier. The mountaineer's method for peak detection in photoplethysmographic signals. *Revista Facultad de Ingeniería Universidad de Antioquia*. 2019, č. 90, s. 42–50. Dostupné z DOI: 10.17533/udea.redin.n90a06.
20. RASCHKA, Sebastian. An Overview of General Performance Metrics of Binary Classifier Systems. *CoRR*. 2014, roč. abs/1410.5330. Dostupné z arXiv: 1410.5330.
21. FAWCETT, Tom. An introduction to ROC analysis. *Pattern Recognition Letters*. 2006, roč. 27, č. 8, s. 861–874. ISSN 0167-8655. Dostupné z DOI: <https://doi.org/10.1016/j.patrec.2005.10.010>. ROC Analysis in Pattern Recognition.
22. LYONS, Richard G. *Understanding Digital Signal Processing*. 3. vyd. Pearson Education, Inc., 2011. ISBN 978-0-13-702741-5.
23. PRANDONI, Paolo; VETTERLI, Martin. *Signal Processing for Communications*. EPFL Press, 2008. ISBN 978-2-940222-20-9.
24. KHAYAM, Syed Ali. The Discrete Cosine Transform (DCT): Theory and Application. *Course Notes, Department of Electrical & Computer Engineering*. 2003.
25. STRANG, Gilbert. The Discrete Cosine Transform. *SIAM Rev.* 1999, roč. 41, č. 1, s. 135–147. ISSN 0036-1445. Dostupné z DOI: 10.1137/S0036144598336745.
26. SHAO, Xuancheng; JOHNSON, Steven G. Type-IV DCT, DST, and MDCT algorithms with reduced numbers of arithmetic operations. *CoRR*. 2007. Dostupné tiež z: <http://arxiv.org/abs/0708.4399>.
27. CHU, Eleanor; GEORGE, Alan. *Inside the FFT Blackbox: Serial and Parallel Fast Fourier Transform Algorithms*. CRC Press LLC, 2000. Computational Mathematics. ISBN 0-8493-0270-6.
28. KUMAR, G Ganesh; SAHOO, Subhendu; MEHER, P.K. 50 Years of FFT Algorithms and Applications. *Circuits, Systems, and Signal Processing*. 2019, roč. 38. Dostupné z DOI: 10.1007/s00034-019-01136-8.

29. DUHAMEL, P.; HOLLMANN, Henk. 'Split radix' FFT algorithm. *Electronics Letters*. 1984, roč. 20, s. 14–16. Dostupné z DOI: 10.1049/el:19840012.
30. MAKHOUL, J. A fast cosine transform in one and two dimensions. *IEEE Transactions on Acoustics, Speech, and Signal Processing*. 1980, roč. 28, č. 1, s. 27–34. Dostupné z DOI: 10.1109/TASSP.1980.1163351.
31. HEINZEL, G.; RÜDIGER, A.; SCHILLING, R. Spectrum and spectral density estimation by the Discrete Fourier transform (DFT), including a comprehensive list of window functions and some new at-top windows. In: 2002.
32. WELCH, P. The use of fast Fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms. *IEEE Transactions on Audio and Electroacoustics*. 1967, roč. 15, č. 2, s. 70–73. Dostupné z DOI: 10.1109/TAU.1967.1161901.
33. MATIN, M.A.; ISLAM, M.M. Overview of Wireless Sensor Network. In: MARTIN, Mohammad A. (ed.). *Wireless Sensor Networks*. IntechOpen, 2012, kap. 1, s. 1–22. ISBN 978-953-51-0735-4. Dostupné z DOI: 10.5772/49376.
34. Vykonávacie rozhodnutie Komisie (EÚ) 2019/1345 z 2. augusta 2019, ktorým sa mení rozhodnutie 2006/771/ES s cieľom aktualizovať harmonizované technické podmienky v oblasti využívania rádiového frekvenčného spektra pre zariadenia s krátkym dosahom. *OJ*. 2019-08-13, roč. L 212, s. 53–72.
35. *Bluetooth Technology Website / The Official Website of Bluetooth Technology*. Dostupné tiež z: <https://www.bluetooth.com/>.
36. DJEDOUBOUM, Asside; ARI, Ado; GUEROUI, Abdelhak; MOHAMADOU, Alidou; ALIOUAT, Zibouda. Big Data Collection in Large-Scale Wireless Sensor Networks. *Sensors*. 2018, roč. 18. Dostupné z DOI: 10.3390/s18124474.
37. IYENGAR, Ashok; OUYANG, Christine. *Edge computing architecture*. Dostupné tiež z: <https://www.ibm.com/cloud/architecture/architectures/edge-computing/>.
38. MAGESH, S.; INDUMATHI, J.; S, Radha RamMohan.; R, Niveditha V.; PRABHA, P. Shanmuga. Concepts and Contributions of Edge Computing in Internet of Things (IoT): A Survey. In: 2020, zv. 7, s. 146–156. Č. 5. Dostupné z DOI: 10.22247/ijcna/2020/203914.

Príloha A: Harmonogram práce

A.1 Zimný semester

Obdobie	Náplň práce
1.týždeň	Základný prehľad relevantnej literatúry.
2.týždeň	Štúdium literatúry ohľadom monitorovania vibrácií. Pokusný zber dát akcelerácie z MHD pomocou akcelerometra na smartfóne a ich prieskumná analýza.
3.týždeň	Štúdium článkov o frekvenčnej analýze a rešerš algoritmov na hľadanie špičiek. Implementácia objavených prístupov hľadania špičiek a aplikovanie na merania vibrácií z električiek a autobusu.
4.týždeň	Flashovanie firmvéru na vývojový kit iCOMOX.
5.týždeň	Osnova práce s referenciami na nájdenú literatúru.
6.týždeň	Firmvér pre dosku na platforme ESP32 pre zaznam akceleračných dát na SD kartu cez OpenLog
7.týždeň	Merania vibrácií v MHD a analýza získaných záznamov v jupyter notebooku. Doplnenie zdrojov pre časti osnovy s málo referenciami.
8.týždeň	Sekcia 2.1. práce o monitorovaní vibrácií a šoku.
9.týždeň	Doplnenie typov akcelerometrov a časti o numerickej kvadratúre k sekcii 2.1. Úvod do sekcie 2.2. o analýze v časovej doméne.
10.týždeň	Deskriptívne štatistiky a algoritmy na identifikáciu špičiek.
11.týždeň	Sekcia 2.2. o frekvenčnej a časovo-frekvenčnej analýze signálu.
12.týždeň	Sekcia 2.3 o architektúre senzorových sietí a ich obmedzeniach. Návrh riešenia a úvod k priebežnej správe BP1
13.týždeň	Zapracované pripomienky k prezentovanému návrhu.

A.2 Letný semester

Obdobie	Orientačný plán práce
1. – 3. týždeň	Odladovanie modelov na monitorovanie vibrácií na základe analyzovaných algoritmov. Meranie úspešnosti na synteticky generovaných dátach.
4. – 6. týždeň	Návrh a prvotná implementácia firmvéru pre senzorovú jednotku s loggovaním výstupných udalostí na pamäťovú kartu.
7. – 9. týždeň	Optimalizácia posielaných dát cez zvolený bezdrôtový sieťový protokol. Vzdialená konfigurácia zariadenia.
10 – 13.týždeň	Experimenty so senzorovou jednotkou v kontrolovanom a reálnom prostredí. Vyhodnotenie výskumných otázok.