

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-1234-98765

Miroslav Hájek

Spracovanie dát generovaných senzorovou IoT sieťou

Bakalárska práca

Vedúci práce: Ing. Marcel Baláž, PhD.

Máj 2022

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-1234-98765

Miroslav Hájek

Spracovanie dát generovaných senzorovou IoT sieťou

Bakalárska práca

Študijný program: Informatika

Študijný odbor: Informatika

Miesto vypracovania: Ústav počítačového inžinierstva a aplikovanej informatiky

Vedúci práce: Ing. Marcel Baláž, PhD.

Pedagogický vedúci: Ing. Jakub Findura

Máj 2022

Bakalársky projekt

Akademický rok:	2021/2022
Vedúci projektu:	Ing. Marcel Baláž, PhD.
Pedagogický vedúci:	Ing. Jakub Findura
Pridelený študentovi:	Miroslav Hájek
Študijný program:	Informatika
Miesto vypracovania:	Ústav počítačového inžinierstva a aplikovanej informatiky, FIIT STU

Spracovanie dát generovaných senzorovou IoT sieťou

Senzorové IoT siete sa stali bežnou súčasťou rôznych priemyselných procesov. Ich primárnou úlohou je zbieranie rôznorodých dát z prostredia, ich ukladanie a vyhodnocovanie v reálnom čase. Analyzovanie a vyhodnocovanie dát pri nepretržitom monitorovaní už len z malého množstva senzorov predstavuje veľkú výzvu. Sensory produkujú veľké množstvo dát a anomálie nemusia byť na prvý pohľad detegovateľné.

Cieľom projektu je analyzovať dáta zachytené senzorovou sieťou. Analyzovať algoritmy na ich ukladanie a spracovanie. Analyzujte jednotlivé úrovne senzorovej siete a identifikujte miesta, kde by sa dali dáta čiastočne spracovať. Na základe analýzy navrhnete spôsob ukladania a spracovania dát, prípadne optimalizáciu toku dát pre existujúcu senzorovú sieť. Vaše riešenie implementujte a otestujte jeho funkčnosť.

Čestné prehlásenie

Čestne vyhlasujem, že som túto prácu vypracoval samostatne, na základe konzultácií a s použitím uvedenej literatúry.

V Bratislave, 1.5.2022

.....

Miroslav Hájek

Pod'akovanie

Text pod'akovania

Anotácia

Slovenská technická univerzita v Bratislave

Fakulta informatiky a informačných technológií

Študijný program: Informatika

Autor: Miroslav Hájek

Bakalárska práca: Spracovanie dát generovaných senzorovou IoT sieťou

Vedúci bakalárskej projektu: Ing. Marcel Baláž, PhD.

Pedagogický vedúci: Ing. Jakub Findura

Máj 2022

Stručná charakteristika zadania bakalárskeho projektu ale predovšetkým výsledkov bakalárskeho projektu v slovenskom a anglickom jazyku každá v rozsahu max. 1 strany A4 (hlavička + cca 150-200 slov).

Annotation

Slovak University of Technology Bratislava

Faculty of Informatics and Information Technologies

Degree course: Informatics

Author: Miroslav Hájek

Bachelor's Thesis: Data Processing for Sensor IoT Network

Supervisor: Ing. Marcel Baláž, PhD.

Departmental advisor: Ing. Jakub Findura

2022, May

Annotation text in English, 150-200 words.

Obsah

1	Úvod	1
2	Analýza	3
2.1	Senzorová sieť	3
2.1.1	Senzorová jednotka	4
2.2	Monitorovanie vibrácií a šoku	5
2.2.1	Meranie fyzikálnej veličiny akcelerácie	6
2.2.2	MEMS kapacitný akcelerometer	6
2.2.3	Analógovo-digitálny prevodník	6
2.2.4	Odvodzovanie rýchlosti a polohy zo zrýchlenia	6
2.3	Metódy analýzy signálu v časovej doméne	6
2.3.1	Číselné charakteristiky štatistického rozdelenia	6
2.3.2	Prúdové algoritmy	7
2.3.3	Online detekcia anomálií a odchýliek pozorovaní	7
2.3.4	Klastrovanie s DBSCAN a LOF, Extrakcia features a PCA . .	8
2.3.5	Algoritmy na rozpoznávanie špičiek	8
2.4	Frekvenčná a časovo-frekvenčná analýza signálu	8
2.4.1	Fourierová transformácia	9
2.4.2	Algoritmus FFT pre DFT a DCT	9
2.4.3	Oknové funkcie	10
2.4.4	Filtre s konečnou impulznou odozvou	10
2.4.5	Hilbert–Huangova transformácia: Empirická modálna dekom- pozícia (EMD)	10
3	Opis riešenia	13
3.1	Hardvér senzorovej jednotky	13
3.2	Vývojové prostredie a knižnice	13

3.3	Koordinácia subsystémov	14
3.4	Konzervácia energie znížením vzorkovania	14
3.5	Pravidlový systém na extrahovanie črt záujmu	14
4	Zhodnotenie	17
A	Technická dokumentácia	
B	Harmonogram práce	
C	Obsah digitálneho média	

1 Úvod

2 Analýza

2.1 Senzorová sieť

Nízko-energetické zariadenia komunikujúce cez odľahčené sieťové protokoly so snahou spracovania v reálnom čase a ponechaním najdôležitejších informácií dolovaním z veľkého množstva zdrojových dát. Cloud / Fog computing. Sink a Edge nodes

Vlastnosti senzorovej siete

- Autokonfigurácia senzora - reakcia na zmeny v sieti a prostredia pôsobenia
- Škálovateľnosť - veľké množstvo senzorov so spoločným účelom a schopnosťou vzájomnej kooperácie a interoperability.
- Odolnosť voči chybám - v prípade pridania alebo odobratia uzla budú spojenia bez prerušenia.
- Energeticky efektívna komunikácia uzlov - s upravenými protokolmi štandardného sieťového zásobníka
 - Event-driven - stály zber dát a reakcia na náhle zmeny. posielajú údaje až po prekročení kritického prahu
 - Query-driven - zbierajú údaje iba po prijatí dopytu od používateľa
 - Time-driven - pravidelne odosielať údaje sinku. vzorkovaciu frekvenciu volí sink

[1]

Spracovanie toku informácií (IFP - Information flow processing) - nástroj na včasné spracovanie dát ako tečie z periférií do centra systému. Snahou je ukladanie agregovaných štatistík, napr. detektor požiaru za použitia čidiel teploty a dymu nepotrebuje ukladať jednotlivé merania, lebo sú samo o sebe nepodstatné. Keď

nastane varovná situácia, je potrebné aby tá obsahoval všetky údaje na lokalizáciu ohniska.

CEP - Complex event processing - spracúva toky udalosti zo zdrojov reálneho sveta na základe aplikovania aktívnych pravidiel stanovených správcami systému a poupraví toky do komplexnejšieho výstupu. Pravidlá sú v tvare Event-Condition-Action (ECA).

- Udalosť - definuje zdroje ako generátory udalostí
- Podmienka - uvažuje ktorá časť udalosti bude braná do úvahy pri spracovaní, napr. môže ísť o prekročenie prahu
- Akcia - aká sada úloh má byť vykonaná pri detekcii udalosti

Behové pravidlá sú spracúvané vo viacerých fázach

- Signalizácia - detekcia udalosti
- Spustenie - asociácia udalosti so sadou pravidiel
- Vyhodnotenie - vyhodnotenie podmienky
- Plánovanie - stanovenie poradia vykonania
- Vykonanie - vykonanie pravidiel

[2]

2.1.1 Senzorová jednotka

Súčasti senzorovej jednotky:

- Zberná jednotka
- Výpočtová jednotka
- Komunikačná jednotka
- Napájacia jednotka

Obmedzenia na senzorové uzly

- Spotreba energie - energetická autonómia uzlov vo WSN umožňuje nasadzovanie zariadení do odľahlých miest pre využitie v inteligentných mestách alebo na účely ochrany prírody. životnosť senzorovej jednotky je ohraničená kapacitou batérie.
- Dosah komunikácie - Sensory disponujú obmedzenou energiou na vysielanie a dosah je negatívne ovplyvnený silou signálu na anténe. Z toho vyplývajú aj nižšie prenosové rýchlosti.
- Výpočtový výkon a úložisko - Nízka taktovacia frekvencia procesora v megahercoch a veľkosti pracovných pamätí v stovkách kilobajoch alebo megabajtoch.

[3]

Za ideálnych okolností by sa mal online algoritmus učiť kontinuálne bez ukladania predošlých bodov a detekcií. V rozhodnutiach algoritmu sú zahrnuté informácie o všetkých predošlých bodoch do terajšieho rozhodnutia. Mal by mať schopnosť sa adaptovať dynamickému prostrediu, v ktorom pôsobí. Bez nutnosti manuálnych úprav parametrov modelu. Zároveň je žiaduce minimalizovať falošné pozitíva a negatíva pri detekcii udalostí.

Kontinuálne spracovanie častokrát vyžaduje, aby boli dáta rozdelené do rovnako dlhých blokov zvaných okná. Okno $\mathcal{W}_{\sigma,\pi}$ je funkciou morfujúca maticu vstupných dát X do vektora $w = (W_1, \dots, W_q)$ [4]

2.2 Monitorovanie vibrácií a šoku

Vibrácie sú pohyb hmoty okolo rovnovážneho stavu, ktorý býva vzniká zväčša ako vedľajší nežiaduci produkt inak užitočných javov. Dlhodobé vystavenie súčiastok na vibrácie môže napr. poškodzovať ložiská motorov.

Fyzikálny model vibrácii (s jedným stupňom voľnosti) ako oscilatórny systém Zjednodušený mechanický model s pružinou (kx), tlmič ($c\frac{dx}{dt}$) a hmota ($m\frac{d^2x}{dt^2}$) Odozva na mechanické vibrácie (voľné a nútené) a šok [5]

2.2.1 Meranie fyzikálnej veličiny akcelerácie

Data pipeline - Technológia MEMS 3DOF akcelerometrov, Vzorkovanie, kvantovanie, kódovanie analógovo-digitálnym prevodíkom -

2.2.2 MEMS kapacitný akcelerometer

[6]

2.2.3 Analógovo-digitálny prevodník

vzorkovacia frekvencia, aliasing, prepočet z A/D hodnoty na akceleráciu. Kvantizačný šum

Adaptívne vzorkovanie - preskočenie vzorky, keď je predpoklad, že na základe existujúcich vzoriek vieme dostatočne dobre odhadnúť budúce čítania. [7]. Efekt zberu až po prekročení prahu intenzity akcelerácie na signál.

2.2.4 Odvodzovanie rýchlosti a polohy zo zrýchlenia

fyzikálne vzťahy pre polohu, rýchlosť a zrýchlenie, numerická derivácia a integrácia (obdĺžnikové, lichobežníkové, Simposonovo pravidlo) [8]

$$a = x_{ADC} \cdot \frac{(2^{b_{ADC}}/2)}{(G_{res} \cdot g)}; g = 9.81 \text{ m/s}^2; b_{ADC} = 12 \text{ bit}; G_{res} = 2g \quad (2.1)$$

2.3 Metódy analýzy signálu v časovej doméne

časový rad, okná [9] [10] [11] [12], online algoritmus [4], požiadavky na efektívne algoritmy

2.3.1 Číselné charakteristiky štatistického rozdelenia

bodové odhady momentov. výberový priemer = stredná hodnota, výberový rozptyl (Welfordov online algoritmus), šikmosť, špicatosť, kvantily, normálne rozdelenie pravdepodobnosti

2.3.2 Prúdové algoritmy

stream algorithm models, Data Stream Model - cash register, turnstile, time series, window model Odhad momentov, Rátanie frekvencií, Zistenie či sa dopyt už vyskytol Count-min sketch (<https://florian.github.io/count-min-sketch/>) - probabilistická dátová štruktúra

Shewart Control Chart, CUSUM

2.3.3 Online detekcia anomálií a odchýliek pozorovaní

Outlier je pozorovanie, ktoré sa odchyľuje, tak významne od ostatných pozorovaní, že vzbudzuje podozrenie, že bolo vytvorené odlišným mechanizmom. Normálne dáta, Šum, Anomálie (slabé a silné odchýlky) Výstupy algoritmov na detekciu výchyliet:

- Outlier skóre - miera vychýlenosti bodu
- Binárne štítky - binárne štítky, označenie, či je bod anomália alebo nie.

Algoritmy na anomálie vytvárajú model normálnych vzorov v dátach a skóre vychýlenosti je dané deviáciou od týchto vzorov. [13] Hampel filter

[14] Množstvo prenášaných a spracovaných dát prevyšuje ľudskú schopnosť manuálneho prieskumu. Anomália je pozorovanie alebo postupnosť pozorovaní, ktoré sa významne odchyľuje od distribúcie zvyšku dát.

- Bodové anomálie - x_t je bodová anomália ak sa jeho hodnota významne odlišuje od všetkých bodov v intervale $[x_{t-k}; x_{t+k}]$
- Kolektívne (disonanancie) - jednotlivé body nepredstavujú anomálne správanie, až ak vezmeme dlhšiu postupnosť môže byť označená za anomáliu.
- Kontextové výchyľky / anomálie - body sú normálne v určitom kontexte, ale v inom anomálne.

[15] [16]

$$|x - \hat{x}| \geq \theta \tag{2.2}$$

Bežiaci filter [17]

Skóre anomálnosti, binárny klasifikátor, Falošne pozívny - proces je normálny, ale registrujeme neočakávané správanie, Falošne negatívny - proces je abnormálny, ale správanie prechádza bez povšimnutia Matica zámen, Precision, Recall, ROC - kvalita binárneho klasifikátora v závislosti od prahu, AUC [18]

Z-score a Z-test:

$$z = \frac{|x - \mu|}{\sigma} \approx \frac{|x - \bar{x}|}{S} \quad (2.3)$$

Bežiaci priemerovací filter [17]

Zisťovanie výchyliet testovaním štatistických hypotéz: generalized extreme Studentized deviate test [11]

Median Absolute Deviate (robustná štatistika na určenie vychýlenosti od normálu)

$$MAD = \text{median}(|X_i - \bar{X}|) \quad (2.4)$$

[19]

2.3.4 Klastrovanie s DBSCAN a LOF, Extrakcia features a PCA

2.3.5 Algoritmy na rozpoznávanie špičiek

lokálne minimá a maximá extrémny - cez prvú a druhú deriváciu, topografická prominencia a izolácia - relatívna výška vrchola / extrémny,

[20] [21] [22] [23]

2.4 Frekvenčná a časovo-frekvenčná analýza signálu

vlastnosti frekvenčného spektra, decibele, spektrogram, odstup od šumu (SNR), power spectrum density (dbFS), spektrálny analyzátor

2.4.1 Fourierová transformácia

Diskrétna fourierová transformácia mapuje sínál dĺžky N do množiny N diskretných frekvenčných komponentov. [24]

$$X = \mathbf{W}x; W_{nk} = e^{-i\frac{2\pi}{N}nk} = W_N^{nk} \quad (2.5)$$

Inverzná transformácia

$$x = \frac{1}{N} \mathbf{W}^H X \quad (2.6)$$

Integrálne transformácie: Fourierová transformácia (CFT, DFT), Kosínusová transformácia (MDCT), Vlnková transformácia (CWT) [25] [26]

$$T(n) = \int f(t)K(t, x)dt \quad (2.7)$$

$$\mathcal{F} : X(\omega) = \int_{-\infty}^{+\infty} x(t) \cdot e^{-i\omega t} dt \quad (2.8)$$

2.4.2 Algoritmus FFT pre DFT a DCT

Opis DIT radix-2 FFT algoritmus komplexných, reálny, pre MDCT [27]

$$X(m) = \sum_{n=0}^{N-1} x(n) \cdot e^{-i2\pi nm/N} \quad (2.9)$$

Frekvenčné rozlíšenie

$$\Delta f = \frac{f_s}{N} \quad (2.10)$$

2.4.3 Oknové funkcie

Gaborová transformácia, Prehľad okien a ich transformácií (sinc), Efekt oknových funkcií na spectral leakage, výhodné percentá prekryvu FT [28] [29] Priemerovanie a prekryv - Amplitude Flatness (AF), Power Flatness (PF), Overlap Correlation (OC)

2.4.4 Filtre s konečnou impulznou odozvou

Roziel medzi FIR a IIR, Dolná pripust', pásmová priepust', horná pripust', Konvolúcia a konvolučné jadro, konvolučná veta, účel: identifikácia prítomnosti známej frekvencie v signále akcelerácie

$$y(n) = \sum_{k=0}^{D_y} x(k) \cdot h(n-k) = x(n) * h(n) \quad (2.11)$$

Prenosová funkcia

$$H(\Omega) = \frac{Y(\Omega)}{X(\Omega)} \quad (2.12)$$

Detektor obálok ^{1 2}

2.4.5 Hilbert–Huangova transformácia: Empirická modálna dekompozícia (EMD)

Odhad okamžitej frekvencie, DESA, TKEO (Teager-Kaiserov energetický operátor) [30]

$$\psi(x(n)) = x^2(n) - x(n-1) \cdot x(n+1) \approx A^2 \omega^2 \quad (2.13)$$

¹<https://www.mathworks.com/help/dsp/ug/envelope-detection.html>

²<https://www.dsprelated.com/showarticle/938.php>

3 Opis riešenia

Požiadavky

- Najvhodnejší spôsob identifikácie lokálnych extrémov - špičiek
- Možnosti redukcie zberu dát za cenu redukcie energetické nároky a prenosu významných črt signálu
- Pravidlový systém na definíciu udalostí záujmu operátorov a ich spoľahlivá identifikácia
- Upozornenie na nezvyčajnosti pri prevoze (detekciou anomálií) - veľká nerovnosť, neočakávaný pohyb

Senzorová jednotka s akcelerometrom na meranie vibrácií a nárazov pri prevoze krehkých látok/materiálov upozorňujúca na základe konfigurovateľných pravidiel alebo nezvyčajných vzorov (pozn.:lepšie dodefinovať). Preskúmanie možností redukcie zberu alebo nasnímaných údajov - nastavenie vzorkovacej frekvencie / akceptovanie nad stanovenú amplitúdu / kompresia. Rozšírenie: /distribuovaná/ korelácia údajov z viacerých akcelometrov z jedného balíka / vozidla.

3.1 Hardvér senzorovej jednotky

3.2 Vývojové prostredie a knižnice

CMSIS, MDK5, OPENOCD, GCC

3.3 Koordinácia subsystémov

3.4 Konzervácia energie znížením vzorkovania

3.5 Pravidlový systém na extrahovanie črt záujmu

Táto časť bakalárskeho projektu obsahuje opis výsledkov riešenia jednotlivých etáp projektu. V prípade, že záverečný projekt nerieši všetky etapy, malo by byť v príslušnej časti uvedené kto, resp. kde sa príslušná etapa rieši/riešila/bude riešiť.

Typické etapy riešenia pri tvorbe softvérového systému:

- špecifikácia požiadaviek
- návrh
- implementácia (ak to zadanie požaduje)
- overenie riešenia

Podľa možnosti treba vychádzať zo známych prístupov (napr. pri softvérových projektoch štruktúrovaný alebo objektovo orientovaný prístup) a techník (napr. blokové schémy, vývojové diagramy, UML, entito-relačné diagramy atď.). Táto časť práce závisí od konkrétneho zadania. Je dôležité prezentovať návrhové rozhodnutia, alternatívy, ktoré sa zvažovali pri riešení a samotný návrh riešenia zadaného problému. Štruktúrovanie textu tejto časti BP by malo vychádzať zo zadanej úlohy, ktorá sa rieši. Najmä v tejto časti študent preukazuje tvorivý prístup k riešeniu problémov a kritické myslenie.

4 Zhodnotenie

Hlavné výsledky práce, prípadne porovnanie s inými prístupmi, možné smery ďalšieho rozvíjania. Tu sa musí presne špecifikovať, čo je pôvodné a čo riešiteľ prebral.

Literatúra

1. MATIN, M.A.; ISLAM, M.M. Overview of Wireless Sensor Network. In: MATIN, Mohammad A. (ed.). *Wireless Sensor Networks*. IntechOpen, 2012, kap. 1, s. 1–22. ISBN 978-953-51-0735-4. Dostupné z DOI: 10.5772/49376.
2. CUGOLA, Gianpaolo; MARGARA, Alessandro. Processing Flows of Information: From Data Stream to Complex Event Processing. *ACM Computing Surveys*. 2012, roč. 44, č. 3. ISSN 0360-0300. Dostupné z DOI: 10.1145/2187671.2187677.
3. DJEDOUBOUM, Asside; ARI, Ado; GUEROUI, Abdelhak; MOHAMADOU, Alidou; ALIOUAT, Zibouda. Big Data Collection in Large-Scale Wireless Sensor Networks. *Sensors*. 2018, roč. 18. Dostupné z DOI: 10.3390/s18124474.
4. PAJUREK, Tomáš. *Online Anomaly Detection in Time-Series*. Fakulta informačních technologií, České vysoké učení technické v Praze, 2018. Dostupné tiež z: <https://dspace.cvut.cz/bitstream/handle/10467/76417/F8-DP-2018-Pajurek-Tomas-thesis.pdf>. Dipl. pr.
5. BROCH, Jens Trampe. *Mechanical Vibration and Shock Measurements*. 2. vyd. Brüel & Kjær, 1984. ISBN 87-87355-3-4-5.
6. MOHAMMED, Zakriya; ELFADEL, Ibrahim (Abe) M.; RASRAS, Mahmoud. Monolithic Multi Degree of Freedom (MDoF) Capacitive MEMS Accelerometers. *Micromachines*. 2018, roč. 9, č. 11. ISSN 2072-666X. Dostupné z DOI: 10.3390/mi9110602.
7. LAW, Yee Wei; CHATTERJEA, Supriyo; JIN, Jiong; HANSELMANN, Thomas; PALANISWAMI, Marimuthu. Energy-efficient data acquisition by adaptive sampling for wireless sensor networks. In: *Proceedings of the 2009 International Conference on Wireless Communications and Mobile Computing*:

- Connecting the World Wirelessly*. Association for Computing Machinery, 2009, s. 1146–1151. IWCMC '09. ISBN 978-1-60558-569-7. Dostupné z DOI: 10.1145/1582379.1582631.
8. YANG, Yanli; ZHAO, Yanfei; KANG, Dali. Integration on acceleration signals by adjusting with envelopes. *Journal of Measurements in Engineering*, 2016, roč. 4, s. 117–121.
9. WEI, William W.S. *Time Series Analysis: Univariate and Multivariate Methods*. 2. vyd. Pearson Education, Inc., 2006. ISBN 0-321-32216-9.
10. NIELSEN, Aileen. *Practical Time Series Analysis: Prediction with Statistics and Machine Learning*. O'Reilly Media, 2019. ISBN 978-1-492-04165-8.
11. NIST/SEMATECH. *e-Handbook of Statistical Methods: Generalized ESD Test for Outliers*. 2012. Dostupné z DOI: <https://doi.org/10.18434/M32189>.
12. HOCHENBAUM, Jordan; VALLIS, Owen S.; KEJARIWAL, Arun. Automatic Anomaly Detection in the Cloud Via Statistical Learning. *CoRR*. 2017, roč. abs/1704.07706.
13. AGGARWAL, Charu C. *Outlier Analysis*. 2. vyd. Springer Publishing Company, Inc., 2016. ISBN 978-3-319-47578-3.
14. BRAEI, Mohammad; WAGNER, Sebastian. Anomaly Detection in Univariate Time-series: A Survey on the State-of-the-Art. *CoRR*. 2020, roč. abs/2004.00433. Dostupné tiež z: <https://arxiv.org/abs/2004.00433>.
15. BLÁZQUEZ-GARCÍA, Ane; CONDE, Angel; MORI, Usue; LOZANO, Jose Antonio. A review on outlier/anomaly detection in time series data. *CoRR*. 2020, roč. abs/2002.04236. Dostupné tiež z: <https://arxiv.org/abs/2002.04236>.
16. MEHROTRA, Kishan G.; MOHAN, Chilukuri K.; HUANG, HuaMing. *Anomaly Detection Principles and Algorithms*. Springer Publishing Company, Inc., 2017. ISBN 978-3-319-67524-4.
17. GIANNONI, Federico; MANCINI, M.; MARINELLI, Federico. Anomaly Detection Models for IoT Time Series Data. *ArXiv*. 2018, roč. abs/1812.00890. Dostupné tiež z: <https://arxiv.org/pdf/1812.00890.pdf>.

18. ZHANG, Yang; MERATNIA, Nirvana; HAVINGA, Paul. Outlier Detection Techniques for Wireless Sensor Networks: A Survey. *IEEE Communications Surveys Tutorials*. 2010, roč. 12, č. 2, s. 159–170. Dostupné z DOI: 10.1109/SURV.2010.021510.00088.
19. BASSEVILLE, Michèle; NIKIFOROV, Igor. *Detection of Abrupt Change Theory and Application*. 1993. ISBN 0-13-126780-9.
20. SCHNEIDER, Roger. Survey of Peaks/Valleys identification in Time Series. 2011. Department of Informatics, University of Zürich.
21. ARGÜELLO-PRADA, Erick Javier. The mountaineer's method for peak detection in photoplethysmographic signals. *Revista Facultad de Ingeniería Universidad de Antioquia*. 2019, č. 90, s. 42–50. Dostupné z DOI: 10.17533/udea.redin.n90a06.
22. RAHMAN, M.S.; CHOI, C.; KIM, Y.-P; KIM, S. A simple and robustness algorithm for ECG R-peak detection. *Journal of Electrical Engineering and Technology*. 2018, roč. 13, s. 2080–2085. Dostupné z DOI: 10.5370/JEET.2018.13.5.2080.
23. SCHOLKMANN, Felix; BOSS, Jens; WOLF, Martin. An Efficient Algorithm for Automatic Peak Detection in Noisy Periodic and Quasi-Periodic Signals. *Algorithms*. 2012, roč. 5, č. 4, s. 588–603. ISSN 1999-4893. Dostupné z DOI: 10.3390/a5040588.
24. PRANDONI, Paolo; VETTERLI, Martin. *Signal Processing for Communications*. EPFL Press, 2008. ISBN 978-2-940222-20-9.
25. AHMED, Nasir; NATARAJAN, T; RAO, Kamisetty R. Discrete cosine transform. *IEEE transactions on Computers*. 1974, roč. 100, č. 1, s. 90–93.
26. KOVAČEV, Radovan. *Časově-frekvenční analýza signálu*. Fakulta informačních technologií, Vysoké učení technické v Brně, 2012. Dipl. pr.
27. CHU, Eleanor; GEORGE, Alan. *Inside the FFT Blackbox: Serial and Parallel Fast Fourier Transform Algorithms*. CRC Press LLC, 2000. Computational Mathematics. ISBN 0-8493-0270-6.

28. LYONS, Richard G. *Understanding Digital Signal Processing*. 3. vyd. Pearson Education, Inc., 2011. ISBN 978-0-13-702741-5.
29. HEINZEL, G.; RÜDIGER, A.; SCHILLING, R. Spectrum and spectral density estimation by the Discrete Fourier transform (DFT), including a comprehensive list of window functions and some new at-top windows. In: 2002.
30. POTOČŇÁK, Tomáš; KOZUMPLÍK, Jiří. Časovo-frekvenčná analýza spánkového EEG s využitím metód založených na okamžitej frekvencii. *Elektrorevue*. 2017, roč. 19, č. 3. ISSN 1213-1539.
31. GUPTA, Manish; GAO, Jing; AGGARWAL, Charu C.; HAN, Jiawei. Outlier Detection for Temporal Data: A Survey. *IEEE Transactions on Knowledge and Data Engineering*. 2014, roč. 26, č. 9, s. 2250–2267. Dostupné z DOI: 10.1109/TKDE.2013.184.
32. BREUNIG, Markus M.; KRIEGEL, Hans-Peter; NG, Raymond T.; SANDER, Jörg. LOF: Identifying Density-Based Local Outliers. *SIGMOD Rec.* 2000, roč. 29, č. 2, s. 93–104. ISSN 0163-5808. Dostupné z DOI: 10.1145/335191.335388.
33. GURALNIK, Valery; SRIVASTAVA, Jaideep. Event Detection from Time Series Data. In: 1999, s. 33–42. Dostupné z DOI: 10.1145/312129.312190.
34. TRAN, Duc-Tan; LUU, Ha; NGUYEN, Tien Anh. A real-time vibration monitoring for vehicle based on 3-DOF MEMS accelerometer. In: 2010.
35. ARENAS-GARCÍA, Jerónimo; GÓMEZ-VERDEJO, Vanessa; NAVIA-VÁZQUEZ, Ángel. RLS Adaptation of One-Class SVM for Time Series Novelty Detection. 2004.
36. O'REILLY, Colin; GLUHAK, Alexander; IMRAN, Muhammad Ali; RAJASEGARAR, Sutharshan. Anomaly Detection in Wireless Sensor Networks in a Non-Stationary Environment. *IEEE Communications Surveys Tutorials*. 2014, roč. 16, č. 3, s. 1413–1432. Dostupné z DOI: 10.1109/SURV.2013.112813.00168.

37. HYNDMAN, Rob J.; WANG, Earo; LAPTEV, Nikolay. Large-Scale Unusual Time Series Detection. In: *2015 IEEE International Conference on Data Mining Workshop (ICDMW)*. 2015, s. 1616–1619. Dostupné z DOI: 10.1109/ICDMW.2015.104.
38. LIU, Jiang; WANG, Pengcheng; TIAN, Xincheng. Vibration displacement measurement based on three axes accelerometer. In: *2017 Chinese Automation Congress (CAC)*. 2017, s. 2374–2378. Dostupné z DOI: 10.1109/CAC.2017.8243173.
39. VARANIS, Marcus; SILVA, Anderson; MERELES, Arthur; PEDERIVA, Robson. MEMS accelerometers for mechanical vibrations analysis: a comprehensive review with applications. *Journal of the Brazilian Society of Mechanical Sciences and Engineering*. 2018, roč. 40. Dostupné z DOI: 10.1007/s40430-018-1445-5.
40. DADAFSHAR, Majid. *Accelerometer and Gyroscopes Sensors: Operation, Sensing, and Applications*. 2014.
41. VERMA, Nishchal K.; GUPTA, Rajat; SEVAKULA, Rahul K.; SALOUR, Al. Signal transforms for feature extraction from vibration signal for air compressor monitoring. In: *TENCON 2014 - 2014 IEEE Region 10 Conference*. 2014, s. 1–6. Dostupné z DOI: 10.1109/TENCON.2014.7022275.
42. POPIVANOV, I.; MILLER, R.J. Similarity search over time-series data using wavelets. In: *Proceedings 18th International Conference on Data Engineering*. 2002, s. 212–221. Dostupné z DOI: 10.1109/ICDE.2002.994711.
43. GHOSH, Ripul; AKULA, Aparna; KUMAR, Satish; SARDANA, Hk. Time–frequency analysis based robust vehicle detection using seismic sensor. *Journal of Sound and Vibration*. 2015, roč. 346, s. 424–434. Dostupné z DOI: 10.1016/j.jsv.2015.02.011.
44. SHIM, JaeSeok; KIM, GeoYoung; CHO, ByungJin; KOO, JeongSeo. Application of Vibration Signal Processing Methods to Detect and Diagnose Wheel Flats in Railway Vehicles. *Applied Sciences*. 2021, roč. 11, č. 5. ISSN 2076-3417. Dostupné z DOI: 10.3390/app11052151.

45. HAN, Sangbo. Measuring displacement signal with an accelerometer. *Journal of Mechanical Science and Technology*. 2010, roč. 24, s. 1329–1335. Dostupné z DOI: 10.1007/s12206-010-0336-1.
46. CHOWDHURY, Ranak Roy; ADNAN, Muhammad Abdullah; GUPTA, Rajesh K. Real-Time Principal Component Analysis. *ACM/IMS Trans. Data Sci.* 2020, roč. 1, č. 2. ISSN 2691-1922. Dostupné z DOI: 10.1145/3374750.
47. VETTERLI, Martin; KOVAČEVIC, Jelena. *Wavelets and Subband Coding*. Prentice-Hall, Inc., 1995. ISBN 978-0-13-097080-0.
48. MUNOZ, Arrate; ERTLÉ, Raphaël; UNSER, Michael. Continuous wavelet transform with arbitrary scales and $O(N)$ complexity. *Signal Processing*. 2002, roč. 82, č. 5, s. 749–757. ISSN 0165-1684. Dostupné z DOI: [https://doi.org/10.1016/S0165-1684\(02\)00140-8](https://doi.org/10.1016/S0165-1684(02)00140-8).
49. ROZINAJ, Gregor; RYBÁROVÁ, Renata; MINÁRIK, Ivan; KAČUR, Juraj. *Multimédiá*. 1. vyd. 2013. ISBN 978-80-01-05312-6.
50. WATTEYNE, Thomas; DOHERTY, Lance; SIMON, Jonathan; PISTER, Kris. Technical Overview of SmartMesh IP. In: *2013 Seventh International Conference on Innovative Mobile and Internet Services in Ubiquitous Computing*. 2013, s. 547–551. Dostupné z DOI: 10.1109/IMIS.2013.97.
51. YIU, Joseph. *The definitive guide to the ARM Cortex-M3*. Elsevier Inc., 2010. ISBN 978-1-85617-963-8.
52. PICKERING, J. Analogue to Digital and Digital to Analogue Converters (ADCs and DACs): A Review Update. *arXiv: Accelerator Physics*. 2016.
53. MUTHUKRISHNAN, S. Data Streams: Algorithms and Applications. *Foundations and Trends in Theoretical Computer Science*. 2005, roč. 1, č. 2, s. 117–236. ISSN 1551-305X. Dostupné z DOI: 10.1561/04000000002.
54. BAYAT, Akram; POMPLUN, Marc; TRAN, Duc A. A Study on Human Activity Recognition Using Accelerometer Data from Smartphones. *Procedia Computer Science*. 2014, roč. 34, s. 450–457. ISSN 1877-0509. Dostupné z DOI: <https://doi.org/10.1016/j.procs.2014.07.009>. The 9th International Conference on Future Networks and Communications (FNC'14)/The

11th International Conference on Mobile Systems and Pervasive Computing (MobiSPC'14)/Affiliated Workshops.

55. MACHADO., Inês; GOMES., Ricardo; GAMBOA., Hugo; PAIXÃO., Vítor. Human Activity Recognition from Triaxial Accelerometer Data - Feature Extraction and Selection Methods for Clustering of Physical Activities. In: *Proceedings of the International Conference on Bio-inspired Systems and Signal Processing - BIOSIGNALS, (BIOSTEC 2014)*. SciTePress, 2014, s. 155–162. ISBN 978-989-758-011-6. ISSN 2184-4305. Dostupné z DOI: 10.5220/0004749801550162.

Príloha A: Technická dokumentácia

Prílohy dopĺňajú hlavnú časť práce. Obsahujú napríklad podrobné informácie k jednotlivým etapám riešenia projektu. Typicky sa tu uvádza aj podstatná časť technickej dokumentácie. Pozor, prílohy nesmú obsahovať také informácie, ktoré sú pre pochopenie práce kľúčové. Tie musí obsahovať hlavná časť práce, ktorá musí byť úplná, celistvá.

Súčasťou príloh nie je len textový obsah, ale aj ďalšie artefakty, ktoré sú výsledkom projektu, napr. počítačový kód, dátové vzorky, vedecký článok či plagát. Zvláštnu pozornosť venujte tým artefaktom, ktoré sú potrebné pre replikovateľnosť postupov opisovaných v práci (napr. aby mohol oponent pri vyhodnocovaní práce zopakovať uvádzané postupy a prísť k rovnakým záverom).

Digitálne artefakty sa prikladajú na elektronickom médiu. K akémukoľvek digitálnemu obsahu treba uviesť v dokumente priebežnej či záverečnej správy bakalárskej/diplomovej práce primeraný textový opis, preto nezabudnite digitálne médium zdokumentovať. Prínajmenšom medzi prílohy zaradíte kapitolu "Obsah elektronického média". Na prílohy sa nezabudnite z hlavnej časti práce primerane odkazovať.

Obsah technickej dokumentácie závisí od povahy riešeného problému. Uvádza sa technická dokumentácia k systému (počítačový, softvérový), ktorý bol vytvorený v rámci riešenia projektu (ak sa toto v zadaní požadovalo). Samotný obsah a rozsah závisí aj od účelu vytvoreného systému (produkt, experimentovanie a pod.) V prípade softvérového systému technická dokumentácia spravidla obsahuje časti v náväznosti na etapy tvorby softvérového systému:

- dokumentáciu k etape špecifikácie požiadaviek
- dokumentáciu k etape návrhu projektu
- dokumentáciu k implementácii

- v prípade, že súčasťou riešenia sú programy, dokumentáciu k implementácii tvoria zdrojové texty programov
- v prípade, že súčasťou riešenia je návrh zariadenia, dokumentáciu k implementácii tvorí technická dokumentácia (schémy zapojenia, návrh dosiek plošných spojov, schémy rozmiestnenia súčiastok, zoznam použitých súčiastok, opis konektorov atď.)
- dokumentáciu k overeniu riešenia
- dokumentáciu k používaniu a údržbe (návod na použitie a údržbu projektu)

Príloha B: Harmonogram práce

B.1 Zimný semester

B.2 Letný semester

Príloha C: Obsah digitálneho média

Evidenčné číslo práce v informačnom systéme: FIIT-1234-98765

Obsah digitálnej časti práce (archív ZIP):

Názov odovzdaného archívu: ...zip